



CORSO DI BIG DATA – MODULO ANALISI PER I BIG DATA

Prova scritta del 12 giugno 2024

Si consideri il data set sintetico presente nel file `data.csv` costituito da 3000 punti con 15 feature numeriche cadauno e una label binaria di classe con valori appartenenti a {0, 1}.

1. Caricare il dataset, estrarre randomicamente un test set pari al 5% dei dati, mantenendo il restante 95% come training set vero e proprio. Calcolare e stampare la matrice di correlazione tra le feature e trasformare gli eventuali dati multicollineari con una opportuna combinazione lineare. Infine selezionare le feature rilevanti tramite il Fisher score.

punti ____/ 8

2. Implementare un classificatore SVM non lineare per il data set curato come al punto precedente con i seguenti iperparametri:

- $C = \{1, 1/\sqrt{n_samples}\}$
- kernel=RBF e polinomiale
- grado del kernel polinomiale = {3, 4}

Usare l'accuracy come metrica e stampare l'accuracy del miglior classificatore e la test accuracy ottenuta in predizione.

punti ____/ 8

3. Implementare in Tensorflow una piccola rete neurale densa con almeno due layer che esegua la classificazione binaria del data set curato, risultato del punto 1. Si utilizzi un opportuno ammontare di dropout sui layer densi ad esclusione del primo. La rete sarà addestrata con ottimizzatore RMSProp in versione "centrata" con weight decay e momento pari 0.1. Si implementino le callback di early stopping, con validation set pari al 10% del training set, una pazienza sulla validation loss di 5 epoche e un incremento minimo di miglioramento pari a 0.01; infine, la modelcheckpoint salverà solo il miglior modello rispetto alla massima validation accuracy.

punti ____/ 10

4. Confrontare i risultati dei due classificatori calcolando e stampando, per ciascuno, la matrice di confusione, il valore di accuracy, la ROC e il valore di AUC calcolati sul test set.

punti ____/ 4

TOTALE: punti ____/ 30

Data: _____ Allievo: _____ Matricola: _____



Regole della prova scritta

Di seguito si riportano le regole da seguire e le caratteristiche della prova ai fini della valutazione:

1. La durata complessiva della prova è pari a due ore e prevede una serie di quesiti che approfondiscono diversi aspetti dello stesso problema: ognuno sarà libero di dedicare ad ogni quesito il tempo che vorrà.
2. La prova si svolge **interamente** al calcolatore.
3. L'ambiente di sviluppo predisposto è un environmet conda denominato `spyder-env`, direttamente accessibile da Visual Studio Code
4. Ai fini dell'avvio dell'ambiente, aprire Visual Studio Code e dal suo file manager selezionare la cartella BigData sul Desktop e creare un nuovo notebook per il quale si selezionerà l'ambiente illustrato precedentemente.
5. Sarà consentito consegnare dopo la prima ora di prova.
6. Sarà necessario spegnere e consegnare i dispositivi mobili (smartphone, smartwatch e tablet) alla cattedra prima dello svolgimento della prova.
7. La navigazione internet dalle postazioni sarà bloccata, in generale, e consentita solo verso i siti di documentazione delle librerie ed il repository delle slide in pdf.
8. Il docente distribuirà copia digitale del compito ed eventuali data set direttamente dalla propria postazione ovvero tramite penna USB e allo stesso modo raccoglierà gli elaborati di programmazione.
9. Il candidato consegnerà comunque il presente foglio datato e con l'indicazione del nome e del numero di matricola.
10. Ai fini del calcolo del voto finale della prova, il valore massimo di ciascun quesito è riportato in calce allo stesso. La prova riceverà una valutazione pari alla somma dei voti riportati in ciascun quesito. Si precisa che il docente attribuirà ad ogni quesito una votazione non binaria, cioè non tutto il valore oppure 0, ma valuterà la correttezza formale dell'elaborato, il rigore metodologico dell'approccio teorico e l'originalità delle soluzioni proposte per attribuire una votazione nel range definito dal valor massimo del quesito.

Data: _____ Allievo: _____ Matricola: _____