

CORSO DI BIG DATA
MODULO DI MACHINE LEARNING PER I BIG DATA

Testo Esercitazione 1

Si esegua il preprocessing del data set `heart_disease_uci.csv` in allegato nella cartella `data`, che riporta l'unione di quattro studi clinici su pazienti con sindromi coronariche. Il data set classifica ogni record sulla base di quattro etichette differenti rispetto alla gravità della sindrome. Le informazioni relative al data set si trovano all'indirizzo: <https://archive.ics.uci.edu/dataset/45/heart+disease>.

Si richiedono le seguenti fasi di processing:

- Analisi delle righe eccessivamente sparse per la rimozione
- Analisi delle colonne eccessivamente sparse per la rimozione
- Encoding delle feature categoriche
- Split train/test
- Imputazione delle feature mancanti
- Analisi delle feature multicollineari a partire dalla matrice di correlazione
- Feature selection