

CORSO DI BIG DATA
MODULO DI MACHINE LEARNING PER I BIG DATA

Testo Esercitazione 2

Si esegua l'interpolazione polinomiale sui punti del data set `function_1000_25.csv` in allegato nella cartella `data`, che riporta 1000 punti che descrivono una sinusoide, ma corrotti dal 25% di rumore gaussiano.

Il data set dovrà essere soggetto primariamente a rimozione degli outlier con il metodo Local Outlier Factor, gestendo il valore dei vicini considerati per ogni punto e il livello di contaminazione del rumore previsto dal metodo.

Successivamente, si implementerà un modello di regressione polinomiale scegliendo una lista di valori del grado del polinomio e, per ogni grado, si eseguiranno 20 run di addestramento ripetendo la procedura di split train/test per ogni run. In questo modo si calcoleranno i valori medi e le deviazioni standard del MSE_{train} e del MSE_{test} .

Infine, si creerà il plot dell'andamento del MSE_{train} e del MSE_{test} al variare del grado del polinomio per osservare quale sia la capacità ottima del modello.