

Python

Esercitazione Clustering

A.A. 2025/2026

Prof. Salvatore Contino

salvatore.contino01@unipa.it



Informazioni generali



Prof. Salvatore Contino

Ph.D. in Ingegneria Informatica
RTD-a IBIO-01/A



Sezione di informatica edificio 6, 3° piano,
Laboratorio d'Interazione Uomo-Macchina

E-mail: salvatore.contino01@unipa.it

AI per la salute

Le attività del laboratorio si focalizzano:

- **Medicina di Precisione**
 - Modelli multimodali per la diagnosi precoce
 - Modelli multimodali per la risposta farmaceutica ed il follow-up
 - Digital Pathology per il supporto al reparto di anatomia patologica
 - Clustering di popolazione per individuare malattie metaboliche del fegato
- **Ricerca farmaceutica**
 - Drug Discovery
 - Drug Repurposing
 - Hierarchical Graph Explainer
- **Sviluppo di algoritmi e strutture dati innovative**
 - Federated Learning e algoritmi di gestione di unbalanced data
 - Sviluppo di algoritmi di segmentazione condizionati dal testo
 - Studio dei meccanismi di Reasoning
 - Ontologie e OntoRAG
 - LLMs per la telemedicina (foglio dimissioni e gestione P.S.)
 - Nuovi modelli per classificazione e segmentazione



Link download

<https://github.com/CHILab1/Esercitazioni-Big-Data.git>

Dataset download



Categoria	Variabile	Descrizione
Demografica	age	Età del paziente (anni)
Demografica	sex	Sesso (M/F)
Demografica	race	Etnia
Demografica	income	Livello di reddito
Demografica	edu	Anni di istruzione
Clinica	dzgroup	Gruppo diagnostico principale
Clinica	dzclass	Classe diagnostica aggregata
Clinica	num.co	Numero di comorbidità
Clinica	diabetes	Presenza diabete
Clinica	dementia	Presenza demenza
Clinica	ca	Presenza cancro
Parametri vitali	scoma	Livello di coma
Parametri vitali	meanbp	Pressione arteriosa media
Parametri vitali	hrt	Frequenza cardiaca
Parametri vitali	resp	Frequenza respiratoria
Parametri vitali	temp	Temperatura corporea
Parametri vitali	wblc	Globuli bianchi
Laboratorio	alb	Albumina
Laboratorio	bili	Bilirubina
Laboratorio	crea	Creatinina
Laboratorio	sod	Sodio
Laboratorio	ph	pH sangue
Laboratorio	glucose	Glucosio
Laboratorio	bun	Azoto ureico
Laboratorio	urine	Produzione di urina
Laboratorio	pafi	Rapporto ossigenazione
Score	aps	Acute Physiology Score
Score	sps	Support Prognostic Score
Funzionalità	adlp	Attività quotidiane prima del ricovero
Funzionalità	adls	Attività quotidiane al ricovero
Funzionalità	adlsc	Versione categorizzata
Costi	charges	Costi ospedalieri
Costi	totcst	Costo totale
Costi	totmcst	Costo medico totale
Costi	avtisst	Costo medio giornaliero
Outcome	death	Morte (0/1)

Esercizi da svolgere



1. Si consideri il dataset clinico SUPPORT2, contenente informazioni demografiche, fisiologiche e di laboratorio relative a pazienti ospedalizzati. Dopo aver caricato i dati, rimuovere le variabili di outcome e prognosi (e.g. dzgroup, dzclass) per evitare fenomeni di data leakage e selezionare la variabile target (ad esempio *death*).
2. Suddividere il dataset in training set (95%) e test set (5%) utilizzando un campionamento stratificato rispetto alla variabile target («*death*»), in modo da preservare la distribuzione delle classi.
3. Gestire i dati mancanti applicando imputazione con mediana per le variabili numeriche e con un valore costante (ad esempio "Unknown") per quelle categoriche; successivamente codificare le variabili categoriche tramite Ordinal Encoding.
4. Applicare lo scaling delle feature numeriche tramite z-scoring, quindi calcolare e analizzare la matrice di correlazione, individuando eventuali coppie di variabili altamente correlate e discutendo la presenza di multicollinearità.
5. Gestire la multicollinearità mediante rimozione di feature ridondanti o tramite una trasformazione lineare (ad esempio PCA), e infine applicare un metodo di selezione delle feature per identificare le variabili più rilevanti, commentando criticamente i risultati ottenuti.

Esercizi da svolgere

5. Implementare un clustering dei punti del data set processato nelle fasi precedenti, utilizzando l'algoritmo DBSCAN con una griglia di ricerca degli iper-parametri:

MinPts = 5, 10, 20

Eps = 0.5, 1.5, 2.0

Stampare l'accuracy del modello di clustering sul training set e sul test set. Valuta la purezza del clustering.

6. Implementare un clustering dei punti del dataset processato nelle fasi precedenti, utilizzando un secondo algoritmo di clustering. La selezione dell'algoritmo deve essere coerente con la natura del dato. Valuta la purezza del clustering.
7. Esegui la comparazione delle performance utilizzando l'etichetta «*death*» con criteri di valutazione esterni.