

CORSO DI BIG DATA
MODULO DI MACHINE LEARNING PER I BIG DATA

Testo Esercitazione 4

Con riferimento al data set dell'esercitazione su clustering, eseguire una classificazione binaria sulla feature `death`, una classificazione multiclasse sulla feature `dzgroup` ed una regressione sulla feature `aps`.

Di seguito si riportano i passi da seguire **separatamente** per ciascun task:

1. Procedere allo split train-test secondo il rapporto 95%-15% in forma stratificata secondo i valori della variabile target.
2. Eseguire l'imputazione dei dati mancanti con le stesse strategie dell'esercitazione precedente.
3. Rimuovere le feature che presentano elevata correlazione con la variabile target e successivamente analizzare le possibili feature multicollineari rimanenti.
4. Utilizzare RandomForestClassifier per la classificazione e RandomForestRegressor per la regressione con i seguenti iperparametri(*)
 - a. Classificatore
 - i. criterion: "gini", "log_loss"
 - ii. min_samples_split: 2, 5, 10
 - iii. max_features: "sqrt", 5
 - b. Regressore
 - i. criterion: "squared_error", "absolute_error"
 - ii. min_samples_split: 2, 5, 10
 - iii. max_features: "sqrt", 5
5. Valutare il regressore sul test set con la metrica R2, il classificatore binario con la curva ROC e la relativa AUC ed il classificatore multiclasse con le curve ROC e le AUC di ogni classe, ciascuna valutata in modalità one-vs-rest.

(*) Si noti che gli iperparametri indicati potrebbero **non essere** quelli ottimali perché il modello di addestramento bene. Opzionalmente si discuta se non sia il caso di condizionare il modello ad altri iperparametri e si conducano le relative prove.