



**Università
degli Studi
di Palermo**



Introduzione al Modulo

CORSO DI BIG DATA – MODULO MACHINE LEARNING PER I BIG DATA
a.a. 2025/2026


Prof. Roberto Pirrone

Il Docente

- Roberto Pirrone
 - Studio: Edificio 6a, terzo piano, stanza 3025
 - Email: roberto.pirrone@unipa.it,
roberto.pirrone@community.unipa.it (Google)
 - Telefono studio: 091238.62625, laboratorio: .62643
 - Ricevimento: ogni giovedì dalle 10:00 alle 12:00 presso il proprio studio

Il Laboratorio

- Laboratorio di Interazione Uomo-Macchina
 - Edificio 6a, terzo piano, a sx dalle scale
 - Email: chilab@unipa.it
 - Telefono: 091238.62643



Università
degli Studi
di Palermo



E adesso

Cosa vi aspettate da questo corso?

Cosa pensate che sia «ML per i Big Data»?



Università
degli Studi
di Palermo



dipartimento
di ingegneria
unipa



Cosa non è «Machine Learning per i Big Data»

- Il modulo di «Machine Learning per i Big Data» *non è*:
 - Un corso di Python (anche se lo useremo tantissimo)
 - Una serie di tutorial su framework più o meno esoterici (anche se ne abbiamo studiati e ne studieremo ancora diversi)
 - Un corso di Machine Learning (anche se ne studieremo un bel po')

Cosa non è «Machine Learning per i Big Data»

- *Non è possibile* studiare analiticamente tutte le librerie Python che useremo durante il corso!!!


```
class sklearn.mixture.GaussianMixture(n_components=1, *, covariance_type='full', tol=0.001,  
reg_covar=1e-06, max_iter=100, n_init=1, init_params='kmeans', weights_init=None,  
mean>>> import numpy as np  
verb>>> import matplotlib.pyplot as plt  
>>> from scipy.stats import multivariate_normal  
DataFrame.groupby(by=None, level=None, *, as_index=True, sort=True,  
group_keys=True, observed=True, dropna=True) [sou
```

```
>>> x = np.linspace(0, 5, 10, endpoint=False)  
>>> y = multivariate_normal.pdf(x, mean=2.5, cov=0.5); y  
array([ 0.00108914,  0.01033349,  0.05946514,  0.20755375,  0.43939129,  
        0.56418958,  0.43939129,  0.20755375,  0.05946514,  0.01033349])  
>>> fig1 = plt.figure()  
>>> ax = fig1.add_subplot(111)  
>>> ax.plot(x, y)  
>>> plt.show()
```

```
return F.relu(self.conv2(x))
```


Cosa non è «Machine Learning per i Big Data»

- Non è possibile studiare nel dettaglio tutte le soluzioni software che gravitano anche nel solo mondo dell'analisi dei Big Data!!!



© Matt Turck (@mattturck) and ShivonZilis (@shivonz)

Fonte <http://bit.ly/40juPDK>

Cosa è «Machine Learning per i Big Data»

- Il modulo di «Machine Learning per i Big Data» è un insieme degli argomenti visti prima, ma integrati opportunamente per consentirvi di progettare delle *pipeline di analisi dei dati*
- Un Ingegnere Informatico deve conoscere:
 - Le architetture software per i Big Data (modulo precedente)
 - I componenti giusti per il problema in esame (e qui ci aiuta questo modulo)

Cosa è «Machine Learning per i Big Data»

- Una corretta architettura per un problema di analisi dei dati richiede che
 - Si conoscano le caratteristiche numeriche e statistiche dei vari tipi di dati 
 - Si determinino le corrette fasi di acquisizione e preprocessing in ingresso all'architettura  
 - Si individuino i processi e i componenti più adatti per l'analisi, la valutazione e la visualizzazione 

Cosa è «Machine Learning per i Big Data»

- Tutto questo richiederà un po' di *appoggio esterno*
 - Le caratteristiche *statistiche* dei dati
 - Un linguaggio di programmazione che ci supporti in tutto il processo: *Python*
 - E' orientato all'analisi dei dati
 - Ha tutte le librerie necessarie
 - Supporta i principali framework per i Big Data e per il Machine Learning e Deep Learning

Il Syllabus

- Le informazioni complete sugli obiettivi didattici del corso, il programma delle lezioni e i libri di testo si trovano nella *Scheda di Trasparenza*



Il Syllabus

- Testi consigliati
 - Data Mining: The Textbook, 2015, Charu C. *Aggarwal*, Springer-Verlag New York, ISBN 978-3319141411 (prezzo orientativo € 70,00)
 - Deep Learning, (2016), di Ian Goodfellow, Yoshua *Bengio*, Aaron Courville, MIT Press, ISBN 978-0262035613 (prezzo orientativo €65,00)

Il Syllabus

ORE	Lezioni ed Esercitazioni	Testo rif.
2	Introduzione al Corso. Cenni di Teoria della Probabilità e Teoria dell'Informazione; stimatori statistici e tecniche di campionamento.	Estratti dal Bengio capp. 3 e 17.1-2
3	Introduzione al Machine Learning: apprendimento supervisionato, non supervisionato, apprendimento con rinforzo, capacità del modello, parametri e iperparametri, tipologie di errore, tecniche di addestramento.	Estratti dal Bengio cap. 5
6	Esercitazione su introduzione a scikit learn con richiami di pandas, numpy, matplotlib e seaborn, e sul data processing: imputazione di dati mancanti, scaling ed encoding delle feature, analisi di correlazione e feature multicollineari.	Introduzione con slide docente
6	Esercitazione sull'apprendimento dei modelli: costruzione di un semplice regressore e osservazione dell'andamento del MSE al variare dell'iperparametro per comprendere il concetto di underfitting e overfitting.	Introduzione con slide docente

Il Syllabus

ORE	Lezioni ed Esercitazioni	Testo rif.
5	Clustering: k-means e sue varianti, clustering gerarchico, clustering density based e a griglia, clustering basato su grafi, clustering di dati ad elevata dimensionalità, validazione del clustering, analisi degli outlier.	Aggarwal cap. 6
6	Esercitazione sul clustering: feature selection, uso del clustering, griglia di ricerca degli iperparametri, valutazione.	Introduzione con slide docente
7	Classificatori: feature selection, decision tree e classificatori a regole, Naive Bayes, regressione logistica, Support Vector Machines, Nearest Neighbor, valutazione dei classificatori. : Multi-class e rare class learning, regressione su dati numerici, semi-supervised learning, metodi di ensemble.	Aggarwal capp. 10 e 11
6	Esercitazione sui classificatori: feature selection, uso del clustering, griglia di ricerca degli iperparametri, valutazione.	Introduzione con slide docente

Il Syllabus

ORE	Lezioni ed Esercitazioni	Testo rif.
7	Deep Learning: struttura di una rete neurale, tipologia di unità nascoste e di uscita, funzioni di loss, concetto di grafo di computazione, stochastic gradient descent, ottimizzazione e regolarizzazione, CNN, Autoencoder, LSTM, GAN, Graph Neural Networks, fine tuning e transfer learning.	Estratti dal Bengio capp. 6, 7 e 8 Slide docente
6	Esercitazione sul Deep Learning: Introduzione a PyTorch usando un semplice esempio di classificazione multi-classe: istanza del modello, train-test loop, valutazione del modello sul test set.	Introduzione con slide docente

- Le diverse esercitazioni costituiscono i singoli passi di una pipeline di analisi dei dati
- Ritroveremo questi passi nel compito di esame
- Alla fine del corso svolgeremo delle simulazioni di esame

Il materiale didattico

- Le slide da sole *non sono* materiale didattico: esse sono a compendio dei libri di testo, della spiegazione orale del docente e degli *appunti* presi dallo studente
- *Suggerimento*: stampate le slide prima della lezione e annotatele con i vostri appunti

Il materiale didattico

- Repository GitHub del corso
 - Contiene:
 - I file pdf di tutte le slide (incluse queste)
 - Le slide guida delle esercitazioni
 - Eventuali codici di supporto da usare nelle esercitazioni
 - I dati utilizzati nelle esercitazioni



Gli esami

- Compito scritto al calcolatore con allegato un data set su cui vi verrà richiesto di effettuare il pre-processing, l'analisi di tipo ML/DL e la valutazione delle prestazioni
 - 1 quesito di difficoltà bassa (4 o 6 /30)
 - 2 quesiti di difficoltà media (6 o 8 /30 ciascuno)
 - 1 quesito di difficoltà alta (10 /30)
- Per ogni quesito il voto viene attribuito «gradualmente» e non in maniera binaria

Gli esami

- Il compito dura due ore e vi viene fornito l'environment Python su VS Code
- Riceverete una mail personale al vostro indirizzo community.unipa.it contenente il voto totale e la valutazione scritta di ciascun quesito
- Verrà svolto un breve colloquio orale sugli argomenti di teoria

Gli esami

- Il voto finale parte da una media del risultato del primo modulo e del compito scritto di questo modulo e poi tiene conto del colloquio orale
- La media di partenza può salire o *scendere!!*

Le tesi di laurea

- Le possibili tesi di laurea presso il nostro Laboratorio riguardano le applicazioni dell'IA alla salute:
 - Analisi di strutture molecolari per il supporto intelligente al Drug Discovery/Repurposing
 - Analisi di strutture polimeriche per il supporto allo sviluppo di nuovi (bio-)materiali
 - Integrazione degli algoritmi di AI nei sistemi radiologici ospedalieri (PACS)
 - Sistemi di interazione Medico-sistema diagnostico basati sulle Intelligenze Artificiali Generative (Chat-GPT e simili)
 - Segmentazione di scansioni TAC, RM, PET usando le reti neurali ed i modelli generativi

Le tesi di laurea

- Altra alternativa possono essere le tesi aziendali che abbiano attinenza con l'analisi dei dati e *siano di interesse per il nostro laboratorio*
- Vengono pubblicate sul sito del Corso di Laurea
- Cercate quelle in cui io sono relatore



Le tesi di laurea

- Vincoli sull'assegnazione della tesi
 - Che ci sia uno slot libero (*max 6 tesisti in contemporanea*, altrimenti deve prima laurearsi qualcuno per poter avere la tesi)
 - Che siano garantiti almeno sei mesi effettivi di lavoro consecutivamente al netto delle altre materie e del tirocinio (ci sono 24 CFU di lavoro)
 - Discutiamo della tesi a valle delle *materie pesanti*
 - Non ha senso chiedere la tesi un anno prima, quando ancora si devono sostenere altri esami e si «scompare» per mesi

Le tesi di laurea

- Vincoli sull'assegnazione della tesi
 - Dopo aver definito l'argomento, si verrà affidati ad uno o più ricercatori e/o dottorandi del laboratorio
 - Ci si incontrerà con i propri referenti (anche on line) *al più settimanalmente* sullo stato di avanzamento lavori
 - Riunioni periodiche in presenza con me
 - Manifestate il vostro interesse sin da ora!!
 - L'anno prossimo c'è anche «Natural Language Processing»