



**Università
degli Studi
di Palermo**



Richiami di Teoria della Probabilità

CORSO DI BIG DATA – MODULO MACHINE LEARNING PER I BIG DATA
a.a. 2025/2026

Prof. Roberto Pirrone

Sommario

- Probabilità di variabili discrete
- Probabilità marginale, condizionale e congiunta di variabili discrete
- Variabili continue
- Densità di probabilità e distribuzione di probabilità
- Probabilità marginale, condizionale e congiunta di variabili continue
- Indipendenza statistica e condizionale
- Media varianza e covarianza
- Correlazione
- Regola di Bayes
- Principali distribuzioni di probabilità
- Cenni di teoria dell'informazione

Probabilità di variabili discrete

- Una variabile casuale discreta X assume valori casuali appartenenti ad un insieme discreto $\mathcal{X} = \{x_i, i = 1, 2, \dots\}$
- Se, su N osservazioni di X , registriamo che c_i volte $X=x_i$:

$$p(X = x_i) = \frac{c_i}{N}$$

$$\forall x_i, 0 \leq p(X = x_i) \leq 1$$

$$\sum_{x_i} p(X = x_i) = 1$$

Probabilità di variabili discrete

- La legge che esprime la probabilità $P(x) = p(X = x)$, $x \in \mathcal{X}$ per una certa variabile casuale discreta X , si chiama *distribuzione discreta di probabilità*
- Formalmente la distribuzione discreta di probabilità è realizzata da una *funzione massa di probabilità* (Probability Mass Function) che esprime il fatto che una certa probabilità è *concentrata* su ogni elemento di $\mathcal{X}$.

Probabilità condizionale e congiunta

- Sia n_{ij} il numero di osservazioni di un'altra variabile $Y=y_j$ quando $X=x_i$, allora La probabilità che $Y=y_j$ posto che $X=x_i$ è:

$$p(Y = y_j | X = x_i) = \frac{n_{ij}}{c_i}$$

- Calcoliamo la probabilità congiunta che $Y=y_j$ e $X=x_i$

$$p(X = x_i, Y = y_j) = \frac{n_{ij}}{N} = \frac{n_{ij}}{c_i} * \frac{c_i}{N} =$$

$$p(Y = y_j | X = x_i) * p(X = x_i)$$

Regola del prodotto

Probabilità marginale

- Il numero totale c_i di osservazioni di $X=x_i$ è:

$$c_i = \sum_j n_{ij}$$

$$p(X = x_i) = \sum_j p(X = x_i, Y = y_j)$$

Regola della somma

Probabilità marginale

- Se sostituiamo la regola del prodotto in quella della somma:

$$\begin{aligned} p(X = x_i) &= \sum_j p(X = x_i, Y = y_j) \\ &= \sum_j p(X = x_i | Y = y_j) * p(Y = y_j) \end{aligned}$$

Probabilità marginale

	x_1	x_2	x_3	x_4	$p_Y(Y) \downarrow$
y_1	$\frac{1}{8}$	$\frac{1}{16}$	$\frac{1}{32}$	$\frac{1}{32}$	$\frac{1}{4}$
y_2	$\frac{1}{16}$	$\frac{1}{8}$	$\frac{1}{32}$	$\frac{1}{32}$	$\frac{1}{4}$
y_3	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{4}$
y_4	$\frac{1}{4}$	0	0	0	$\frac{1}{4}$
$p_X(X) \rightarrow$	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{8}$	$\frac{1}{8}$	1

Variabili continue

- Se x è una variabile continua in $\mathbb{R}$, le sommatorie divengono integrali
- La probabilità che $x \in [a, b]$ è:

$$p(x \in [a, b]) = \int_a^b p(x) dx$$

Densità di probabilità e distribuzione di probabilità

- La legge che esprime la probabilità $P(x) = p(x = x)$, $x \in \mathbb{R}$ per una certa variabile casuale continua x , si chiama *distribuzione di probabilità* di cui la funzione densità di probabilità è la realizzazione


N.B. $x \rightarrow$ la variabile, $x \rightarrow$ il singolo valore che essa può assumere

Densità di probabilità e distribuzione di probabilità

$$p(x) \geq 0, \int_{-\infty}^{\infty} p(x) dx = 1$$

$$P(z) = \int_{-\infty}^z p(x) dx \equiv p(x \leq z)$$

Distribuzione cumulativa di probabilità



Probabilità marginale e condizionale di variabili continue

$$p(x) = \int p(x, y) dy$$

$$P(y = y, x = x) = P(y = y | x = x) P(x = x)$$

$$P \left(x^{(1)}, \dots, x^{(n)} \right) = P \left(x^{(1)} \right) \prod_{i=2}^n P \left(x^{(i)} | x^{(1)}, \dots, x^{(i-1)} \right)$$

Indipendenza statistica e condizionale

- Indipendenza statistica

$$\forall x \in \mathbf{x}, y \in \mathbf{y}, p(\mathbf{x} = x, \mathbf{y} = y) = p(\mathbf{x} = x)p(\mathbf{y} = y)$$

- Indipendenza condizionale

$$\begin{aligned} \forall x \in \mathbf{x}, y \in \mathbf{y}, z \in \mathbf{z}, p(\mathbf{x} = x, \mathbf{y} = y | \mathbf{z} = z) \\ = p(\mathbf{x} = x | \mathbf{z} = z)p(\mathbf{y} = y | \mathbf{z} = z) \end{aligned}$$

Media varianza e covarianza

- La media o valore atteso, è un operatore lineare

Se x è una variabile aleatoria
qualunque variabile $y = f(x)$ è ancora
Una variabile aleatoria!!

$$\mathbb{E}_{x \sim P}[f(x)] = \sum_x P(x) f(x)$$

$$\mathbb{E}_{x \sim p}[f(x)] = \int p(x) f(x) dx$$

$$\mathbb{E}_x[\alpha f(x) + \beta g(x)] = \alpha \mathbb{E}_x[f(x)] + \beta \mathbb{E}_x[g(x)]$$

Media varianza e covarianza

- La varianza è il valore atteso della differenza tra $f(x)$ ed il quadrato del suo valore atteso

$$\text{Var}(f(x)) = \mathbb{E} [(f(x) - \mathbb{E}[f(x)])^2] = \\ \mathbb{E} [f(x)^2] - \mathbb{E} [f(x)]^2$$

Sviluppo il quadrato, ricordandomi che $\mathbb{E}[\mathbb{E}[x]] \equiv \mathbb{E}[x]$

Media varianza e covarianza

- Proprietà della varianza (sotto ipotesi di indipendenza statistica)

$$\begin{aligned}\text{Var}(\alpha \cdot f(x)) &= \mathbb{E} [\alpha^2 \cdot f(x)^2] - \mathbb{E} [\alpha \cdot f(x)]^2 = \\ &\alpha^2 \cdot \mathbb{E} [f(x)^2] - \alpha^2 \cdot \mathbb{E} [f(x)]^2 = \\ &\alpha^2 \cdot \left(\mathbb{E} [f(x)^2] - \mathbb{E} [f(x)]^2 \right) \equiv \alpha^2 \cdot \text{Var}(f(x))\end{aligned}$$

Ricordiamo che: $(E[\alpha X])^2 = (\alpha E[X])^2 = \alpha^2 (E[X])^2$

Media varianza e covarianza

- Proprietà della varianza (sotto ipotesi di indipendenza statistica)

$$\begin{aligned}\text{Var}(f(x) + g(y)) &= \mathbb{E} [(f(x) + g(y))^2] - \mathbb{E} [(f(x) + g(y))]^2 = \\ &= \text{Var}(f(x)) + \text{Var}(g(y))\end{aligned}$$

Media varianza e covarianza

- La covarianza esprime quanto due variabili aleatorie siano legate linearmente l'una all'altra

$$\begin{aligned}\text{Cov}(f(x), g(y)) &= \mathbb{E}[(f(x) - \mathbb{E}[f(x)])(g(y) - \mathbb{E}[g(y)])] = \\ &\mathbb{E}[f(x)g(y)] - \mathbb{E}[f(x)]\mathbb{E}[g(y)]\end{aligned}$$

Media varianza e covarianza

- In un data set $\mathcal{D}$ di n campioni $\mathbf{x}_i \in \mathbb{R}^d$ che possiamo considerare *manifestazioni casuali del fenomeno da essi descritto*, la covarianza è una *matrice*

$$D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\} \quad \text{con} \quad \mathbf{x}_i \in \mathbb{R}^d \quad \mathbf{x}_i = \begin{bmatrix} x_i^{(1)} \\ x_i^{(2)} \\ \vdots \\ x_i^{(d)} \end{bmatrix} \quad \mathbb{E}[\mathbf{x}] = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$$

$$\Sigma = \mathbb{E} \left[(\mathbf{x} - \mathbb{E}[\mathbf{x}]) (\mathbf{x} - \mathbb{E}[\mathbf{x}])^T \right]$$

$$\Sigma = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \mathbb{E}[\mathbf{x}]) (\mathbf{x}_i - \mathbb{E}[\mathbf{x}])^T$$

Media varianza e covarianza

- Le variabili aleatorie sono «le singole componenti» dei campioni e quindi gli elementi della matrice esprimono le covarianze tra coppie di componenti, in valore atteso su tutto $\mathcal{D}$

$$\Sigma_{jk} = \text{Cov} \left(x^{(j)}, x^{(k)} \right) = \mathbb{E} \left[\left(x^{(j)} - \mathbb{E} \left[x^{(j)} \right] \right) \left(x^{(k)} - \mathbb{E} \left[x^{(k)} \right] \right) \right]$$

$$\Sigma_{jk} = \frac{1}{n} \sum_{i=1}^n \left(x_i^{(j)} - \mathbb{E} \left[x^{(j)} \right] \right) \left(x_i^{(k)} - \mathbb{E} \left[x^{(k)} \right] \right)$$

$$\Sigma_{jj} = \text{Var} \left(x^{(j)} \right) = \mathbb{E} \left[\left(x^{(j)} - \mathbb{E} \left[x^{(j)} \right] \right)^2 \right]$$

Correlazione

- La matrice di covarianza di una data set $\mathcal{D}$ esprime come le varie componenti dei campioni $\mathbf{x}_k$ (le singole *feature*) siano più o meno legate linearmente tra loro.
- E' una matrice semidefinita positiva
- Esiste anche un altro indice, derivato dalla covarianza, che viene spesso utilizzato per indicare quanto due feature siano collegate ed è il *coefficiente di correlazione* o *indice di correlazione di Pearson*

Correlazione

- Si consideri il caso di due variabili aleatorie X e Y
- Il coefficiente di correlazione si definisce come

$$\Sigma_{X,Y} = \begin{bmatrix} \sigma_X^2 & \text{Cov}(X, Y) \\ \text{Cov}(X, Y) & \sigma_Y^2 \end{bmatrix}$$
$$\det \Sigma_{X,Y} = \sigma_X^2 \sigma_Y^2 - \text{Cov}(X, Y)^2 \geq 0$$

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} \in [-1, 1]$$

Indica il segno della correlazione!!

Teorema di Bayes

- Dalla definizione di probabilità condizionale, ci rendiamo conto che è possibile esprimere la probabilità congiunta $P(x,y)$ di due variabili correlate sia a partire da $P(x|y)$ sia a partire da $P(y|x)$

$$P(x|y) = \frac{P(y|x)P(x)}{P(y)}$$

Teorema di Bayes

- Assumiamo di avere un dataset $\mathcal{D}$ dal quale vogliamo apprendere un modello descritto da un vettore di parametri $\mathbf{w}$
- Avremo appreso il miglior modello quando avremo massimizzato la «probabilità a posteriori» o *posterior* $P(\mathbf{w} | \mathcal{D})$
 - Ciò che possiamo stimare *dopo* aver osservato i dati

Teorema di Bayes

- Il teorema di Bayes correla il *posterior* con:
 - la conoscenza a priori o *prior* sul nostro modello: $P(\mathbf{w})$
 - la verosimiglianza o *likelihood* del nostro modello, espresso dalla probabilità di predire effettivamente $\mathcal{D}$ usando i parametri del modello $\mathbf{w}$: $P(\mathcal{D}|\mathbf{w})$

$$P(\mathbf{w}|\mathcal{D}) = \frac{P(\mathcal{D}|\mathbf{w})P(\mathbf{w})}{P(\mathcal{D})}$$

$$\text{posterior} \propto \text{likelihood} \times \text{prior}$$

Teorema di Bayes

- La conoscenza a priori di $P(\mathcal{D})$ non è altro che la probabilità marginale espressa in termini del numeratore:

$$P(\mathcal{D}) = \int p(\mathcal{D}|\mathbf{w})p(\mathbf{w})d\mathbf{w}$$

- Non è necessaria:
 - Elimina la dipendenza del problema dai parametri del modello $\mathbf{w}$ che invece sono il nostro obiettivo
 - È da ritenersi una costante perché è l'evidenza del data set a prescindere dalla scelta dei parametri

Principali distribuzioni di probabilità

- Quale forma uso per descrivere queste probabilità?
- Tanti dati:
 - Multidimensionali
 - Categorici
 - Serie discrete
 - ...
- *Diverse tipologie di distribuzioni di probabilità che li sottendono*
- Dobbiamo conoscerle perché il Machine Learning è un *processo di stima delle distribuzioni di probabilità sui dati a partire da quelli osservati dal modello*

Principali distribuzioni di probabilità

- Distribuzione di Bernoulli (o binomiale) per variabili binarie

$$P(x = 1) = \phi$$

$$P(x = 0) = 1 - \phi$$

$$P(x = x) = \phi^x (1 - \phi)^{1-x}$$

$$\mathbb{E}_x[x] = \phi$$


$$\text{Var}_x(x) = \phi(1 - \phi)$$

Principali distribuzioni di probabilità

- Distribuzione di Bernoulli (o binomiale) per variabili binarie

$$\text{Bin}(n, p) = \binom{n}{k} p^k (1 - p)^{n-k}$$

k : numero di osservazioni di $x=1$ su n tentativi



Principali distribuzioni di probabilità

- Distribuzione Multinoulli (distribuzione categorica) in cui $\mathbf{x}$ è una variabile continua che può assumere uno tra K stati diversi

$$\mathbf{x} = (0_1, 0_2, \dots, 1_k, \dots, 0_K)^T \quad \text{One-hot encoding}$$

$$p(\mathbf{x}|\boldsymbol{\mu}) = \prod_{k=1}^K \mu_k^{x_k}$$

$$\boldsymbol{\mu} = (\mu_1, \dots, \mu_K)^T, \quad \mu_k = p(x_k = 1)$$

Principali distribuzioni di probabilità


- Distribuzione multinomiale (generalizza la binomiale) per variabili discrete
 - date N osservazioni descrive la probabilità di osservare m_k volte lo stato $x_k=1$ da una distribuzione Multinoulli con media $\boldsymbol{\mu}$

$$\text{Mult} (m_1, m_2, \dots, m_K | \boldsymbol{\mu}, N) = \binom{N}{m_1 m_2 \dots m_K} \prod_{k=1}^K \mu_k^{m_k}$$

Principali distribuzioni di probabilità

- Distribuzione esponenziale
 - Si utilizza quando si vuole concentrare la probabilità vicino a 0


$$p(x; \lambda) = \lambda \mathbf{1}_{x \geq 0} \exp(-\lambda x)$$



Principali distribuzioni di probabilità

- Distribuzione di Laplace
 - Si utilizza quando si vuole concentrare la probabilità vicino ad un valore dato μ (anche 0)

$$\text{Laplace}(x; \mu, b) = \frac{1}{2b} \exp \left(-\frac{|x - \mu|}{b} \right)$$




Principali distribuzioni di probabilità

- Distribuzione empirica
 - Rappresenta la distribuzione di una variabile continua di cui si osservano m campioni che sono ovviamente equiprobabili

$$\hat{p}(x) = \frac{1}{m} \sum_{i=1}^m \delta(x - x^{(i)})$$

Principali distribuzioni di probabilità

- Distribuzione gaussiana
o «Normale»




$$\mathcal{N}(x; \mu, \sigma^2) = \sqrt{\frac{1}{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right)$$

Principali distribuzioni di probabilità

- Distribuzione gaussiana
o «Normale» multivariata

$\mathbf{x} \in \mathbb{R}^n$




$$\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \sqrt{\frac{1}{(2\pi)^n \det(\boldsymbol{\Sigma})}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$


$\boldsymbol{\Sigma}$ è la matrice di covarianza di $\mathbf{x}$

Σ in azione


$$\mu = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \quad \Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$



$$\mu = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \quad \Sigma = \begin{bmatrix} 1 & -0.5 \\ -0.5 & 1 \end{bmatrix}$$



$$\mu = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \quad \Sigma = \begin{bmatrix} 1 & -0.8 \\ -0.8 & 1 \end{bmatrix}$$



Mixture di distribuzioni

- Rappresentazione di una distribuzione di probabilità complessa e non nota attraverso un insieme di più *distribuzioni componenti*

$$P(\mathbf{x}) = \sum_i P(c = i) P(\mathbf{x} | c = i)$$

- $P(c)$ è la distribuzione multinoulli di appartenenza all' i -esima distribuzione componente
- c : *variabile latente* $\rightarrow$ una variabile randomica correlata al processo e non direttamente osservabile
- Mistura di gaussiane: *approssimatore universale* di distribuzioni

Cenni di teoria dell'informazione

- Intuitivamente il contenuto informativo di un evento raro è maggiore del contenuto informativo di un evento altamente probabile
- Due eventi indipendenti hanno informazione che si somma

$$I(x = x) = -\log P(x)$$

- $\log_2 \rightarrow \textit{bit}$ $\log_e \rightarrow \textit{nat}$

Cenni di teoria dell'informazione

- Entropia di Shannon
 - Misura l'informazione per un'intera distribuzione come valore atteso su di essa

$$H(\mathbf{x}) = \mathbb{E}_{\mathbf{x} \sim P} [I(x)] = -\mathbb{E}_{\mathbf{x} \sim P} [\log P(x)] \triangleq H(P)$$

Cenni di teoria dell'informazione

- Divergenza di Kullback-Leibler
 - Quanto due distribuzioni $P(x)$ e $Q(x)$ sono dissimili → *non è una distanza!*

$$D_{KL}(P \parallel Q) = \mathbb{E}_{x \sim P} \left[\log \frac{P(x)}{Q(x)} \right] =$$

$$\mathbb{E}_{x \sim P} [\log P(x) - \log Q(x)]$$

$$D_{KL}(P \parallel Q) \neq D_{KL}(Q \parallel P)$$

Cenni di teoria dell'informazione

- Cross-entropia
 - Misura l'entropia mutua di P e Q
 - Ha un significato analogo alla D_{KL}

$$\begin{aligned} H(P, Q) &= H(P) + D_{KL}(P \parallel Q) = -\mathbb{E}_{x \sim P} [\log Q(x)] \\ &= -\sum_{x \sim P} P(x) \log Q(x) \end{aligned}$$

Cenni di teoria dell'informazione

- Mutua Informazione

- Date due variabili aleatorie X e Y in qualche modo correlate, aventi distribuzioni rispettivamente P_X e P_Y , la MI misura l'ammontare di informazione che ottengo su una variabile se osservo l'altra
- Si definisce come la D_{KL} tra la distribuzione congiunta ed il prodotto delle due distribuzioni nel senso dell'indipendenza statistica

$$MI(X, Y) = D_{KL}(P_{X,Y} \parallel P_X \otimes P_Y)$$