



**Università
degli Studi
di Palermo**



Clustering

CORSO DI BIG DATA – MODULO MACHINE LEARNING PER I BIG DATA
a.a. 2025/2026

Prof. Roberto Pirrone



Sommario

- Generalità
- Feature selection
- Clustering basato su prototipi rappresentativi
- Clustering gerarchico
- Clustering probabilistico
- Clustering per densità
- Misure di bontà del clustering

Generalità

- Il clustering è il processo di partizionamento di un data set in modo che ogni partizione (o *cluster*) contenga dati molto simili tra loro che rispetto agli appartenenti ad altre partizioni
- Rappresenta una classe di algoritmi di apprendimento non supervisionati che sono i più utilizzati nel *data mining*
 - Data summarization
 - Customer segmentation, collaborative filtering
 - Social network analysis
 - ...

Feature selection

- In generale non tutte le feature presenti in un campione sono rilevanti per il compito di clustering e, anzi, possono introdurre una certa «rumorosità» nei dati se prese in considerazione
- È necessario impiegare dei modelli di feature selection che cercano di individuare la «tendenza al clustering» di certi sottoinsiemi di feature

Feature selection

- Modelli basati su filtro: viene valutata la tendenza di una feature o di un gruppo di feature a contribuire al clustering utilizzando uno score numerico
- Modelli «wrapper»: approcci iterativi di clustering per tentativi su sottoinsiemi di feature
 - Computazionalmente onerosi, ma possono fornire una base per la scelta del miglior algoritmo di clustering per il problema sotto esame

Feature selection

- Modelli basati su filtro

$$\text{Term Strength} = P(t \in \bar{Y} | t \in \bar{X})$$

- Usata per analisi di dati testuali
- Viene calcolata come la frazione delle coppie di documenti in cui occorre un certo termine t , posto che t occorra nel primo dei due
- Determina «termini rilevanti» rispetto al data set

Feature selection

- Modelli basati su filtro

$$\text{Term Strength} = P(t \in \bar{Y} | t \in \bar{X})$$

- È una *similarità* che può essere estesa a dati multidimensionali rappresentati come vettori binari di attributi presenti/assenti
- Analogamente si possono usare misure di rilevanza rispetto a dati quantitativi confrontando la distanza tra singoli attributi di due campioni rispetto alla distanza complessiva dei due campioni

$$\frac{d(\mathbf{x}_j^{(i)} - \mathbf{x}_j^{(k)})}{d(\mathbf{x}^{(i)} - \mathbf{x}^{(k)})}$$

Feature selection

- Modelli basati su filtro
 - Dipendenza predittiva da un attributo
 - Assunto: gli attributi rilevanti per il clustering sono correlati
 - Come fare a trovare gli attributi rilevanti?

Feature selection

- Modelli basati su filtro
 - Dipendenza predittiva da un attributo
 - *Idea*: eseguo una classificazione/regressione (a seconda del tipo di attributo) rispetto alla i -esima feature che funge da classe del campione
 - Spesso si usa la classificazione nearest neighbor
 - La misura di accuratezza della classificazione rispetto all'attributo i sarà la misura di rilevanza utilizzata per la feature selection

Feature selection

- Modelli basati su filtro
 - Entropia
 - I dati raggruppati in un cluster hanno entropia più bassa che quelli distribuiti uniformemente nello spazio di variazione
 - Affronteremo il problema di stabilire qual'è il subset delle k feature più rilevanti per clusterizzare i nostri campioni

Feature selection

- Modelli basati su filtro
 - Entropia
 - Discretizziamo i valori di ognuna delle k feature in ϕ intervalli
 - Otteniamo una griglia multidimensionale discreta composta da $m = \phi^k$ regioni

Feature selection


- Modelli basati su filtro
 - Entropia
 - Contiamo il numero di punti che cadono in ogni regione e, se p_i è la frazione di punti che cade nella regione i -esima, si ha:

$$E = - \sum_{i=1}^m [p_i \log(p_i) + (1 - p_i) \log(1 - p_i)]$$


- Problemi di sparsità per elevate dimensioni

Feature selection


- Modelli basati su filtro
 - Entropia
 - *Le distanze 1-D tra le feature clusterizzano*
 - Entropia minore di quelle di punti non clusterizzati




(a) Uniform Data



(b) Clustered data



(c) Distance distribution (uniform)



(d) Distance distribution (clustered)

Feature selection

- Modelli basati su filtro
 - Entropia
 - Si calcolano le «distanze punto a punto» tra i campioni lungo ogni feature e, se m sono gli intervalli di discretizzazione dei valori di distanza, si ha:

$$E = - \sum_{i=1}^m [p_i \log(p_i) + (1 - p_i) \log(1 - p_i)]$$

$$p_i = \frac{N_{d_i}}{N_d}, \quad d_i \in \text{i-th interval}, \quad i = 1, 2, \dots, m$$

Feature selection

- Modelli basati su filtro
 - Entropia
 - Si scelgono le feature con entropia minore
 - Approccio greedy: si eliminano le feature che portano via via alla maggiore diminuzione di E



Università
degli Studi
di Palermo



Feature selection

- Modelli basati su filtro
 - Hopkins Statistic
 - Si generi un campione $R = \{r_1, \dots, r_r\} \subset \mathcal{D}$
 - Si generi un campione sintetico $S = \{s_1, \dots, s_r\} \subset \mathbb{R}^d$, lo spazio dei dati
 - Siano $\alpha_i = \min_{\mathbf{x}} \text{Dist}(r_i, \mathbf{x})$ e $\beta_i = \min_{\mathbf{x}} \text{Dist}(s_i, \mathbf{x})$ $i = 1, \dots, r$ e $\mathbf{x} \in \mathcal{D} - R$

Feature selection

- Modelli basati su filtro

- Hopkins Statistic

$$H = \frac{\sum_{i=1}^r \beta_i}{\sum_{i=1}^r (\alpha_i + \beta_i)}$$

- $H \rightarrow 0.5$ per dati distribuiti uniformemente (α_i e β_i sono simili)
 - $H \rightarrow 1$ per dati clusterizzati ($\alpha_i \ll \beta_i$)

Feature selection

- Modelli wrapper
 - Si effettua una serie di clustering su differenti sottoinsiemi di feature e si verifica di volta in volta la qualità ottenuta con una apposita *misura interna di bontà del clustering*
 - Computazionalmente oneroso
 - Necessita di un approccio greedy per la ricerca dei sottoinsiemi rilevanti nello spazio delle feature
 - Fortemente dipendente dalla scelta della misura di bontà del clustering



Università
degli Studi
di Palermo



Feature selection

- Modelli wrapper
 - Alternativamente si effettua un clustering sul sottoinsieme di feature considerate e si utilizzano «artificialmente» le etichette dei cluster ottenute come etichette di classe
 - Si utilizza un *criterio di bontà di classificazione supervisionata delle singole feature* su tali etichette per valutare indirettamente la bontà del clustering
 - Si selezionano le prime k feature con il valore migliore dell'indice di qualità di classificazione



Università
degli Studi
di Palermo



Clustering basato su prototipi rappresentativi

Algorithm *GenericRepresentative*(Database: $\mathcal{D}$, Number of Representatives: k)

begin

Initialize representative set S ;

repeat

Create clusters $(\mathcal{C}_1 \dots \mathcal{C}_k)$ by assigning each point in $\mathcal{D}$ to closest representative in S using the distance function $Dist(\cdot, \cdot)$;

Recreate set S by determining one representative $\bar{Y}_j$ for each $\mathcal{C}_j$ that minimizes $\sum_{\bar{X}_i \in \mathcal{C}_j} Dist(\bar{X}_i, \bar{Y}_j)$;

until convergence;

return $(\mathcal{C}_1 \dots \mathcal{C}_k)$;

end

Passo di assegnazione

Passo di ottimizzazione

Clustering basato su prototipi rappresentativi

- I k cluster sono in genere un iperparametro determinato dall'utente
- Si devono determinare k prototipi rappresentativi $\bar{Y}_j$ che minimizzino la funzione obiettivo

$$O = \sum_{j=1}^k \sum_{\bar{X}_i \in \mathcal{C}_j} Dist(\bar{X}_i, \bar{Y}_j)$$

- I valori degli $\bar{Y}_j$ in generale *non appartengono* al data set $\mathcal{D}$
- La scelta di diverse forme di $Dist(.,.)$ dà luogo a differenti algoritmi

Clustering basato su prototipi rappresentativi

- K-means

$$Dist(\overline{X_i}, \overline{Y_j}) = \|\overline{X_i} - \overline{Y_j}\|_2^2$$

- Si può mostrare che i valori ottimi degli $\bar{Y}_j$ sono i valori medi dei punti in ogni singolo cluster $\mathcal{C}_j$

Clustering basato su prototipi rappresentativi


- Mahalanobis K-means

$$Dist(\overline{X}_i, \overline{Y}_j) = (\overline{X}_i - \overline{Y}_j) \Sigma_j^{-1} (\overline{X}_i - \overline{Y}_j)^T$$


- La distanza di Mahalanobis è opportuna per cluster di forma (iper-)ellittica
- La covarianza locale Σ_j , calcolata sui punti del cluster $\mathcal{C}_j$:
 - fornisce una misura implicita di densità del cluster e quindi consente di gestire cluster a densità variabile
 - Consente la gestione di cluster con forme (iper-)ellittiche variabili

Clustering basato su prototipi rappresentativi

- *E quando la forma non è più una sfera o un'ellissoide?*



(a) Varying cluster shape
(Bad for k -means)



(b) Varying cluster density
(Good for Mahalanobis k -means)

Clustering basato su prototipi rappresentativi

- Per la gestione di cluster di forma qualunque, il k-means ricorre al cosiddetto *kernel trick*
 - Si consideri una funzione $\Phi(.)$ che mappa un vettore in uno spazio a più alta dimensionalità
 - Si definisce «kernel» una qualunque funzione tale che:

$$K(\overline{X_i}, \overline{X_j}) = \Phi(\overline{X_i}) \cdot \Phi(\overline{X_j})$$

Clustering basato su prototipi rappresentativi


- Per la gestione di cluster di forma qualunque, il k-means ricorre al cosiddetto *kernel trick*
 - L'uso del kernel è un operatore lineare nello spazio trasformato e quindi consente l'uso di algoritmi lineari nello spazio definito da $\Phi(\cdot)$
 - Il kernel $K(\cdot, \cdot)$ viene definito direttamente in termini dei vettori dello spazio di ingresso e non è *mai* necessario calcolare il mapping $\Phi(\cdot)$

$$K(\overline{X_i}, \overline{X_j}) = \Phi(\overline{X_i}) \cdot \Phi(\overline{X_j})$$

→ Uso di *euristiche* e di *algoritmi di ML dedicati* per selezionare il kernel K più adatto ad un dato compito

Clustering basato su prototipi rappresentativi

- Per la gestione di cluster di forma qualunque, il k-means ricorre al cosiddetto *kernel trick*



Clustering basato su prototipi rappresentativi

- Per la gestione di cluster di forma qualunque, il k-means ricorre al cosiddetto *kernel trick*
- La nuova funzione obiettivo, tenendo conto del mapping $\Phi(\cdot)$ è:

$$O = \sum_{j=1}^k \sum_{\bar{X}_i \in \mathcal{C}_j} \|\Phi(\bar{X}_i) - \bar{Y}_j\|_2, \quad \bar{Y}_j = \frac{\sum_{\bar{X}_l \in \mathcal{C}_j} \Phi(\bar{X}_l)}{|\mathcal{C}_j|}$$

$$O = \Phi(\bar{X}_i) \cdot \Phi(\bar{X}_i) - 2 \frac{\sum_{\bar{X}_l \in \mathcal{C}_j} \Phi(\bar{X}_i) \cdot \Phi(\bar{X}_l)}{|\mathcal{C}_j|} + \frac{\sum_{\bar{X}_l, \bar{X}_k \in \mathcal{C}_j} \Phi(\bar{X}_l) \cdot \Phi(\bar{X}_k)}{|\mathcal{C}_j|^2} =$$

$$O = K(\bar{X}_i, \bar{X}_i) - 2 \frac{\sum_{\bar{X}_l \in \mathcal{C}_j} K(\bar{X}_i, \bar{X}_l)}{|\mathcal{C}_j|} + \frac{\sum_{\bar{X}_l, \bar{X}_k \in \mathcal{C}_j} K(\bar{X}_l, \bar{X}_k)}{|\mathcal{C}_j|^2}$$

Clustering basato su prototipi rappresentativi

- K-medians

$$Dist(\overline{X_i}, \overline{Y_j}) = \|\overline{X_i} - \overline{Y_j}\|_1$$

- Uso della distanza di Manhattan
- Robusto rispetto agli outlier a causa dell'uso dei mediani

Clustering basato su prototipi rappresentativi

- K-medoids
- Impone che i valori degli $\bar{Y}_j$ appartengano a $\mathcal{D}$
- Adattabile a dati eterogenei con la giusta definizione dell'appropriata misura di distanza/similarità
- Computazionalmente oneroso

Algorithm *GenericMedoids*(Database: $\mathcal{D}$, Number of Representatives: k)
begin

Initialize representative set S by selecting from $\mathcal{D}$;

repeat

Create clusters $(\mathcal{C}_1 \dots \mathcal{C}_k)$ by assigning
each point in $\mathcal{D}$ to closest representative in S
using the distance function $Dist(\cdot, \cdot)$;

Determine a pair $\bar{X}_i \in \mathcal{D}$ and $\bar{Y}_j \in S$ such that
replacing $\bar{Y}_j \in S$ with $\bar{X}_i$ leads to the
greatest possible improvement in objective function;

Perform the exchange between $\bar{X}_i$ and $\bar{Y}_j$ only
if improvement is positive;

until no improvement in current iteration;

return $(\mathcal{C}_1 \dots \mathcal{C}_k)$;

end

Clustering gerarchico

- Il clustering gerarchico crea una tassonomia di cluster che vengono aggregati attraverso il calcolo di distanze tra essi
- Il calcolo di tali distanze utilizza in genere altri approcci come quelli basati sul concetto di densità o sull'utilizzo di grafi
- Approcci
 - Agglomerativi o bottom-up
 - Divisivi o top-down

Clustering gerarchico

- Approcci agglomerativi

```
Algorithm AgglomerativeMerge(Data:  $\mathcal{D}$ )  
begin  
  Initialize  $n \times n$  distance matrix  $M$  using  $\mathcal{D}$ ;  
  repeat  
    Pick closest pair of clusters  $i$  and  $j$  using  $M$ ;  
    Merge clusters  $i$  and  $j$ ;  
    Delete rows/columns  $i$  and  $j$  from  $M$  and create  
      a new row and column for newly merged cluster;  
    Update the entries of new row and column of  $M$ ;  
  until termination criterion;  
  return current merged cluster set;  
end
```


M è la struttura dati su cui lavorano tutti gli algoritmi gerarchici

Due approcci:

1. Soglia massima sulla distanza tra due cluster da fondere
2. Soglia minima sul numero di cluster

Clustering gerarchico

- Approcci agglomerativi
 - Il calcolo delle distanze tra i cluster avviene incrementalmente via via che si aggiorna M
 - In generale i cluster i e j contengono rispettivamente m_i e m_j *elementi* e necessitano di calcolare $m_i \times m_j$ distanze



(a) Dendrogram

Quale sarà la distanza tra i due cluster?

Si utilizzano delle statistiche per stimare la similarità tra gruppi di oggetti

Clustering gerarchico

- Stime di distanza per approcci agglomerativi, dopo aver fuso i cluster i e j
 - Single linkage – la distanza è la minima tra le $m_i \times m_j$ distanze possibili
 - Per ogni cluster $k \neq i, j$ si considerano $\min\{M_{ik}, M_{jk}\}$ per le righe e $\min\{M_{ki}, M_{kj}\}$ per le colonne di M
 - Complete linkage – la distanza è la massima tra le $m_i \times m_j$ distanze possibili
 - Per ogni cluster $k \neq i, j$ si considerano $\max\{M_{ik}, M_{jk}\}$ per le righe e $\max\{M_{ki}, M_{kj}\}$ per le colonne di M



Clustering gerarchico

- Stime di distanza per approcci agglomerativi, dopo aver fuso i cluster i e j
 - Group-average linkage – la distanza è la media tra le $m_i \times m_j$ distanze possibili
 - Per ogni cluster $k \neq i, j$ si considerano $(m_i M_{ik} + m_j M_{jk}) / (m_i + m_j)$ per le righe e $(m_i M_{ki} + m_j M_{kj}) / (m_i + m_j)$ per le colonne di M
 - Centroidi più vicini – si fondono i cluster con i centroidi più vicini



Università
degli Studi
di Palermo



dipartimento
di ingegneria
unipa



Clustering gerarchico

- Approcci agglomerativi – varianza dei cluster
 - Si cerca di effettuare il merge quando la variazione della funzione obiettivo è la minima possibile per preservare le proprietà statistiche dell'agglomerato

$$SE_i = \sum_{r=1}^d \left(S_{ir}/m_i - F_{ir}^2/m_i^2 \right)$$

$$S_{ir} = \sum_{\mathbf{x} \in \mathcal{C}_i} \mathbf{x}_r^2 \quad \text{Momento del II ordine di } \mathcal{C}_i \text{ sulla dimensione } r$$


$$F_{ir} = \sum_{\mathbf{x} \in \mathcal{C}_i} \mathbf{x}_r \quad \text{Momento del I ordine di } \mathcal{C}_i \text{ sulla dimensione } r$$

$$\text{Var} = \mathbb{E}[\mathbf{x}^2] - \mathbb{E}[\mathbf{x}]^2$$




Clustering gerarchico

- Approcci agglomerativi: limiti del clustering



(a) Good case with no noise



(b) Bad case with noise

Clustering gerarchico

- Approcci divisivi
 - $\mathcal{A}$ può essere un algoritmo di clustering qualunque
 - Bisecting k-means: esegue un 2-means ad ogni iterazione
 - La scelta del nodo L può essere dettata da diversi criteri
 - Il nodo più vicino alla radice

Algorithm *GenericTopDownClustering*(Data: $\mathcal{D}$, Flat Algorithm: $\mathcal{A}$)
begin
 Initialize tree $\mathcal{T}$ to root containing $\mathcal{D}$;
 repeat
 Select a leaf node L in $\mathcal{T}$ based on pre-defined criterion;
 Use algorithm $\mathcal{A}$ to split L into $L_1 \dots L_k$;
 Add $L_1 \dots L_k$ as children of L in $\mathcal{T}$;
 until termination criterion;
end

Clustering probabilistico

- *Soft Clustering*: ogni punto ha una probabilità anche piccola, ma diversa da 0, di appartenere ad *ogni* cluster
- Considereremo un *modello generativo* $\mathcal{M}$ che descrive la probabilità p_{data} di generare un punto appartenente ad un dato cluster
- Si assuma che p_{data} sia una mistura di distribuzioni $\mathcal{G}_i$, che saranno i nostri cluster, con un insieme di prior $\alpha_i = P(\mathcal{G}_i)$

Clustering probabilistico

- Sia $f^i(.)$ la forma funzionale di ogni $\mathcal{G}_i$
- La generazione di un punto dato il nostro modello è descritta da

$$f^{point}(\overline{X}_j | \mathcal{M}) = \sum_{i=1}^k \alpha_i \cdot f^i(\overline{X}_j)$$

Clustering probabilistico

- Per l'intero data set si ha

$$f^{data}(\mathcal{D}|\mathcal{M}) = \prod_{j=1}^n f^{point}(\overline{X}_j|\mathcal{M})$$

Ipotesi i.i.d.

- Il clustering si ottiene massimizzando la log-likelihood di $f^{data}(\mathcal{D}|\mathcal{M})$

$$\mathcal{L}(\mathcal{D}|\mathcal{M}) = \log \left(\prod_{j=1}^n f^{point}(\overline{X}_j|\mathcal{M}) \right) = \sum_{j=1}^n \log \left(\sum_{i=1}^k \alpha_i f^i(\overline{X}_j) \right)$$

Clustering probabilistico

- La massimizzazione della likelihood si ottiene con un approccio iterativo a due passi detto *Expectation Maximization (EM)* che ci consente di stimare l'insieme $\mathbf{w}$ di tutti i parametri della mistura ed i prior α_i
- Usiamo lo schema del Teorema di Bayes

$$P(\mathbf{w}|\mathcal{D}) = \frac{P(\mathcal{D}|\mathbf{w})P(\mathbf{w})}{P(\mathcal{D})}$$

Clustering probabilistico

- Expectation Maximization

$$P(\mathbf{w}|\mathcal{D}) = \frac{P(\mathcal{D}|\mathbf{w})P(\mathbf{w})}{P(\mathcal{D})}$$

- Expectation: si effettua una stima di $P(\mathbf{w}|\mathcal{D})$ delle predizioni del modello fissati i parametri $\mathbf{w}$
- Maximization: si effettua uno step di massimizzazione di $P(\mathcal{D}|\mathbf{w})$ per calcolare il nuovo vettore dei parametri $\mathbf{w}$

Clustering probabilistico

- Applichiamo l'algoritmo EM al nostro modello
- Expectation - stima di $P(\mathcal{G}_i | X_j, \mathbf{w})$
 - Si stima col teorema di Bayes la probabilità a posteriori che un certo punto sia stato generato da una componente $\mathcal{G}_i$ della mistura, dato $\mathbf{w}$

$$P(\mathcal{G}_i | \overline{X}_j, \mathbf{w}) = \frac{P(\mathcal{G}_i) \cdot P(\overline{X}_j | \mathcal{G}_i, \mathbf{w})}{\sum_{r=1}^k P(\mathcal{G}_r) \cdot P(\overline{X}_j | \mathcal{G}_r, \mathbf{w})} = \frac{\alpha_i \cdot f^{i, \mathbf{w}}(\overline{X}_j)}{\sum_{r=1}^k \alpha_r \cdot f^{r, \mathbf{w}}(\overline{X}_j)}$$

Clustering probabilistico

- Applichiamo l'algoritmo EM al nostro modello
- Maximization – nuova stima dei parametri α_i e Θ
 - Note le probabilità *stimate* di assegnazione di ciascun punto ad ogni cluster si ottengono i nuovi valori dei parametri α_i :

$$\alpha_i = P(\mathcal{G}_i) = \frac{\sum_{j=1}^n P(\mathcal{G}_i | \overline{X}_j, \mathbf{w})}{n} \quad \text{ovvero} \quad \alpha_i = \frac{1 + \sum_{j=1}^n P(\mathcal{G}_i | \overline{X}_j, \mathbf{w})}{k + n}$$

- Si aggiorna $\mathbf{w}$ massimizzando la log-likelihood: $\partial \mathcal{L}(\mathcal{D} | \mathcal{M}) / \partial \mathbf{w} = 0$

Clustering probabilistico

- Si consideri una mistura di gaussiane in d dimensioni:

$$f^{i,\mathbf{w}}(\overline{X_j}) = \frac{1}{\sqrt{|\Sigma_i|}(2 \cdot \pi)^{(d/2)}} e^{-\frac{1}{2}(\overline{X_j} - \overline{\mu_i})\Sigma_i^{-1}(\overline{X_j} - \overline{\mu_i})}$$

- Si può mostrare che il passo di expectation in questo caso pesa i cluster in modo da assegnare i punti ai cluster *esattamente* come il Mahalanobis K-means

Clustering probabilistico

- Nel caso particolare in cui $\alpha_i = 1/k$ e tutte le componenti hanno deviazione standard uguale a σ :

$$f^{j,w}(\bar{X}_i) = \frac{1}{(\sigma\sqrt{2 \cdot \pi})^d} e^{-\left(\frac{\|\bar{X}_i - \bar{Y}_j\|^2}{2\sigma^2}\right)}$$

- I parametri sono σ e i vettori $\bar{Y}_j$ e si ottiene il k-means classico
- In generale la forma della mistura $K_1 \cdot e^{-K_2 \cdot \text{Dist}(\bar{X}_i, \bar{Y}_j)}$ consente di usare EM per implementare tutti i clustering basati su prototipi rappresentativi

Clustering per densità


- In questi approcci si cerca di creare i cluster come componenti connesse di un grafo costituito da elementi strutturali che sono caratterizzati dal possedere un parametro di *densità* sopra una certa soglia
- Approcci *density based* propriamente detti: gli elementi strutturali sono punti il cui intorno contiene un numero di punti maggiore di una certa soglia

Clustering per densità

- In questi approcci si cerca di creare i cluster come componenti connesse di un grafo costituito da elementi strutturali che sono caratterizzati dal possedere un parametro di *densità* sopra una certa soglia
- Approcci *grid-based*: gli elementi strutturali sono ipercubi di una griglia che suddivide lo spazio dei dati: un ipercubo sarà «denso» se contiene un numero di punti maggiore di una certa soglia

Clustering per densità

- Algoritmi density based – DBSCAN
 - DBSCAN si basa sulla definizione di tre tipologie di punti nel data set
 - Core points: punti che nel loro intorno di dato raggio Eps contengono almeno τ punti
 - Border points: punti che contengono meno di τ punti nel loro intorno, ma contengono un core point
 - Noise points: punti che nel loro intorno contengono meno di τ punti e non contengono core point



Clustering per densità

- Algoritmi density based – DBSCAN

Algorithm *DBSCAN*(Data: $\mathcal{D}$, Radius: Eps , Density: τ)

begin

Determine core, border and noise points of $\mathcal{D}$ at level (Eps, τ) ;

Create graph in which core points are connected
if they are within Eps of one another;

Determine connected components in graph;

Assign each border point to connected component
with which it is best connected;

return points in each connected component as a cluster;

end

*Si devono calcolare le
distanze tra tutte le
coppie di punti!!*

Clustering per densità

- Algoritmi density based – DBSCAN
 - Il passo di determinazione del grafo dei core points è un approccio single linkage con distanza Eps
 - La ricerca dei core points è un problema $O(n^2)$ che può essere ridotto a $O(n \log n)$ con l'utilizzo di apposite strutture di indicizzazione
 - *Problemi legati all'elevata dimensionalità poiché tali strutture richiedono calcoli di distanze tra i punti che sono onerose e poco significative per elevati valori di d*

Clustering per densità

- Algoritmi density based – DBSCAN
 - Il fatto che τ (denominata in genere *MinPts* nella letteratura di settore) sia fissato comporta problemi nella gestione di cluster a densità variabile
 - *Eps* e τ sono in relazione tra loro: *Eps* può essere determinato come valore di cutoff della distanza di ogni punto dai suoi τ nearest neighbors

Clustering per densità



Università
degli Studi
di Palermo



dipartimento
di ingegneria
unipa



Clustering per densità

- Algoritmi grid based

Algorithm *GenericGrid*(Data: $\mathcal{D}$, Ranges: p , Density: τ)

begin

Discretize each dimension of data $\mathcal{D}$ into p ranges;

Determine dense grid cells at density level τ ;

Create graph in which dense grids are connected if they are adjacent;


Determine connected components of graph;

return points in each connected component as a cluster;


end

Otterremo p^d celle!!

Le distanze non servono più: si calcolano i confronti con le posizioni discretizzate delle celle!!



(a) Data points and grid



(b) Agglomerating adjacent grids

Clustering per densità


- Algoritmi grid based
 - Il clustering dipende dal numero delle celle p lungo le dimensioni della griglia e dal parametro di densità $MinPts$
 - Celle troppo grandi (p piccolo) possono contenere punti di diversi cluster, mentre celle troppo piccole danno luogo a un numero elevato di celle vuote
 - Un valore di $MinPts$ troppo basso fa collassare più celle in un cluster, mentre al contrario tende a spezzare i cluster
 - *Problemi ad elevata dimensionalità perché il numero delle celle cresce esponenzialmente con d*

Clustering per densità

- Algoritmi grid based
 - È possibile legare la dimensione della cella a al valore di Eps , a parità di scelta di $MinPts$, per ottenere forme dei cluster simili a quelle di DBSCAN
 - Assumiamo che i dati si trovino all'interno di un ipercubo unitario:

$$\frac{1}{p} \propto \frac{Eps}{\sqrt{2}}$$

Otteniamo un'adiacenza tra celle dense che raggruppa i punti in modo molto simile agli intorno dei core point



Misure di bontà del clustering

- Il clustering è una procedura non supervisionata e quindi non ci fornisce, in principio, informazioni utili alla validazione della bontà del task effettuato
- Si determinano comunque due tipologie di criteri
 - Criteri interni, basati sui dati
 - Criteri esterni, quando delle etichette di classe sono comunque disponibili per verificare se il clustering ha seguito il criterio di classificazione

Misure di bontà del clustering

- Criteri di validazione interni
 - Within Cluster Sum of Squares (WCSS)

$$WCSS = \sum_{j=1}^K \sum_{\bar{X}_i \in \mathcal{C}_j} (\bar{X}_i - \bar{Y}_j)^2$$

- Pensata principalmente per il k-means e per gli algoritmi basati su distanze e cluster di forma sferica
- Tende comunque a diminuire all'aumentare del numero di cluster

Misure di bontà del clustering

- Criteri di validazione interni

- Rapporto delle distanze Intra-cluster/inter-cluster

$$Intra = \sum_{(\bar{X}_i, \bar{X}_j) \in P} \text{dist}(\bar{X}_i, \bar{X}_j) / |P|$$

- Campioniamo r punti da $\mathcal{D}$ di cui P appartengono ad un certo cluster e i rimanenti Q no

$$Inter = \sum_{(\bar{X}_i, \bar{X}_j) \in Q} \text{dist}(\bar{X}_i, \bar{X}_j) / |Q|$$

- Il clustering è migliore quanto più $Intra/Inter$ è basso



Università
degli Studi
di Palermo



dipartimento
di ingegneria
unipa



Misure di bontà del clustering

- Criteri di validazione interni
 - Silhouette coefficient

$Davg_i^{in} = \text{avg} \left(\text{Dist} \left(\overline{X}_k, \overline{X}_l \right) \right), \overline{X}_k, \overline{X}_l \in \mathcal{C}_i$ Distanza media tra i punti del cluster i

$Dmin_i^{out} = \min_{\mathcal{C}_m} \text{avg} \left(\text{Dist} \left(\overline{X}_k, \overline{X}_h \right) \right), \overline{X}_k \in \mathcal{C}_i, \overline{X}_h \in \mathcal{C}_m$ Minimo tra le distanze medie degli altri cluster dal cluster i

Misure di bontà del clustering

- Criteri di validazione interni
 - Silhouette coefficient

$$S_i = \frac{Dmin_i^{out} - Davg_i^{in}}{\max \{ Dmin_i^{out}, Davg_i^{in} \}}$$

$$S = \frac{1}{n} \sum_i S_i$$

- S varia in $[-1, 1]$: valori grandi positivi indicano buona separazione tra i cluster, mentre valori negativi indicano mescolamento

Misure di bontà del clustering


- Criteri di validazione interni
 - Misure probabilistiche
 - Si assume che i dati siano descritti da una mistura di distribuzioni i cui centri delle componenti sono i centri dei cluster che sono stati trovati dall'algoritmo
 - Si utilizza solo il passo di massimizzazione dell'approccio *EM* calcolando i parametri rimanenti (le covarianze ad es.) tramite massimizzazione della log-likelihood della mistura

Misure di bontà del clustering

- Criteri di validazione interni
 - Misure probabilistiche
 - Il nuovo modello generativo viene usato per predire i dati da clusterizzare
 - La significatività della misura dipende strettamente dalla forma effettiva dei cluster ovvero la misura ha significato se si hanno delle informazioni a priori su come dovrebbe essere il clustering

Misure di bontà del clustering

- Criteri di validazione interni
 - Possono essere utilizzati anche per effettuare il tuning dei parametri e cioè stabilire il numero di cluster
 - Elbow method: sia *WCSS* sia *Intra/Inter* decrescono rapidamente fino al numero ottimale di cluster e poi si crea un plateau



Misure di bontà del clustering

- Criteri di validazione interni
 - Tutti questi criteri sottendono ciascuno un modello particolare di cluster che potrebbe non essere quello reale
 - Questo rende difficile anche il paragone tra i diversi criteri usati per testare la bontà di un dato algoritmo

Misure di bontà del clustering

- Criteri di validazione esterni
 - Si utilizzano le etichette di cluster, ove disponibili, da usare come etichette di classe
 - Disponibilità di benchmark data set
 - Oppure dati reali con etichette di classe che dipendono dall'applicazione di classificazione e potrebbero non riflettere le caratteristiche dei cluster naturali dei dati

Misure di bontà del clustering

- Criteri di validazione esterni
 - Siano k_t le etichette di classe e k_d il numero di cluster determinati dall'algoritmo
 - Se $k_t = k_d$ si può utilizzare la *matrice di confusione*

		Valori predetti			
Valori reali	Cluster Indices	1	2	3	4
	1	97	0	2	1
	2	5	191	1	3
	3	4	3	87	6
	4	0	0	5	195

		1	2	3	4
1	Cluster Indices	33	30	17	20
2		51	101	24	24
3		24	23	31	22
4		46	40	44	70



Misure di bontà del clustering

- Criteri di validazione esterni
 - In generale si usano degli indici numerici
 - Sia m_{ij} il numero di punti della classe i mappati nel cluster j , cioè l'elemento (i,j) della matrice di confusione

$$N_i = \sum_{j=1}^{k_d} m_{ij}, \quad \forall i = 1 \dots k_t$$

Somma dei valori lungo una riga:
l'effettivo numero di punti
appartenenti alla classe i

$$M_j = \sum_{i=1}^{k_t} m_{ij}, \quad \forall j = 1 \dots k_d$$

Somma dei valori lungo una colonna:
il numero di punti predetti
come appartenenti al cluster j

Misure di bontà del clustering

- Criteri di validazione esterni
 - Purity: si assume che un buon cluster avrà quanti più possibili punti appartenenti tutti ad una stessa classe

$$\text{Purity} = \frac{\sum_{j=1}^{k_d} P_j}{\sum_{j=1}^{k_d} M_j}, \quad P_j = \max_i m_{ij}$$

Numero di punti predetti nella classe dominante

- La Purity tende a 1 per un buon clustering

Misure di bontà del clustering

- Criteri di validazione esterni

- Gini index: considera il contributo anche delle altre classi presenti nel cluster
- È un buon cluster quello in cui i punti sono concentrati in poche classi e c'è poca dispersione
- G_j tende a 0 per un buon clustering, mentre ha $1 - 1/k_t$ come limite superiore

$$G_j = 1 - \sum_{i=1}^{k_t} \left(\frac{m_{ij}}{M_j} \right)^2$$

% punti di
classe i
predetti
nel cluster j

$$G_{average} = \frac{\sum_{j=1}^{k_d} G_j \cdot M_j}{\sum_{j=1}^{k_d} M_j}$$

Misure di bontà del clustering

- Criteri di validazione esterni
 - Entropia: l'indice di Gini G_j è legato all'entropia E_j del cluster j poiché m_{ij}/M_j è la probabilità frequentista che un punto di classe i appartenga a tale cluster

$$E_j = - \sum_{i=1}^{k_t} \left(\frac{m_{ij}}{M_j} \right) \cdot \log \left(\frac{m_{ij}}{M_j} \right)$$

$$E_{\text{average}} = \frac{\sum_{j=1}^{k_d} E_j \cdot M_j}{\sum_{j=1}^{k_d} M_j}$$

Misure di bontà del clustering

- Criteri di validazione esterni
 - È possibile infine stabilire una misura di bontà del clustering analizzando la matrice di confusione con le misure tipiche della classificazione: Precision, Recall e F_1 -score (che vedremo più avanti)