



Clustering

CORSO DI BIG DATA – MODULO MACHINE LEARNING PER I BIG DATA

a.a. 2025/2026

Prof. Roberto Pirrone



Sommario

- Generalità
- Feature selection
- Clustering basato su prototipi rappresentativi
- Clustering gerarchico
- Clustering probabilistico
- Clustering per densità
- Misure di bontà del clustering

Generalità

- Il clustering è il processo di partizionamento di un data set in modo che ogni partizione (o *cluster*) contenga dati molto simili tra loro che rispetto agli appartenenti ad altre partizioni

- Rappresenta una classe di algoritmi di apprendimento non supervisionati che sono i più utilizzati nel *data mining*

  - Data summarization
  - Customer segmentation, collaborative filtering
  - Social network analysis
  - …

Feature selection

- In generale non tutte le feature presenti in un campione sono rilevanti per il compito di clustering e, anzi, possono introdurre una certa «rumorosità» nei dati se prese in considerazione

- È necessario impiegare dei modelli di feature selection che cercano di individuare la «tendenza al clustering» di certi sottoinsiemi di feature

Feature selection

- Modelli basati su filtro: viene valutata la tendenza di una feature o di un gruppo di feature a contribuire al clustering utilizzando uno score numerico

- Modelli «wrapper»: approcci iterativi di clustering per tentativi su sottoinsiemi di feature
  - Computazionalmemte onerosi, ma possono fornire una base per la scelta del miglior algoritmo di clustering per il problema sotto esame

Feature selection

- Modelli basati su filtro

$$\text{Term Strength } = P(t \in \bar{Y} | t \in \bar{X})$$

  - Usata per analisi di dati testuali
  - Viene calcolata come la frazione delle coppie di documenti in cui occorre un certo termine *t*, posto che *t* occorra nel primo dei due
  - Determina «termini rilevanti» rispetto al data set

Feature selection

- Modelli basati su filtro

$$\text{Term Strength} = P(t \in \bar{Y} | t \in \bar{X})$$

  - È una *similarità* che può essere estesa a dati multidimensionali rappresentati come vettori binari di attributi presenti/assenti

  - Analogamente si possono usare misure di rilevanza rispetto a dati quantitativi confrontando la *distanza tra singoli attributi di due campioni rispetto alla distanza complessiva dei due campioni*

$$\frac{d(\boldsymbol{x}_j^{(i)} - \boldsymbol{x}_j^{(k)})}{d(\boldsymbol{x}^{(i)} - \boldsymbol{x}^{(k)})}$$

Feature selection

- Modelli basati su filtro
  - Dipendenza predittiva da un attributo
  - Assunto: *gli attributi rilevanti per il clustering sono correlati*
  - Come fare a trovare gli attributi rilevanti?

Feature selection

- Modelli basati su filtro
  - Dipendenza predittiva da un attributo
  - *Idea*: eseguo una classificazione/regressione (a seconda del tipo di attributo) rispetto alla *i*-esima feature che funge da classe del campione
    - Spesso si usa la classificazione nearest neighbor
  - La misura di accuratezza della classificazione rispetto all'attributo *i* sarà la misura di rilevanza utilizzata per la feature selection

Feature selection

- Modelli basati su filtro
  - Entropia
  - I dati raggruppati in un cluster hanno entropia più bassa che quelli distribuiti uniformemente nello spazio di variazione
  - Affronteremo il problema di stabilire qual'è il subset delle *k* feature più rilevanti per clusterizzare i nostri campioni

Feature selection

- Modelli basati su filtro
  - Entropia
  - Discretizziamo i valori di ognuna delle *k* feature in ϕ intervalli
  - Otteniamo una griglia multidimensionale discreta composta da m = ϕ^k regioni

Feature selection

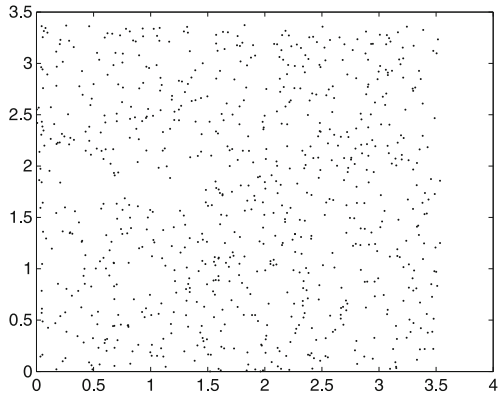
- Modelli basati su filtro
  - Entropia
  - Contiamo il numero di punti che cadono in ogni regione e, se p_i è la frazione di punti che cade nella regione *i*-esima, si ha:

$$E = -\sum_{i=1}^{m} [p_i \log(p_i) + (1 - p_i) \log(1 - p_i)$$

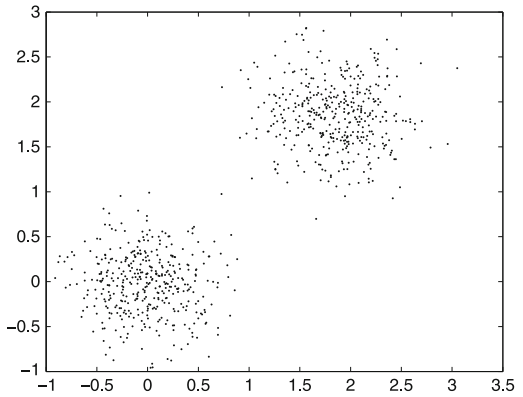
  - Problemi di sparsità per elevate dimensioni

Feature selection

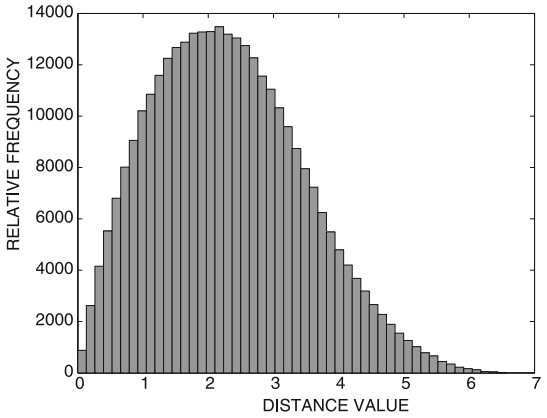
- Modelli basati su filtro
  - Entropia
  - *Le distanze 1-D tra le feature clusterizzano*
  - Entropia minore di quelle di punti non clusterizzati



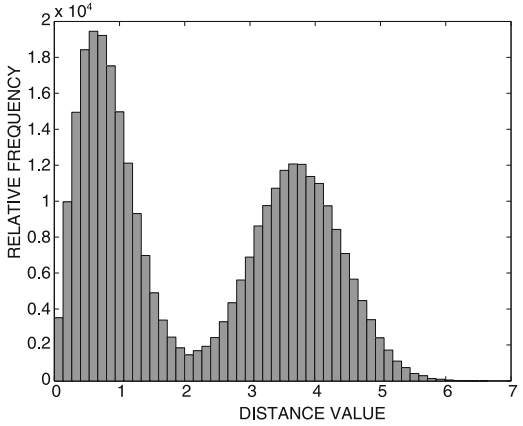
(a) Uniform Data



(b) Clustered data



(c) Distance distribution (uniform)



(d) Distance distribution (clustered)

Università degli Studi di Palermo

dipartimento di ingegneria unipa

CHILAB

Feature selection

- Modelli basati su filtro
  - Entropia
  - Si calcolano le «distanze punto a punto» tra i campioni lungo ogni feature e, se *m* sono gli intervalli di discretizzazione dei valori di distanza, si ha:

$$E = -\sum_{i=1}^{m} \left[p_i \log\left(p_i\right) + \left(1 - p_i\right) \log\left(1 - p_i\right) \right.$$

$$p_i = \frac{N_{d_i}}{N_d}, \; d_i \in \text{i-th interval}, \; i = 1, 2, \ldots, m$$

Feature selection

- Modelli basati su filtro
  - Entropia
  - Si scelgono le feature con entropia minore
  - Approccio greedy: si eliminano le feature che portano via via alla maggiore diminuzione di *E*

Feature selection

- Modelli basati su filtro
  - Hopkins Statistic
  - Si generi un campione $R = \{r_1, \ldots, r_r\} \subset \mathcal{D}$
  - Si generi un campione sintetico $S = \{s_1, \ldots, s_r\} \subset \mathbb{R}^d$, lo spazio dei dati
  - Siano $\alpha_i = \min_{\boldsymbol{x}} \text{Dist}(r_i, \boldsymbol{x})$ e $\beta_i = \min_{\boldsymbol{x}} \text{Dist}(s_i, \boldsymbol{x})$ $i = 1, \ldots, r$ e $\boldsymbol{x} \in \mathcal{D} - R$

Feature selection

- Modelli basati su filtro
  - Hopkins Statistic

$$H = \frac{\sum_{i=1}^{r} \beta_i}{\sum_{i=1}^{r} (\alpha_i + \beta_i)}$$

  - H → 0.5 per dati distribuiti uniformemente (α_i e β_i sono simili)
  - H → 1 per dati clusterizzati ($\alpha_i << \beta_i$)

Feature selection

- Modelli wrapper
  - Si effettua una serie di clustering su differenti sottoinsiemi di feature e si verifica di volta in volta la qualità ottenuta con una apposita *misura interna di bontà del clustering*
  - Computazionalmente oneroso
    - Necessita di un approccio greedy per la ricerca dei sottoinsiemi rilevanti nello spazio delle feature
    - Fortemente dipendente dalla scelta della misura di bontà del clustering

Feature selection

- Modelli wrapper
  - Alternativamente si effettua un clustering sul sottoinsieme di feature considerate e si utilizzano «artificialmente» le etichette dei cluster ottenute come etichette di classe
  - Si utilizza un *criterio di bontà di classificazione supervisionata delle singole feature* su tali etichette per valutare indirettamente la bontà del clustering
  - Si selezionano le prime *k* feature con il valore migliore dell'indice di qualità di classificazione

Clustering basato su prototipi rappresentativi

Algorithm *GenericRepresentative*(Database: $\mathcal{D}$, Number of Representatives: k)
begin
  Initialize representative set S;
  repeat
    Create clusters $(\mathcal{C}_1 \ldots \mathcal{C}_k)$ by assigning each point in $\mathcal{D}$ to closest representative in S using the distance function $Dist(\cdot, \cdot)$;
    Recreate set S by determining one representative $\overline{Y_j}$ for each $\mathcal{C}_j$ that minimizes $\sum_{\overline{X_i} \in \mathcal{C}_j} Dist(\overline{X_i}, \overline{Y_j})$;
  until convergence;
  return $(\mathcal{C}_1 \ldots \mathcal{C}_k)$;
end

Passo di assegnazione

Passo di ottimizzazione

Clustering basato su prototipi rappresentativi

- I *k* cluster sono in genere un iperparametro determinato dall'utente
- Si devono determinare *k* prototipi rappresentativi $\bar{Y}_j$ che minimizzino la funzione obiettivo

$$O = \sum_{j=1}^{k} \sum_{\overline{X_i} \in \mathcal{C}_j} Dist(\overline{X_i}, \overline{Y_j})$$

- I valori degli $\bar{Y}_j$ in generale *non appartengono* al data set $\mathcal{D}$
- La scelta di diverse forme di *Dist*(.,.) dà luogo a differenti algoritmi

Clustering basato su prototipi rappresentativi

- K-means

$$Dist(\overline{X_i}, \overline{Y_j}) = \|\overline{X_i} - \overline{Y_j}\|_2^2$$

- Si può mostrare che i valori ottimi degli $\bar{Y}_j$ sono i valori medi dei punti in ogni singolo cluster $\mathcal{C}_j$

Clustering basato su prototipi rappresentativi

- Mahalanobis K-means

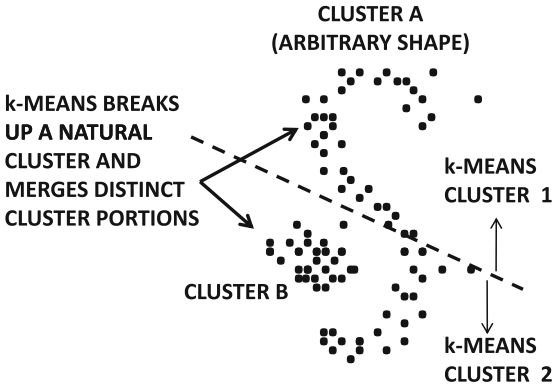
$$Dist(\overline{X_i}, \overline{Y_j}) = (\overline{X_i} - \overline{Y_j})\Sigma_j^{-1}(\overline{X_i} - \overline{Y_j})^T$$

- La distanza di Mahalanobis è opportuna per cluster di forma (iper-)ellittica

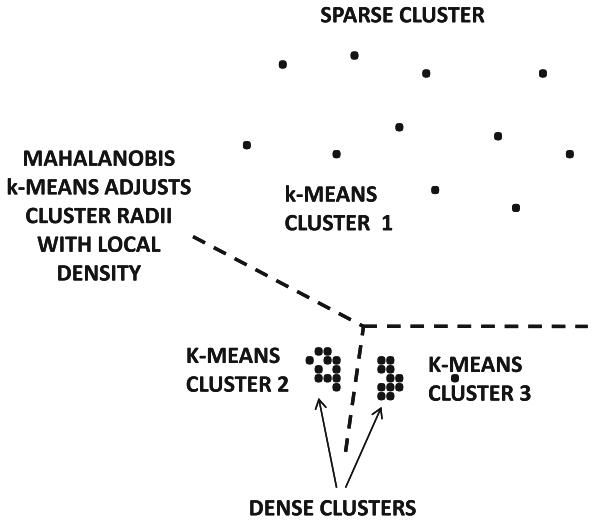
- La covarianza locale Σ_j, calcolata sui punti del cluster $\mathcal{C}_j$:
  - fornisce una misura implicita di densità del cluster e quindi consente di gestire cluster a densità variabile
  - Consente la gestione di cluster con forme (iper-)ellittiche variabili

Clustering basato su prototipi rappresentativi

- *E quando la forma non è più una sfera o un'ellissoide?*



(a) Varying cluster shape
(Bad for k-means)



(b) Varying cluster density
(Good for Mahalanobis k-means)

Clustering basato su prototipi rappresentativi

- Per la gestione di cluster di forma qualunque, il k-means ricorre al cosiddetto *kernel trick*
  - Si consideri una funzione $\Phi(.)$ che mappa un vettore in uno spazio a più alta dimensionalità
  - Si definisce «kernel» una qualunque funzione tale che:

$$K(\overline{X_i}, \overline{X_j}) = \Phi(\overline{X_i}) \cdot \Phi(\overline{X_j})$$

Clustering basato su prototipi rappresentativi

- Per la gestione di cluster di forma qualunque, il k-means ricorre al cosiddetto *kernel trick*
  - L'uso del kernel è un operatore lineare nello spazio trasformato e quindi consente l'uso di algoritmi lineari nello spazio definito da $\Phi(.)$
  - Il kernel $K(.,.)$ viene definito direttamente in termini dei vettori dello spazio di ingresso e non è *mai* necessario calcolare il mapping $\Phi(.)$

$$K(\overline{X_i}, \overline{X_j}) = \Phi(\overline{X_i}) \cdot \Phi(\overline{X_j})$$

Uso di *euristiche* e di *algoritmi di ML dedicati* per selezionare il kernel *K* più adatto ad un dato compito

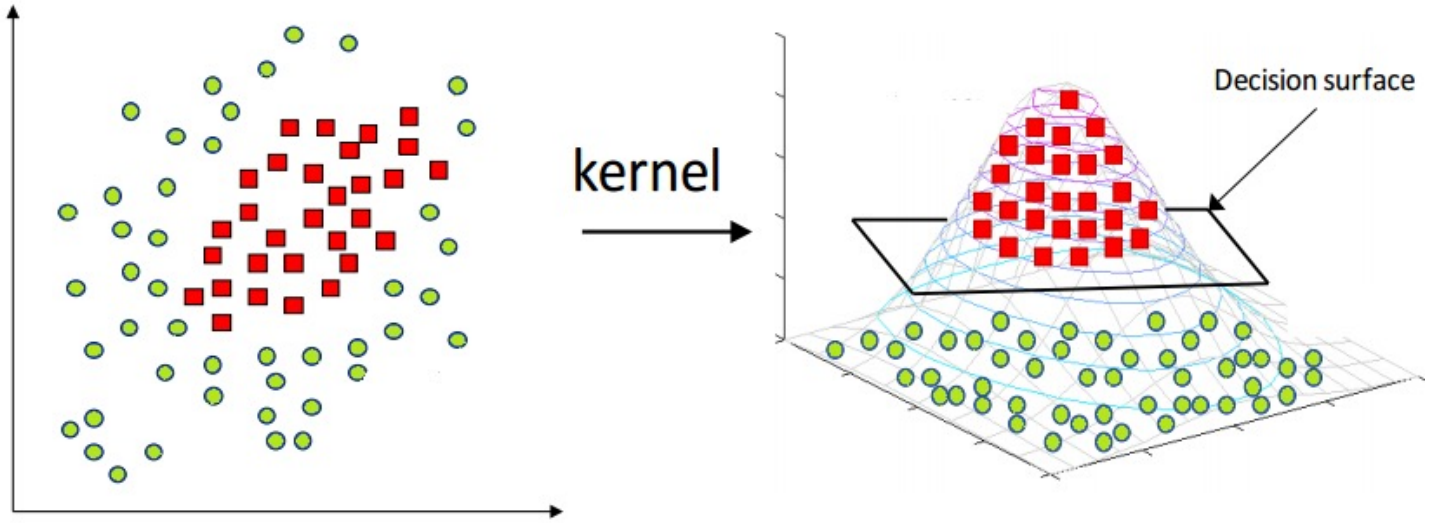
Università degli Studi di Palermo

dipartimento di ingegneria unipa

CHILAB

Clustering basato su prototipi rappresentativi

- Per la gestione di cluster di forma qualunque, il k-means ricorre al cosiddetto *kernel trick*



https://bit.ly/444lfpY

Clustering basato su prototipi rappresentativi

- Per la gestione di cluster di forma qualunque, il k-means ricorre al cosiddetto *kernel trick*
  - La nuova funzione obiettivo, tenendo conto del mapping $\Phi(.)$ è:

$$O = \sum_{j=1}^{k} \sum_{\overline{X_i} \in \mathcal{C}_j} \left|\left|\Phi\left(\overline{X_i}\right) - \overline{Y_j}\right|\right|_2, \quad \overline{Y_j} = \frac{\sum_{\overline{X_l} \in \mathcal{C}_j} \Phi\left(\overline{X_l}\right)}{|\mathcal{C}_j|}$$

$$O = \sum_{j=1}^{k} \sum_{\overline{X_i} \in \mathcal{C}_j} \Phi\left(\overline{X_i}\right) \cdot \Phi\left(\overline{X_i}\right) - 2\frac{\sum_{\overline{X_l} \in \mathcal{C}_j} \Phi\left(\overline{X_i}\right) \cdot \Phi\left(\overline{X_l}\right)}{|\mathcal{C}_j|} + \frac{\sum_{\overline{X_l}, \overline{X_k} \in \mathcal{C}_j} \Phi\left(\overline{X_l}\right) \cdot \Phi\left(\overline{X_k}\right)}{|\mathcal{C}_j|^2}$$

$$O = \sum_{j=1}^{k} \sum_{\overline{X_i} \in \mathcal{C}_j} K\left(\overline{X_i}, \overline{X_i}\right) - 2\frac{\sum_{\overline{X_l} \in \mathcal{C}_j} K\left(\overline{X_i}, \overline{X_l}\right)}{|\mathcal{C}_j|} + \frac{\sum_{\overline{X_l}, \overline{X_k} \in \mathcal{C}_j} K\left(\overline{X_l}, \overline{X_k}\right)}{|\mathcal{C}_j|^2}$$

Università degli Studi di Palermo — dipartimento di ingegneria unipa

Perché il kernel trick funzioni si deve esplicitare K all'interno della funzione obiettivo!!

CHILAB

Clustering basato su prototipi rappresentativi

- K-medians

$$Dist(\overline{X_i}, \overline{Y_j}) = \|\overline{X_i} - \overline{Y_j}\|_1$$

- Uso della distanza di Manhattan

- Robusto rispetto agli outlier a causa dell'uso dei mediani

Clustering basato su prototipi rappresentativi

- K-medoids
- Impone che i valori degli $\bar{Y}_j$ appartengano a $\mathcal{D}$
- Adattabile a dati eterogenei con la giusta definizione dell'appropriata misura di distanza/similarità
- Computazionalmente oneroso

Algorithm *GenericMedoids*(Database: $\mathcal{D}$, Number of Representatives: k)
begin
  Initialize representative set S by selecting from $\mathcal{D}$;
  repeat
    Create clusters $(\mathcal{C}_1 \ldots \mathcal{C}_k)$ by assigning
      each point in $\mathcal{D}$ to closest representative in S
      using the distance function $Dist(\cdot, \cdot)$;
    Determine a pair $\overline{X_i} \in \mathcal{D}$ and $\overline{Y_j} \in S$ such that
      replacing $\overline{Y_j} \in S$ with $\overline{X_i}$ leads to the
      greatest possible improvement in objective function;
    Perform the exchange between $\overline{X_i}$ and $\overline{Y_j}$ only
      if improvement is positive;
  until no improvement in current iteration;
  return $(\mathcal{C}_1 \ldots \mathcal{C}_k)$;
end

Università degli Studi di Palermo
dipartimento di ingegneria unipa
CHILAB

Clustering gerarchico

- Il clustering gerarchico crea una tassonomia di cluster che vengono aggregati attraverso il calcolo di distanze tra essi
- Il calcolo di tali distanze utilizza in genere altri approcci come quelli basati sul concetto di densità o sull'utilizzo di grafi
- Approcci
  - Agglomerativi o bottom-up
  - Divisivi o top-down

Clustering gerarchico

- Approcci agglomerativi

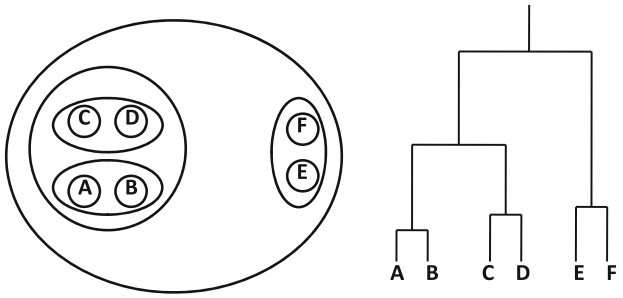
Algorithm *AgglomerativeMerge*(Data: $\mathcal{D}$)
begin
  Initialize $n \times n$ distance matrix M using $\mathcal{D}$;
  repeat
    Pick closest pair of clusters i and j using M;
    Merge clusters i and j;
    Delete rows/columns i and j from M and create
      a new row and column for newly merged cluster;
    Update the entries of new row and column of M;
  until termination criterion;
  return current merged cluster set;
end

M è la struttura dati su cui lavorano tutti gli algoritmi gerarchici

Due approcci:
1. Soglia massima sulla distanza tra due cluster da fondere
2. Soglia minima sul numero di cluster

Clustering gerarchico

- Approcci agglomerativi
  - Il calcolo delle distanze tra i cluster avviene incrementalmente via via che si aggiorna *M*
  - In generale i cluster *i* e *j* contengono rispettivamente m_i e m_j *elementi* e necessitano di calcolare m_i x m_j distanze



(a) Dendrogram

Quale sarà la distanza tra i due cluster?

Si utilizzano delle statistiche per stimare la similarità tra gruppi di oggetti

Clustering gerarchico

- Stime di distanza per approcci agglomerativi, dopo aver fuso i cluster *i* e *j*
  - Single linkage – la distanza è la minima tra le m_i x m_j distanze possibili
    - Per ogni cluster $k \neq i,j$ si considerano min$\{M_{ik}, M_{jk}\}$ per le righe e min$\{M_{ki}, M_{kj}\}$ per le colonne di M
  - Complete linkage – la distanza è la massima tra le m_i x m_j distanze possibili
    - Per ogni cluster $k \neq i,j$ si considerano max$\{M_{ik}, M_{jk}\}$ per le righe e max$\{M_{ki}, M_{kj}\}$ per le colonne di M

Clustering gerarchico

- Stime di distanza per approcci agglomerativi, dopo aver fuso i cluster *i* e *j*
  - Group-average linkage – la distanza è la media tra le m_i x m_j distanze possibili
    - Per ogni cluster $k \neq i,j$ si considerano $(m_i M_{ik} + m_j M_{jk})/(m_i + m_j)$ per le righe e $(m_i M_{ki} + m_j M_{kj})/(m_i + m_j)$ per le colonne di M
  - Centroide più vicino – si fondono i cluster con i centroidi più vicini

Clustering gerarchico

- Approcci agglomerativi – varianza dei cluster
  - Si cerca di effettuare il merge quando la variazione della funzione obiettivo è la minima possibile per preservare le proprietà statistiche dell'agglomerato

$$SE_i = \sum_{r=1}^{d} \left(S_{ir}/m_i - F_{ir}^2/m_i^2 \right)$$

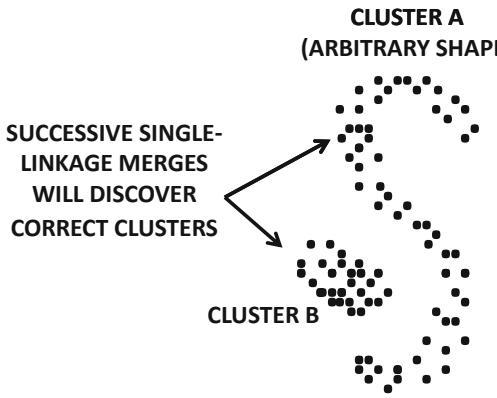
$$S_{ir} = \sum_{\mathbf{x} \in \mathcal{C}_i} \mathbf{x}_r^2$$ *Momento del II ordine di $\mathcal{C}_i$ sulla dimensione r*

$$F_{ir} = \sum_{\mathbf{x} \in \mathcal{C}_i} \mathbf{x}_r$$ *Momento del I ordine di $\mathcal{C}_i$ sulla dimensione r*

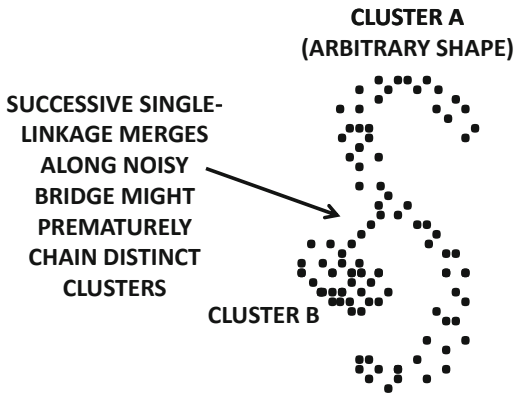
Var = $\mathbb{E}[x^2] - \mathbb{E}[x]^2$

Clustering gerarchico

- Approcci agglomerativi: limiti del clustering



(a) Good case with no noise



(b) Bad case with noise

Clustering gerarchico

- Approcci divisivi
  - $\mathcal{A}$ può essere un algoritmo di clustering qualunque
  - Bisecting k-means: esegue un 2-means ad ogni iterazione
  - La scelta del nodo *L* può essere dettata da diversi criteri
    - Il nodo più vicino alla radice

Algorithm *GenericTopDownClustering*(Data: $\mathcal{D}$, Flat Algorithm: $\mathcal{A}$)
begin
  Initialize tree $\mathcal{T}$ to root containing $\mathcal{D}$;
  repeat
    Select a leaf node L in $\mathcal{T}$ based on pre-defined criterion;
    Use algorithm $\mathcal{A}$ to split L into $L_1 \dots L_k$;
    Add $L_1 \dots L_k$ as children of L in $\mathcal{T}$;
  until termination criterion;
end

Clustering probabilistico

- *Soft Clustering*: ogni punto ha una probabilità anche piccola, ma diversa da 0, di appartenere ad *ogni* cluster

- Considereremo un *modello generativo* $\mathcal{M}$ che descrive la probabilità p_{data} di generare un punto appartenente ad un dato cluster

- Si assuma che p_{data} sia una mistura di distribuzioni $\mathcal{G}_i$, che saranno i nostri cluster, con un insieme di prior $\alpha_i = P(\mathcal{G}_i)$

Clustering probabilistico

- Sia $f^{i}(.)$ la forma funzionale di ogni $\mathcal{G}_i$

- La generazione di un punto dato il nostro modello è descritta da

$$f^{point}(\overline{X_j}|\mathcal{M}) = \sum_{i=1}^{k} \alpha_i \cdot f^{i}(\overline{X_j})$$

Clustering probabilistico

- Per l'intero data set si ha

Ipotesi i.i.d.

$$f^{data}(\mathcal{D}|\mathcal{M}) = \prod_{j=1}^{n} f^{point}(\overline{X_j}|\mathcal{M})$$

- Il clustering si ottiene massimizzando la *log-likelihood* di $f^{data}(\mathcal{D}|\ \mathcal{M})$

$$\mathcal{L}(\mathcal{D}|\mathcal{M}) = \log\left(\prod_{j=1}^{n} f^{point}(\overline{X_j}|\mathcal{M})\right) = \sum_{j=1}^{n} \log\left(\sum_{i=1}^{k} \alpha_i f^i(\overline{X_j})\right)$$

Università degli Studi di Palermo

dipartimento di ingegneria unipa

CHILAB

Clustering probabilistico

- La massimizzazione della likelihood si ottiene con un approccio iterativo a due passi detto *Expectation Maximization (EM)* che ci consente di stimare l'insieme **w** di tutti i parametri della mistura ed i prior α_i

- Usiamo lo schema del Teorema di Bayes

$$P(\mathbf{w}|\mathcal{D}) = \frac{P(\mathcal{D}|\mathbf{w})P(\mathbf{w})}{P(\mathcal{D})}$$

Clustering probabilistico

- Expectation Maximization

$$P(\mathbf{w}|\mathcal{D}) = \frac{P(\mathcal{D}|\mathbf{w})P(\mathbf{w})}{P(\mathcal{D})}$$

- Expectation: si effettua una stima di $P(\mathbf{w}|\mathcal{D})$ delle predizioni del modello fissati i parametri **w**

- Maximization: si effettua uno step di massimizzazione di $P(\mathcal{D}|\mathbf{w})$ per calcolare il nuovo vettore dei parametri **w**

Clustering probabilistico

- Applichiamo l'algoritmo EM al nostro modello

- Expectation - stima di $P(\mathcal{G}_i|X_j, \mathbf{w})$

  - Si stima col teorema di Bayes la probabilità a posteriori che un certo punto sia stato generato da una componente $\mathcal{G}_i$ della mistura, dato **w**

$$P\left(\mathcal{G}_i|\overline{X_j}, \mathbf{w}\right) = \frac{P\left(\mathcal{G}_i\right) \cdot P\left(\overline{X_j}|\mathcal{G}_i, \mathbf{w}\right)}{\sum_{r=1}^{k} P\left(\mathcal{G}_r\right) \cdot P\left(\overline{X_j}|\mathcal{G}_r, \mathbf{w}\right)} = \frac{\alpha_i \cdot f^{i,\mathbf{w}}\left(\overline{X_j}\right)}{\sum_{r=1}^{k} \alpha_r \cdot f^{r,\mathbf{w}}\left(\overline{X_j}\right)}$$

Clustering probabilistico

- Applichiamo l'algoritmo EM al nostro modello
- Maximization – nuova stima dei parametri α_i e **w**
  - Note le probabilità *stimate* di assegnazione di ciascun punto ad ogni cluster si ottengono i nuovi valori dei parametri α_i:

$$\alpha_i = P(\mathcal{G}_i) = \frac{\sum_{j=1}^{n} P(\mathcal{G}_i \mid \overline{X_j}, \mathbf{w})}{n} \quad \text{ovvero} \quad \alpha_i = \frac{1 + \sum_{j=1}^{n} P(\mathcal{G}_i \mid \overline{X_j}, \mathbf{w})}{k + n}$$

  - Si aggiorna **w** massimizzando la log-likelihood: $\partial \mathcal{L}(\mathcal{D} \mid \mathcal{M}) / \partial \mathbf{w} = 0$

Clustering probabilistico

- Si consideri una mistura di gaussiane in *d* dimensioni:

$$f^{i,\mathbf{w}}\left(\overline{X_j}\right) = \frac{1}{\sqrt{|\Sigma_i|}(2\cdot\pi)^{(d/2)}} e^{-\frac{1}{2}\left(\overline{X_j}-\overline{\mu_i}\right)\Sigma_i^{-1}\left(\overline{X_j}-\overline{\mu_i}\right)}$$

- Si può mostrare che il passo di expectation in questo caso pesa i cluster in modo da assegnare i punti ai cluster *esattamente* come il Mahalanobis K-means

Clustering probabilistico

- Nel caso particolare in cui $\alpha_i = 1/k$ e tutte le componenti hanno deviazione standard uguale a σ:

$$f^{j,\mathbf{w}}\left(\overline{X_i}\right) = \frac{1}{\left(\sigma\sqrt{2\cdot\pi}\right)^d} e^{-\left(\frac{\|\overline{X_i}-\overline{Y_j}\|^2}{2\sigma^2}\right)}$$

- I parametri sono σ e i vettori $\bar{Y}_j$ e si ottiene il k-means classico

- In generale la forma della mistura $K_1 \cdot e^{-K_2 \cdot \mathrm{Dist}\left(\overline{X_i},\overline{Y_j}\right)}$ consente di usare EM per implementare tutti i clustering basati su prototipi rappresentativi

Clustering per densità

- In questi approcci si cerca di creare i cluster come componenti connesse di un grafo costituito da elementi strutturali che sono caratterizzati dal possedere un parametro di *densità* sopra una certa soglia

- Approcci *density based* propriamente detti: gli elementi strutturali sono punti il cui intorno contiene un numero di punti maggiore di una certa soglia

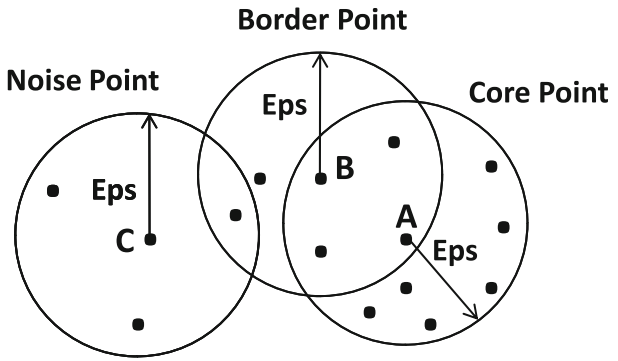
Clustering per densità

- In questi approcci si cerca di creare i cluster come componenti connesse di un grafo costituito da elementi strutturali che sono caratterizzati dal possedere un parametro di *densità* sopra una certa soglia

- Approcci *grid-based*: gli elementi strutturali sono ipercubi di una griglia che suddivide lo spazio dei dati: un ipercubo sarà «denso» se contiene un numero di punti maggiore di una certa soglia

Clustering per densità

- Algoritmi density based – DBSCAN
  - DBSCAN si basa sulla definizione di tre tipologie di punti nel data set
  - Core points: punti che nel loro intorno di dato raggio *Eps* contengono almeno τ punti
  - Border points: punti che contengono meno di τ punti nel loro intorno, ma contengono un core point
  - Noise points: punti che nel loro intorno contengono meno di τ punti e non contengono core point



Clustering per densità

- Algoritmi density based – DBSCAN

Algorithm *DBSCAN*(Data: $\mathcal{D}$, Radius: Eps, Density: τ)
begin
Determine core, border and noise points of $\mathcal{D}$ at level (Eps, τ);
Create graph in which core points are connected
if they are within Eps of one another;
Determine connected components in graph;
Assign each border point to connected component
with which it is best connected;
return points in each connected component as a cluster;
end

Si devono calcolare le distanze tra tutte le coppie di punti!!

Clustering per densità

- Algoritmi density based – DBSCAN
  - Il passo di determinazione del grafo dei core points è un approccio single linkage con distanza *Eps*
  - La ricerca dei core points è un problema $O(n^2)$ che può essere ridotto a $O(n \log n)$ con l'utilizzo di apposite strutture di indicizzazione
  - *Problemi legati all'elevata dimensionalità poiché tali strutture richiedono calcoli di distanze tra i punti che sono onerose e poco significative per elevati valori di d*

Clustering per densità

- Algoritmi density based – DBSCAN
  - Il fatto che τ (denominata in genere *MinPts* nella letteratura di settore) sia fissato comporta problemi nella gestione di cluster a densità variabile
  - *Eps* e τ sono in relazione tra loro: *Eps* può essere determinato come valore di cutoff della distanza di ogni punto dai suoi τ nearest neighbors

Clustering per densità



Università degli Studi di Palermo

dipartimento di ingegneria unipa

CHILAB

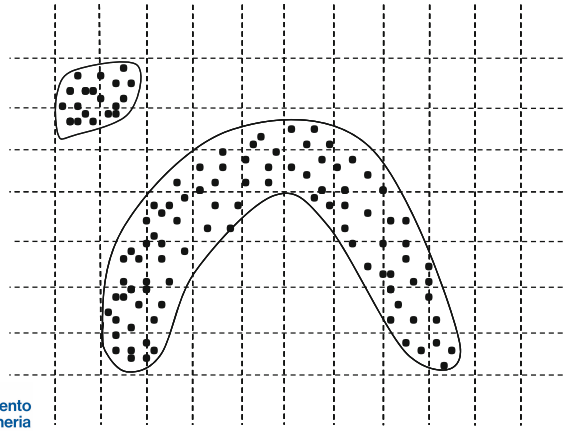
Clustering per densità

- Algoritmi grid based

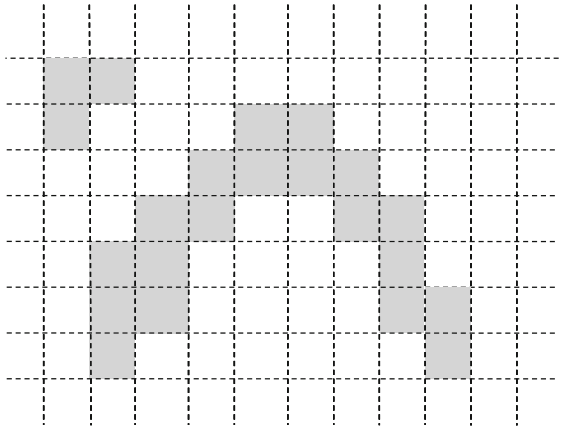
Algorithm *GenericGrid*(Data: $\mathcal{D}$, Ranges: p, Density: τ)
begin
Discretize each dimension of data $\mathcal{D}$ into p ranges;
Determine dense grid cells at density level τ;
Create graph in which dense grids are connected if they are adjacent;
Determine connected components of graph;
return points in each connected component as a cluster;
end

Oterremo ***p^d*** *celle!!*

Le distanze non servono più: si calcolano i ***confronti*** *con le posizioni discretizzate delle celle!!*



(a) Data points and grid



(b) Agglomerating adjacent grids

Università degli Studi di Palermo
dipartimento di ingegneria unipa
CHILAB

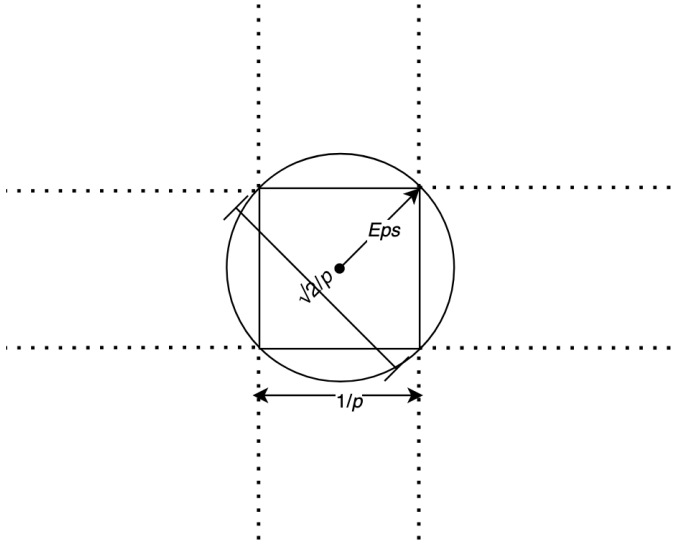
Clustering per densità

- Algoritmi grid based
  - Il clustering dipende dal numero delle celle *p* lungo le dimensioni della griglia e dal parametro di densità *MinPts*
  - Celle troppo grandi (*p* piccolo) possono contenere punti di diversi cluster, mentre celle troppo piccole danno luogo a un numero elevato di celle vuote
  - Un valore di *MinPts* troppo basso fa collassare più celle in un cluster, mentre al contrario tende a spezzare i cluster
  - *Problemi ad elevata dimensionalità perché il numero delle celle cresce esponenzialmente con d*

Clustering per densità

- Algoritmi grid based
  - È possibile legare la dimensione della cella a al valore di *Eps*, a parità di scelta di *MinPts*, per ottenere forme dei cluster simili a quelle di DBSCAN
  - Assumiamo che i dati si trovino all'interno di un ipercubo unitario:

$$\frac{1}{p} \propto \frac{Eps}{\sqrt{2}}$$



Otteniamo un'adiacenza tra celle dense che raggruppa i punti in modo molto simile agli intorni dei core point

Misure di bontà del clustering

- Il clustering è una procedura non supervisionata e quindi non ci fornisce, in principio, informazioni utili alla validazione della bontà del task effettuato

- Si determinano comunque due tipologie di criteri

  - Criteri interni, basati sui dati

  - Criteri esterni, quando delle etichette di classe sono comunque disponibili per verificare se il clustering ha seguito il criterio di classificazione

Misure di bontà del clustering

- Criteri di validazione interni
  - Within Cluster Sum of Squares (WCSS)

$$WCSS = \sum_{j=1}^{K} \sum_{\overline{X}_i \in C_j} (\overline{X}_i - \overline{Y}_j)^2$$

  - Pensata principalmente per il k-means e per gli algoritmi basati su distanze e cluster di forma sferica
  - Tende comunque a diminuire all'aumentare del numero di cluster

Misure di bontà del clustering

- Criteri di validazione interni
  - Rapporto delle distanze Intra-cluster/inter-cluster
  - Campioniamo *r* punti da $\mathcal{D}$ di cui *P* appartengono ad un certo cluster e i rimanenti *Q* no
  - Il clustering è migliore quanto più *Intra*/*Inter* è basso

$$Intra = \sum_{(\bar{X}_i, \bar{X}_j) \in P} \text{dist}(\overline{X_i}, \overline{X_j})/|P|$$

$$Inter = \sum_{(\bar{X}_i, \bar{X}_j) \in Q} \text{dist}(\overline{X_i}, \overline{X_j})/|Q|$$

Misure di bontà del clustering

- Criteri di validazione interni
  - Silohuette coefficient

$$Davg_i^{in} = \text{avg}\left(Dist\left(\overline{X}_k, \overline{X}_l\right)\right),\ \overline{X}_k, \overline{X}_l \in \mathcal{C}_i$$

Distanza media tra i punti del cluster *i*

$$Dmin_i^{out} = \min_{\mathcal{C}_m} \text{avg}\left(Dist\left(\overline{X}_k, \overline{X}_h\right)\right),\ \overline{X}_k \in \mathcal{C}_i, \overline{X}_h \in \mathcal{C}_m$$

Minimo tra le distanze medie degli altri cluster dal cluster *i*

Misure di bontà del clustering

- Criteri di validazione interni
  - Silohuette coefficient

$$S_i = \frac{Dmin_i^{out} - Davg_i^{in}}{\max\left\{Dmin_i^{out}, Davg_i^{in}\right\}}$$

$$S = \frac{1}{n}\sum_i S_i$$

  - *S* varia in [-1, 1]: valori grandi positivi indicano buona separazione tra i cluster, mentre valori negativi indicano mescolamento

Misure di bontà del clustering

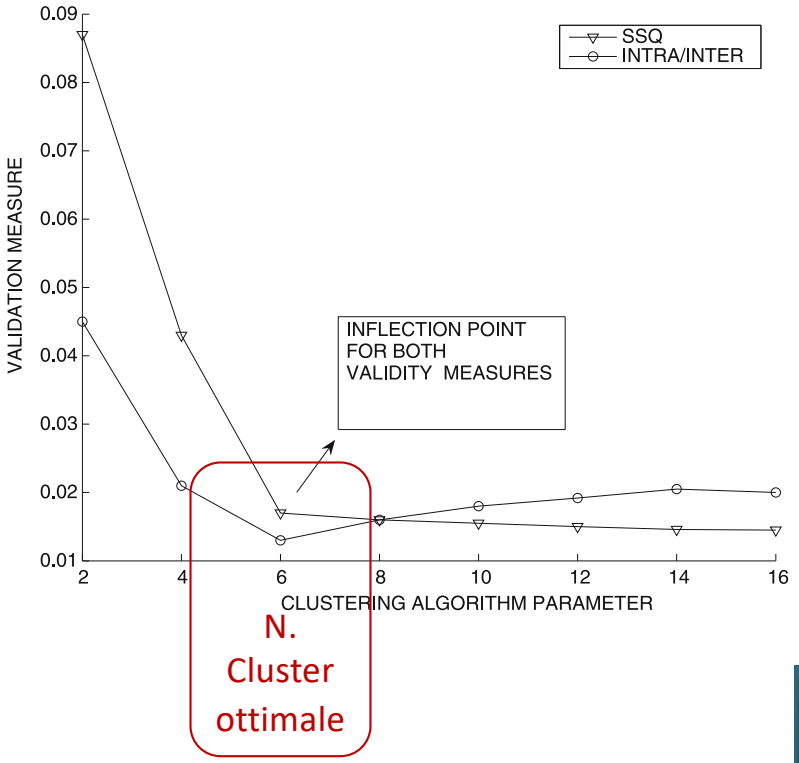
- Criteri di validazione interni
  - Misure probabilistiche
  - Si assume che i dati siano descritti da una mistura di distribuzioni i cui centri delle componenti sono i centri dei cluster che sono stati trovati dall'algoritmo
  - Si utilizza *solo il passo di massimizzazione* dell'approccio *EM* calcolando i parametri rimanenti (le covarianze ad es.) tramite massimizzazione della log-likelihood della mistura

Misure di bontà del clustering

- Criteri di validazione interni
  - Misure probabilistiche
  - Il nuovo modello generativo viene usato per predire i dati da clusterizzare
  - La significatività della misura dipende strettamente dalla forma effettiva dei cluster ovvero la misura ha significato se si hanno delle informazioni a priori su come dovrebbe essere il clustering

Misure di bontà del clustering

- Criteri di validazione interni
  - Possono essere utilizzati anche per effettuare il tuning dei parametri e cioè stabilire il numero di cluster
  - Elbow method: sia WCSS sia *Intra*/*Inter* decrescono rapidamente fino al numero ottimale di cluster e poi si crea un plateau



Misure di bontà del clustering

- Criteri di validazione interni
  - Tutti questi criteri sottendono ciascuno un modello particolare di cluster che potrebbe non essere quello reale
  - Questo rende difficile anche il paragone tra i diversi criteri usati per testare la bontà di un dato algoritmo

Misure di bontà del clustering

- Criteri di validazione esterni
  - Si utilizzano le etichette di cluster, ove disponibili, da usare come etichette di classe
  - Disponibilità di benchmark data set
  - Oppure dati reali con etichette di classe che dipendono dall'applicazione di classificazione e *potrebbero non riflettere* le caratteristiche dei cluster naturali dei dati

Misure di bontà del clustering

- Criteri di validazione esterni
  - Siano k_t le etichette di classe e k_d il numero di cluster determinati dall'algoritmo
  - Se $k_t = k_d$ si può utilizzare la *matrice di confusione*

Valori predetti

Valori reali

Cluster Indices	1	2	3	4
1	97	0	2	1
2	5	191	1	3
3	4	3	87	6
4	0	0	5	195

Cluster Indices	1	2	3	4
1	33	30	17	20
2	51	101	24	24
3	24	23	31	22
4	46	40	44	70

Misure di bontà del clustering

- Criteri di validazione esterni
  - In generale si usano degli indici numerici
  - Sia m_{ij} il numero di punti della classe *i* mappati nel cluster *j,* cioè l'elemento (*i,j*) della matrice di confusione

$$N_i = \sum_{j=1}^{k_d} m_{ij}, \quad \forall i = 1 \dots k_t$$

Somma dei valori lungo una riga: l'effettivo numero di punti appartenenti alla classe *i*

$$M_j = \sum_{i=1}^{k_t} m_{ij}, \quad \forall j = 1 \dots k_d$$

Somma dei valori lungo una colonna: il numero di punti predetti come appartenenti al cluster *j*

Università degli Studi di Palermo

dipartimento di ingegneria unipa

CHILAB

Misure di bontà del clustering

- Criteri di validazione esterni
  - Purity: si assume che un buon cluster avrà quanti più possibili punti appartenenti tutti ad una stessa classe

$$\text{Purity} = \frac{\sum_{j=1}^{k_d} P_j}{\sum_{j=1}^{k_d} M_j}, \quad P_j = \max_i m_{ij}$$

Numero di punti predetti nella classe dominante

  - La Purity tende a 1 per un buon clustering

Misure di bontà del clustering

- Criteri di validazione esterni
  - Gini index: considera il contributo anche delle altre classi presenti nel cluster
  - È un buon cluster quello in cui i punti sono concentrati in poche classi e c'è poca dispersione
  - G_j tende a 0 per un buon clustering, mentre ha $1 - 1/k_t$ come limite superiore

% punti di classe *i* predetti nel cluster *j*

$$G_j = 1 - \sum_{i=1}^{k_t} \left(\frac{m_{ij}}{M_j} \right)^2$$

$$G_{average} = \frac{\sum_{j=1}^{k_d} G_j \cdot M_j}{\sum_{j=1}^{k_d} M_j}$$

Misure di bontà del clustering

- Criteri di validazione esterni
  - Entropia: l'indice di Gini G_j è legato all'entropia E_j del cluster j poiché m_{ij}/M_j è la probabilità frequentista che un punto di classe i appartenga al cluster j

$$E_j = -\sum_{i=1}^{k_t} \left(\frac{m_{ij}}{M_j} \right) \cdot \log \left(\frac{m_{ij}}{M_j} \right)$$

$$E_{\text{average}} = \frac{\sum_{j=1}^{k_d} E_j \cdot M_j}{\sum_{j=1}^{k_d} M_j}$$

Misure di bontà del clustering

- Criteri di validazione esterni
  - È possibile infine stabilire una misura di bontà del clustering analizzando la matrice di confusione con le misure tipiche della classificazione: Precision, Recall e F_1-score (che vedremo più avanti)