



**Università  
degli Studi  
di Palermo**



# Clustering

CORSO DI BIG DATA – MODULO MACHINE LEARNING PER I BIG DATA  
a.a. 2024/2025

Prof. Roberto Pirrone



# Sommario


- Generalità
- Feature selection
- Clustering basato su prototipi rappresentativi
- Clustering gerarchico
- Clustering probabilistico
- Clustering per densità
- Misure di bontà del clustering



Università  
degli Studi  
di Palermo



dipartimento  
di ingegneria  
unipa



# Generalità

- Il clustering è il processo di partizionamento di un data set in modo che ogni partizione (o *cluster*) contenga dati molto simili tra loro che rispetto agli appartenenti ad altre partizioni
- Rappresenta una classe di algoritmi di apprendimento non supervisionati che sono i più utilizzati nel *data mining*
  - Data summarization
  - Customer segmentation, collaborative filtering
  - Social network analysis
  - ...

# Feature selection

- In generale non tutte le feature presenti in un campione sono rilevanti per il compito di clustering e, anzi, possono introdurre una certa «rumorosità» nei dati se prese in considerazione
- È necessario impiegare dei modelli di feature selection che cercano di individuare la «tendenza al clustering» di certi sottoinsiemi di feature

# Feature selection

- Modelli basati su filtro: viene valutata la tendenza di una feature o di un gruppo di feature a contribuire al clustering utilizzando uno score numerico
- Modelli «wrapper»: approcci iterativi di clustering per tentativi su sottoinsiemi di feature
  - Computazionalmente onerosi, ma possono fornire una base per la scelta del miglior algoritmo di clustering per il problema sotto esame

# Feature selection

- Modelli basati su filtro

$$\text{Term Strength} = P(t \in \bar{Y} | t \in \bar{X})$$

- Usata per analisi di dati testuali
- Viene calcolata come la frazione delle coppie di documenti in cui occorre un certo termine  $t$ , posto che  $t$  occorra nel primo dei due
- Determina «termini rilevanti» rispetto al data set

# Feature selection

- Modelli basati su filtro

$$\text{Term Strength} = P(t \in \bar{Y} | t \in \bar{X})$$

- È una *similarità* che può essere estesa a dati multidimensionali rappresentati come vettori binari di attributi presenti/assenti
- Analogamente si possono usare misure di rilevanza rispetto a dati quantitativi confrontando la distanza tra singoli attributi di due campioni rispetto alla distanza complessiva dei due campioni

# Feature selection

- Modelli basati su filtro
  - Dipendenza predittiva da un attributo
  - Assunto: gli attributi rilevanti per il clustering sono correlati
  - Come fare a trovare gli attributi rilevanti?



# Feature selection

- Modelli basati su filtro
  - Dipendenza predittiva da un attributo
  - *Idea*: eseguo una classificazione/regressione (a seconda del tipo di attributo) rispetto alla  $i$ -esima feature che funge da classe del campione
    - Spesso si usa la classificazione nearest neighbor
  - La misura di accuratezza della classificazione rispetto all'attributo  $i$  sarà la misura di rilevanza utilizzata per la feature selection



Università  
degli Studi  
di Palermo



# Feature selection

- Modelli basati su filtro
  - Entropia
  - I dati raggruppati in un cluster hanno entropia più bassa che quelli distribuiti uniformemente nello spazio di variazione
  - Affronteremo il problema di stabilire qual'è il subset delle  $k$  feature più rilevanti per clusterizzare i nostri campioni

# Feature selection

- Modelli basati su filtro
  - Entropia
  - Discretizziamo i valori di ognuna delle  $k$  feature in  $\phi$  intervalli
  - Otteniamo una griglia multidimensionale discreta composta da  $m = \phi^k$  regioni

# Feature selection


- Modelli basati su filtro
  - Entropia
  - Contiamo il numero di punti che cadono in ogni regione e, se  $p_i$  è la frazione di punti che cade nella regione  $i$ -esima, si ha:

$$E = - \sum_{i=1}^m [p_i \log(p_i) + (1 - p_i) \log(1 - p_i)]$$


- Problemi di sparsità per elevate dimensioni

# Feature selection


- Modelli basati su filtro
  - Entropia
    - *Le distanze 1-D tra le feature clusterizzano*
  - Entropia minore di quelle di punti non clusterizzati




(a) Uniform Data



(b) Clustered data



(c) Distance distribution (uniform)



(d) Distance distribution (clustered)

# Feature selection

- Modelli basati su filtro
  - Entropia
  - Si calcolano le «distanze punto a punto» tra i campioni lungo ogni feature e, se  $m$  sono gli intervalli di discretizzazione dei valori di distanza, si ha:

$$E = - \sum_{i=1}^m [p_i \log(p_i) + (1 - p_i) \log(1 - p_i)]$$

$$p_i = \frac{N_{d_i}}{N_d}, \quad d_i \in \text{i-th interval}, \quad i = 1, 2, \dots, m$$



Università  
degli Studi  
di Palermo



dipartimento  
di ingegneria  
unipa



# Feature selection

- Modelli basati su filtro
  - Entropia
  - Si scelgono le feature con entropia minore
  - Approccio greedy: si eliminano le feature che portano via via alla maggiore diminuzione di  $E$



Università  
degli Studi  
di Palermo



dipartimento  
di ingegneria  
unipa



# Feature selection

- Modelli basati su filtro
  - Hopkins Statistic
  - Si generi un campione  $R = \{r_1, \dots, r_r\} \subset \mathcal{D}$
  - Si generi un campione sintetico  $S = \{s_1, \dots, s_r\} \subset \mathbb{R}^d$ , lo spazio dei dati
  - Siano  $\alpha_i = \min_{\mathbf{x}} \text{Dist}(r_i, \mathbf{x})$  e  $\beta_i = \min_{\mathbf{x}} \text{Dist}(s_i, \mathbf{x})$   $i = 1, \dots, r$  e  $\mathbf{x} \in \mathcal{D} - R$



# Feature selection

- Modelli basati su filtro

- Hopkins Statistic

$$H = \frac{\sum_{i=1}^r \beta_i}{\sum_{i=1}^r (\alpha_i + \beta_i)}$$

- $H \rightarrow 0.5$  per dati distribuiti uniformemente ( $\alpha_i$  e  $\beta_i$  sono simili)
    - $H \rightarrow 1$  per dati clusterizzati ( $\alpha_i \ll \beta_i$ )

# Feature selection

- Modelli wrapper
  - Si effettua una serie di clustering su differenti sottoinsiemi di feature e si verifica di volta in volta la qualità ottenuta con una apposita *misura interna di bontà del clustering*
  - Computazionalmente oneroso
    - Necessita di un approccio greedy per la ricerca dei sottoinsiemi rilevanti nello spazio delle feature
    - Fortemente dipendente dalla scelta della misura di bontà del clustering



Università  
degli Studi  
di Palermo

d*i* dipartimento  
di ingegneria  
unipa



# Feature selection

- Modelli wrapper
  - Alternativamente si effettua un clustering sul sottoinsieme di feature considerate e si utilizzano «artificialmente» le etichette dei cluster ottenute come etichette di classe
  - Si utilizza un *criterio di bontà di classificazione supervisionata delle singole feature* su tali etichette per valutare indirettamente la bontà del clustering
  - Si selezionano le prime  $k$  feature con il valore migliore dell'indice di qualità di classificazione



Università  
degli Studi  
di Palermo



dipartimento  
di ingegneria  
unipa



# Clustering basato su prototipi rappresentativi

**Algorithm** *GenericRepresentative*(Database:  $\mathcal{D}$ , Number of Representatives:  $k$ )

**begin**

Initialize representative set  $S$ ;

**repeat**

Create clusters  $(\mathcal{C}_1 \dots \mathcal{C}_k)$  by assigning each point in  $\mathcal{D}$  to closest representative in  $S$  using the distance function  $Dist(\cdot, \cdot)$ ;

Recreate set  $S$  by determining one representative  $\bar{Y}_j$  for each  $\mathcal{C}_j$  that minimizes  $\sum_{\bar{X}_i \in \mathcal{C}_j} Dist(\bar{X}_i, \bar{Y}_j)$ ;

**until** convergence;

**return**  $(\mathcal{C}_1 \dots \mathcal{C}_k)$ ;

**end**

Passo di assegnazione

Passo di ottimizzazione

# Clustering basato su prototipi rappresentativi

- I  $k$  cluster sono in genere un iperparametro determinato dall'utente
- Si devono determinare  $k$  prototipi rappresentativi  $\bar{Y}_j$  che minimizzino la funzione obiettivo

$$O = \sum_{j=1}^k \sum_{\bar{X}_i \in \mathcal{C}_j} Dist(\bar{X}_i, \bar{Y}_j)$$

- I valori degli  $\bar{Y}_j$  in generale *non appartengono* al data set  $\mathcal{D}$
- La scelta di diverse forme di  $Dist(.,.)$  dà luogo a differenti algoritmi

# Clustering basato su prototipi rappresentativi

- K-means

$$Dist(\overline{X_i}, \overline{Y_j}) = \|\overline{X_i} - \overline{Y_j}\|_2^2$$

- Si può mostrare che i valori ottimi degli  $\bar{Y}_j$  sono i valori medi dei punti in ogni singolo cluster  $\mathcal{C}_j$

# Clustering basato su prototipi rappresentativi

- Mahalanobis K-means


$$Dist(\overline{X}_i, \overline{Y}_j) = (\overline{X}_i - \overline{Y}_j) \Sigma_j^{-1} (\overline{X}_i - \overline{Y}_j)^T$$

- La distanza di Mahalanobis è opportuna per cluster di forma (iper-)ellittica
- La covarianza locale  $\Sigma_j$ , calcolata sui punti del cluster  $\mathcal{C}_j$ :
  - fornisce una misura implicita di densità del cluster e quindi consente di gestire cluster a densità variabile
  - Consente la gestione di cluster con forme (iper-)ellittiche variabili




# Clustering basato su prototipi rappresentativi

- *E quando la forma non è più una sfera o un'ellissoide?*



(a) Varying cluster shape  
(Bad for  $k$ -means)



(b) Varying cluster density  
(Good for Mahalanobis  $k$ -means)



# Clustering basato su prototipi rappresentativi

- Per la gestione di cluster di forma qualunque, il k-means ricorre al cosiddetto *kernel trick*
  - Si consideri una funzione  $\Phi(.)$  che mappa un vettore in uno spazio a più alta dimensionalità
  - Si definisce «kernel» una qualunque funzione tale che:

$$K(\overline{X_i}, \overline{X_j}) = \Phi(\overline{X_i}) \cdot \Phi(\overline{X_j})$$

# Clustering basato su prototipi rappresentativi


- Per la gestione di cluster di forma qualunque, il k-means ricorre al cosiddetto *kernel trick*
  - L'uso del kernel è un operatore lineare nello spazio trasformato e quindi consente l'uso di algoritmi lineari nello spazio definito da  $\Phi(\cdot)$
  - Il kernel  $K(\cdot, \cdot)$  viene definito direttamente in termini dei vettori dello spazio di ingresso e non è *mai* necessario calcolare il mapping  $\Phi(\cdot)$

$$K(\overline{X_i}, \overline{X_j}) = \Phi(\overline{X_i}) \cdot \Phi(\overline{X_j})$$

→ Uso di *euristiche* e di *algoritmi di ML dedicati* per selezionare il kernel  $K$  più adatto ad un dato compito

# Clustering basato su prototipi rappresentativi

- Per la gestione di cluster di forma qualunque, il k-means ricorre al cosiddetto *kernel trick*



# Clustering basato su prototipi rappresentativi

- Per la gestione di cluster di forma qualunque, il k-means ricorre al cosiddetto *kernel trick*
- La nuova funzione obiettivo, tenendo conto del mapping  $\Phi(\cdot)$  è:

$$O = \sum_{j=1}^k \sum_{\bar{X}_i \in \mathcal{C}_j} \|\Phi(\bar{X}_i) - \bar{Y}_j\|_2, \quad \bar{Y}_j = \frac{\sum_{\bar{X}_l \in \mathcal{C}_j} \Phi(\bar{X}_l)}{|\mathcal{C}_j|}$$

$$O = \Phi(\bar{X}_i) \cdot \Phi(\bar{X}_i) - 2 \frac{\sum_{\bar{X}_l \in \mathcal{C}_j} \Phi(\bar{X}_i) \cdot \Phi(\bar{X}_l)}{|\mathcal{C}_j|} + \frac{\sum_{\bar{X}_l, \bar{X}_k \in \mathcal{C}_j} \Phi(\bar{X}_l) \cdot \Phi(\bar{X}_k)}{|\mathcal{C}_j|^2} =$$

$$O = K(\bar{X}_i, \bar{X}_i) - 2 \frac{\sum_{\bar{X}_l \in \mathcal{C}_j} K(\bar{X}_i, \bar{X}_l)}{|\mathcal{C}_j|} + \frac{\sum_{\bar{X}_l, \bar{X}_k \in \mathcal{C}_j} K(\bar{X}_l, \bar{X}_k)}{|\mathcal{C}_j|^2}$$

# Clustering basato su prototipi rappresentativi

- K-medians

$$Dist(\overline{X_i}, \overline{Y_j}) = \|\overline{X_i} - \overline{Y_j}\|_1$$

- Uso della distanza di Manhattan
- Robusto rispetto agli outlier a causa dell'uso dei mediani

# Clustering basato su prototipi rappresentativi

- K-medoids
- Impone che i valori degli  $\bar{Y}_j$  appartengano a  $\mathcal{D}$
- Adattabile a dati eterogenei con la giusta definizione dell'appropriata misura di distanza/similarità
- Computazionalmente oneroso

**Algorithm** *GenericMedoids*(Database:  $\mathcal{D}$ , Number of Representatives:  $k$ )  
**begin**

Initialize representative set  $S$  by selecting from  $\mathcal{D}$ ;

**repeat**

Create clusters  $(\mathcal{C}_1 \dots \mathcal{C}_k)$  by assigning  
each point in  $\mathcal{D}$  to closest representative in  $S$   
using the distance function  $Dist(\cdot, \cdot)$ ;

Determine a pair  $\bar{X}_i \in \mathcal{D}$  and  $\bar{Y}_j \in S$  such that  
replacing  $\bar{Y}_j \in S$  with  $\bar{X}_i$  leads to the  
greatest possible improvement in objective function;

Perform the exchange between  $\bar{X}_i$  and  $\bar{Y}_j$  only  
if improvement is positive;

**until** no improvement in current iteration;

**return**  $(\mathcal{C}_1 \dots \mathcal{C}_k)$ ;

**end**

# Clustering gerarchico

- Il clustering gerarchico crea una tassonomia di cluster che vengono aggregati attraverso il calcolo di distanze tra essi
- Il calcolo di tali distanze utilizza in genere altri approcci come quelli basati sul concetto di densità o sull'utilizzo di grafi
- Approcci
  - Agglomerativi o bottom-up
  - Divisivi o top-down

# Clustering gerarchico

- Approcci agglomerativi

```
Algorithm AgglomerativeMerge(Data:  $\mathcal{D}$ )  
begin  
  Initialize  $n \times n$  distance matrix  $M$  using  $\mathcal{D}$ ;  
  repeat  
    Pick closest pair of clusters  $i$  and  $j$  using  $M$ ;  
    Merge clusters  $i$  and  $j$ ;  
    Delete rows/columns  $i$  and  $j$  from  $M$  and create  
      a new row and column for newly merged cluster;  
    Update the entries of new row and column of  $M$ ;  
  until termination criterion;  
  return current merged cluster set;  
end
```

$M$  è la struttura dati su cui lavorano tutti gli algoritmi gerarchici


Due approcci:

1. Soglia massima sulla distanza tra due cluster da fondere
2. Soglia minima sul numero di cluster



# Clustering gerarchico

- Approcci agglomerativi
  - Il calcolo delle distanze tra i cluster avviene incrementalmente via via che si aggiorna  $M$
  - In generale i cluster  $i$  e  $j$  contengono rispettivamente  $m_i$  e  $m_j$  *elementi* e necessitano di calcolare  $m_i \times m_j$  distanze



(a) Dendrogram

*Quale sarà la distanza tra i due cluster?*

Si utilizzano delle statistiche per stimare la similarità tra gruppi di oggetti

# Clustering gerarchico

- Stime di distanza per approcci agglomerativi, dopo aver fuso i cluster  $i$  e  $j$ 
  - Single linkage – la distanza è la minima tra le  $m_i \times m_j$  distanze possibili
    - Per ogni cluster  $k \neq i, j$  si considerano  $\min\{M_{ik}, M_{jk}\}$  per le righe e  $\min\{M_{ki}, M_{kj}\}$  per le colonne di  $M$
  - Complete linkage – la distanza è la massima tra le  $m_i \times m_j$  distanze possibili
    - Per ogni cluster  $k \neq i, j$  si considerano  $\max\{M_{ik}, M_{jk}\}$  per le righe e  $\max\{M_{ki}, M_{kj}\}$  per le colonne di  $M$



# Clustering gerarchico

- Stime di distanza per approcci agglomerativi, dopo aver fuso i cluster  $i$  e  $j$ 
  - Group-average linkage – la distanza è la media tra le  $m_i \times m_j$  distanze possibili
    - Per ogni cluster  $k \neq i, j$  si considerano  $(m_i M_{ik} + m_j M_{jk}) / (m_i + m_j)$  per le righe e  $(m_i M_{ki} + m_j M_{kj}) / (m_i + m_j)$  per le colonne di  $M$
  - Centroide più vicino – si fondono i cluster con i centroidi più vicini

# Clustering gerarchico

- Approcci agglomerativi – varianza dei cluster
  - Si cerca di effettuare il merge quando la variazione della funzione obiettivo è la minima possibile per preservare le proprietà statistiche dell'agglomerato

$$SE_i = \sum_{r=1}^d \left( S_{ir}/m_i - F_{ir}^2/m_i^2 \right)$$

$$S_{ir} = \sum_{\mathbf{x} \in \mathcal{C}_i} \mathbf{x}_r^2 \quad \text{Momento del II ordine di } \mathcal{C}_i \text{ sulla dimensione } r$$

$$F_{ir} = \sum_{\mathbf{x} \in \mathcal{C}_i} \mathbf{x}_r \quad \text{Momento del I ordine di } \mathcal{C}_i \text{ sulla dimensione } r$$

$$\text{Var} = \mathbb{E}[\mathbf{x}^2] - \mathbb{E}[\mathbf{x}]^2$$

# Clustering gerarchico

- Approcci agglomerativi – varianza dei cluster
  - Si cerca di effettuare il merge quando la variazione della funzione obiettivo è la minima possibile per preservare le proprietà statistiche dell'agglomerato

$$SE_i = \sum_{r=1}^d \left( S_{ir}/m_i - F_{ir}^2/m_i^2 \right)$$

$$S_{ir} = \sum_{\mathbf{x} \in \mathcal{C}_i} \mathbf{x}_r^2 \quad \begin{array}{l} \text{Momento del II ordine di } \mathcal{C}_i \\ \text{sulla dimensione } r \end{array}$$


$$F_{ir} = \sum_{\mathbf{x} \in \mathcal{C}_i} \mathbf{x}_r \quad \begin{array}{l} \text{Momento del I ordine di } \mathcal{C}_i \\ \text{sulla dimensione } r \end{array}$$

$$\Delta SE_{i \cup j} = SE_{i \cup j} - SE_i - SE_j$$


$$\Delta SE_{i \cup j \cup k} = SE_{i \cup j \cup k} - SE_{i \cup j} - SE_k, \quad k \neq i, j$$

# Clustering gerarchico

- Approcci agglomerativi: limiti del clustering



(a) Good case with no noise



(b) Bad case with noise

# Clustering gerarchico

- Approcci divisivi
  - $\mathcal{A}$  può essere un algoritmo di clustering qualunque
  - Bisecting k-means: esegue un 2-means ad ogni iterazione
  - La scelta del nodo  $L$  può essere dettata da diversi criteri
    - Il nodo più vicino alla radice

**Algorithm** *GenericTopDownClustering*(Data:  $\mathcal{D}$ , Flat Algorithm:  $\mathcal{A}$ )  
**begin**  
    Initialize tree  $\mathcal{T}$  to root containing  $\mathcal{D}$ ;  
    **repeat**  
        Select a leaf node  $L$  in  $\mathcal{T}$  based on pre-defined criterion;  
        Use algorithm  $\mathcal{A}$  to split  $L$  into  $L_1 \dots L_k$ ;  
        Add  $L_1 \dots L_k$  as children of  $L$  in  $\mathcal{T}$ ;  
    **until** termination criterion;  
**end**



# Clustering probabilistico

- *Soft Clustering*: ogni punto ha una probabilità anche piccola, ma diversa da 0, di appartenere ad *ogni* cluster
- Considereremo un *modello generativo*  $\mathcal{M}$  che descrive la probabilità  $p_{\text{data}}$  di generare un punto appartenente ad un dato cluster
- Si assuma che  $p_{\text{data}}$  sia una mistura di distribuzioni  $\mathcal{G}_i$ , che saranno i nostri cluster, con un insieme di prior  $\alpha_i = P(\mathcal{G}_i)$



# Clustering probabilistico

- Sia  $f^i(.)$  la forma funzionale di ogni  $\mathcal{G}_i$
- La generazione di un punto dato il nostro modello è descritta da

$$f^{point}(\overline{X}_j | \mathcal{M}) = \sum_{i=1}^k \alpha_i \cdot f^i(\overline{X}_j)$$

# Clustering probabilistico

- Per l'intero data set si ha

$$f^{data}(\mathcal{D}|\mathcal{M}) = \prod_{j=1}^n f^{point}(\overline{X}_j|\mathcal{M})$$

Ipotesi i.i.d.

- Il clustering si ottiene massimizzando la log-likelihood di  $f^{data}(\mathcal{D}|\mathcal{M})$

$$\mathcal{L}(\mathcal{D}|\mathcal{M}) = \log \left( \prod_{j=1}^n f^{point}(\overline{X}_j|\mathcal{M}) \right) = \sum_{j=1}^n \log \left( \sum_{i=1}^k \alpha_i f^i(\overline{X}_j) \right)$$

# Clustering probabilistico

- La massimizzazione della likelihood si ottiene con un approccio iterativo a due passi detto *Expectation Maximization (EM)* che ci consente di stimare l'insieme  $\Theta$  di tutti i parametri della mistura ed i prior  $\alpha_i$
- Usiamo lo schema del Teorema di Bayes

$$P(\mathbf{w}|\mathcal{D}) = \frac{P(\mathcal{D}|\mathbf{w})P(\mathbf{w})}{P(\mathcal{D})}$$

# Clustering probabilistico

- Expectation Maximization

$$P(\mathbf{w}|\mathcal{D}) = \frac{P(\mathcal{D}|\mathbf{w})P(\mathbf{w})}{P(\mathcal{D})}$$

- Expectation: si effettua una stima di  $P(\mathbf{w}|\mathcal{D})$  delle predizioni del modello fissati i parametri  $\mathbf{w}$
- Maximization: si effettua uno step di massimizzazione di  $P(\mathcal{D}|\mathbf{w})$  per calcolare il nuovo vettore dei parametri  $\mathbf{w}$

# Clustering probabilistico

- Applichiamo l'algoritmo EM al nostro modello
- Expectation - stima di  $P(\mathcal{G}_i | X_j, \Theta)$ 
  - Si stima col teorema di Bayes la probabilità a posteriori che un certo punto sia stato generato da una componente  $\mathcal{G}_i$  della mistura, dato  $\Theta$

$$P(\mathcal{G}_i | \overline{X}_j, \Theta) = \frac{P(\mathcal{G}_i) \cdot P(\overline{X}_j | \mathcal{G}_i, \Theta)}{\sum_{r=1}^k P(\mathcal{G}_r) \cdot P(\overline{X}_j | \mathcal{G}_r, \Theta)} = \frac{\alpha_i \cdot f^{i, \Theta}(\overline{X}_j)}{\sum_{r=1}^k \alpha_r \cdot f^{r, \Theta}(\overline{X}_j)}$$

# Clustering probabilistico

- Applichiamo l'algoritmo EM al nostro modello
- Maximization – nuova stima dei parametri  $\alpha_i$  e  $\Theta$ 
  - Note le probabilità *stimate* di assegnazione di ciascun punto ad ogni cluster si ottengono i nuovi valori dei parametri  $\alpha_i$ :

$$\alpha_i = P(\mathcal{G}_i) = \frac{\sum_{j=1}^n P(\mathcal{G}_i | \overline{X}_j, \Theta)}{n} \quad \text{ovvero} \quad \alpha_i = \frac{1 + \sum_{j=1}^n P(\mathcal{G}_i | \overline{X}_j, \Theta)}{k + n}$$

- Si aggiorna  $\Theta$  massimizzando la log-likelihood:  $\partial \mathcal{L}(\mathcal{D} | \mathcal{M}) / \partial \Theta = 0$

# Clustering probabilistico

- Si consideri una mistura di gaussiane in  $d$  dimensioni:

$$f^{i,\Theta}(\overline{X}_j) = \frac{1}{\sqrt{|\Sigma_i|}(2 \cdot \pi)^{(d/2)}} e^{-\frac{1}{2}(\overline{X}_j - \overline{\mu}_i)\Sigma_i^{-1}(\overline{X}_j - \overline{\mu}_i)}$$

- Si può mostrare che il passo di expectation in questo caso pesa i cluster in modo da assegnare i punti ai cluster *esattamente* come il Mahalanobis K-means

# Clustering probabilistico

- Nel caso particolare in cui  $\alpha_i = 1/k$  e tutte le componenti hanno deviazione standard uguale a  $\sigma$ :

$$f^{j,\Theta}(\overline{X}_i) = \frac{1}{(\sigma\sqrt{2 \cdot \pi})^d} e^{-\left(\frac{\|\overline{X}_i - \overline{Y}_j\|^2}{2\sigma^2}\right)}$$

- I parametri sono  $\sigma$  e i vettori  $\overline{Y}_j$  e si ottiene il k-means classico
- In generale la forma della mistura  $K_1 \cdot e^{-K_2 \cdot \text{Dist}(\overline{X}_i, \overline{Y}_j)}$  consente di usare EM per implementare tutti i clustering basati su prototipi rappresentativi




# Clustering per densità

- In questi approcci si cerca di creare i cluster come componenti connesse di un grafo costituito da elementi strutturali che sono caratterizzati dal possedere un parametro di *densità* sopra una certa soglia
  - Approcci density based propriamente detti: gli elementi strutturali sono punti il cui intorno contiene un numero di punti maggiore di una certa soglia
  - Approcci grid-based: gli elementi strutturali sono ipercubi di una griglia che suddivide lo spazio dei dati: un ipercubo sarà «denso» se contiene un numero di punti maggiore di una certa soglia
    - $p$  intervalli lungo ognuna delle  $d$  dimensioni  $\rightarrow p^d$  celle della griglia

# Clustering per densità

- Algoritmi density based – DBSCAN
  - DBSCAN si basa sulla definizione di tre tipologie di punti nel data set
  - Core points: punti che nel loro intorno di dato raggio  $Eps$  contengono almeno  $\tau$  punti
  - Border points: punti che contengono meno di  $\tau$  punti nel loro intorno, ma contengono un core point
  - Noise points: punti che nel loro intorno contengono meno di  $\tau$  punti e non contengono core point



# Clustering per densità

- Algoritmi density based – DBSCAN

**Algorithm** *DBSCAN*(Data:  $\mathcal{D}$ , Radius:  $Eps$ , Density:  $\tau$  )

**begin**

Determine core, border and noise points of  $\mathcal{D}$  at level  $(Eps, \tau)$ ;

Create graph in which core points are connected  
if they are within  $Eps$  of one another;

Determine connected components in graph;

Assign each border point to connected component  
with which it is best connected;

**return** points in each connected component as a cluster;

**end**

*Si devono calcolare le  
distanze tra tutte le  
coppie di punti!!*

# Clustering per densità

- Algoritmi density based – DBSCAN
  - Il passo di determinazione del grafo dei core points è un approccio single linkage con distanza  $Eps$
  - La ricerca dei core points è un problema  $O(n^2)$  che può essere ridotto a  $O(n \log n)$  con l'utilizzo di apposite strutture di indicizzazione
  - *Problemi legati all'elevata dimensionalità poiché tali strutture richiedono calcoli di distanze tra i punti che sono onerose e poco significative per elevati valori di  $d$*

# Clustering per densità

- Algoritmi density based – DBSCAN
  - Il fatto che  $\tau$  (denominata in genere *MinPts* nella letteratura di settore) sia fissato comporta problemi nella gestione di cluster a densità variabile
  - *Eps* e  $\tau$  sono in relazione tra loro: *Eps* può essere determinato come valore di cutoff della distanza di ogni punto dai suoi  $\tau$  nearest neighbors

# Clustering per densità

- Algoritmi grid based

**Algorithm** *GenericGrid*(Data:  $\mathcal{D}$ , Ranges:  $p$ , Density:  $\tau$ )

**begin**

Discretize each dimension of data  $\mathcal{D}$  into  $p$  ranges;


Determine dense grid cells at density level  $\tau$ ;

Create graph in which dense grids are connected if they are adjacent;


Determine connected components of graph;

**return** points in each connected component as a cluster;

**end**



(a) Data points and grid



(b) Agglomerating adjacent grids

*Le distanze non servono più: si calcolano i confronti con le posizioni discretizzate delle celle!!*

# Clustering per densità


- Algoritmi grid based
  - Il clustering dipende dal numero delle celle  $p$  lungo le dimensioni della griglia e dal parametro di densità  $MinPts$
  - Celle troppo grandi ( $p$  piccolo) possono contenere punti di diversi cluster, mentre celle troppo piccole danno luogo a un numero elevato di celle vuote
  - Un valore di  $MinPts$  troppo basso fa collassare più celle in un cluster, mentre al contrario tende a spezzare i cluster
  - *Problemi ad elevata dimensionalità perché il numero delle celle cresce esponenzialmente con  $d$*

# Clustering per densità

- Algoritmi grid based
  - È possibile legare la dimensione della cella a al valore di  $Eps$ , a parità di scelta di  $MinPts$ , per ottenere forme dei cluster simili a quelle di DBSCAN
  - Assumiamo che i dati si trovino all'interno di un ipercubo unitario:

$$\frac{1}{p} \propto \frac{Eps}{\sqrt{2}}$$

Otteniamo un'adiacenza tra celle dense che raggruppa i punti in modo molto simile agli intorno dei core point





# Misure di bontà del clustering

- Il clustering è una procedura non supervisionata e quindi non ci fornisce, in principio, informazioni utili alla validazione della bontà del task effettuato
- Si determinano comunque due tipologie di criteri
  - Criteri interni, basati sui dati
  - Criteri esterni, quando delle etichette di classe sono comunque disponibili per verificare se il clustering ha seguito il criterio di classificazione

# Misure di bontà del clustering

- Criteri di validazione interni
  - Within Cluster Sum of Squares (WCSS)

$$WCSS = \sum_{j=1}^K \sum_{\bar{X}_i \in \mathcal{C}_j} (\bar{X}_i - \bar{Y}_j)^2$$

- Pensata principalmente per il k-means e per gli algoritmi basati su distanze e cluster di forma sferica
- Tende comunque a diminuire all'aumentare del numero di cluster

# Misure di bontà del clustering

- Criteri di validazione interni

- Rapporto delle distanze Intra-cluster/inter-cluster

$$Intra = \sum_{(\bar{X}_i, \bar{X}_j) \in P} \text{dist}(\bar{X}_i, \bar{X}_j) / |P|$$

- Campioniamo  $r$  punti da  $\mathcal{D}$  di cui  $P$  appartengono ad un certo cluster e i rimanenti  $Q$  no

$$Inter = \sum_{(\bar{X}_i, \bar{X}_j) \in Q} \text{dist}(\bar{X}_i, \bar{X}_j) / |Q|$$

- Il clustering è migliore quanto più  $Intra/Inter$  è basso



Università  
degli Studi  
di Palermo



dipartimento  
di ingegneria  
unipa



# Misure di bontà del clustering

- Criteri di validazione interni
  - Silhouette coefficient

$Davg_i^{in} = \text{avg} \left( \text{Dist} \left( \overline{X}_k, \overline{X}_l \right) \right), \overline{X}_k, \overline{X}_l \in \mathcal{C}_i$  Distanza media tra i punti del cluster  $i$

$Dmin_i^{out} = \min_{\mathcal{C}_m} \text{avg} \left( \text{Dist} \left( \overline{X}_k, \overline{X}_h \right) \right), \overline{X}_k \in \mathcal{C}_i, \overline{X}_h \in \mathcal{C}_m$  Minimo tra le distanze medie degli altri cluster dal cluster  $i$

# Misure di bontà del clustering

- Criteri di validazione interni
  - Silhouette coefficient

$$S_i = \frac{Dmin_i^{out} - Davg_i^{in}}{\max \{ Dmin_i^{out}, Davg_i^{in} \}}$$

$$S = \frac{1}{n} \sum_i S_i$$

- $S$  varia in  $[-1, 1]$ : valori grandi positivi indicano buona separazione tra i cluster, mentre valori negativi indicano mescolamento

# Misure di bontà del clustering


- Criteri di validazione interni
  - Misure probabilistiche
  - Si assume che i dati siano descritti da una mistura di distribuzioni i cui centri delle componenti sono i centri dei cluster che sono stati trovati dall'algoritmo
  - Si utilizza solo il passo di massimizzazione dell'approccio *EM* calcolando i parametri rimanenti (le covarianze ad es.) tramite massimizzazione della log-likelihood della mistura

# Misure di bontà del clustering

- Criteri di validazione interni
  - Misure probabilistiche
  - Il nuovo modello generativo viene usato per predire i dati da clusterizzare
  - La significatività della misura dipende strettamente dalla forma effettiva dei cluster ovvero la misura ha significato se si hanno delle informazioni a priori su come dovrebbe essere il clustering

# Misure di bontà del clustering

- Criteri di validazione interni
  - Possono essere utilizzati anche per effettuare il tuning dei parametri e cioè stabilire il numero di cluster
  - Elbow method: sia *WCSS* sia *Intra/Inter* decrescono rapidamente fino al numero ottimale di cluster e poi si crea un plateau





# Misure di bontà del clustering

- Criteri di validazione interni
  - Tutti questi criteri sottendono ciascuno un modello particolare di cluster che potrebbe non essere quello reale
  - Questo rende difficile anche il paragone tra i diversi criteri usati per testare la bontà di un dato algoritmo

# Misure di bontà del clustering

- Criteri di validazione esterni
  - Si utilizzano le etichette di cluster, ove disponibili, da usare come etichette di classe
  - Disponibilità di benchmark data set
  - Oppure dati reali con etichette di classe che dipendono dall'applicazione di classificazione e potrebbero non riflettere le caratteristiche dei cluster naturali dei dati

# Misure di bontà del clustering

- Criteri di validazione esterni
  - Siano  $k_t$  le etichette di classe e  $k_d$  il numero di cluster determinati dall'algoritmo
  - Se  $k_t = k_d$  si può utilizzare la *matrice di confusione*

|              |                 | Valori predetti |     |    |     |
|--------------|-----------------|-----------------|-----|----|-----|
| Valori reali | Cluster Indices | 1               | 2   | 3  | 4   |
|              | 1               | 97              | 0   | 2  | 1   |
|              | 2               | 5               | 191 | 1  | 3   |
|              | 3               | 4               | 3   | 87 | 6   |
|              | 4               | 0               | 0   | 5  | 195 |

|   |                 | 1  | 2   | 3  | 4  |
|---|-----------------|----|-----|----|----|
| 1 | Cluster Indices | 33 | 30  | 17 | 20 |
| 2 |                 | 51 | 101 | 24 | 24 |
| 3 |                 | 24 | 23  | 31 | 22 |
| 4 |                 | 46 | 40  | 44 | 70 |

# Misure di bontà del clustering

- Criteri di validazione esterni
  - In generale si usano degli indici numerici
  - Sia  $m_{ij}$  il numero di punti della classe  $i$  mappati nel cluster  $j$ , cioè l'elemento  $(i,j)$  della matrice di confusione

$$N_i = \sum_{j=1}^{k_d} m_{ij}, \quad \forall i = 1 \dots k_t$$

Somma dei valori lungo una riga:  
l'effettivo numero di punti  
appartenenti alla classe  $i$

$$M_j = \sum_{i=1}^{k_t} m_{ij}, \quad \forall j = 1 \dots k_d$$

Somma dei valori lungo una colonna:  
il numero di punti predetti  
come appartenenti al cluster  $j$

# Misure di bontà del clustering

- Criteri di validazione esterni
  - Purity: si assume che un buon cluster avrà quanti più possibili punti appartenenti tutti ad una stessa classe

$$\text{Purity} = \frac{\sum_{j=1}^{k_d} P_j}{\sum_{j=1}^{k_d} M_j}, \quad P_j = \max_i m_{ij}$$

Numero di punti predetti nella classe dominante

- La Purity tende a 1 per un buon clustering

# Misure di bontà del clustering

- Criteri di validazione esterni

- Gini index: considera il contributo anche delle altre classi presenti nel cluster
- È un buon cluster quello in cui i punti sono concentrati in poche classi e c'è poca dispersione
- $G_j$  tende a 0 per un buon clustering, mentre ha  $1 - 1/k_t$  come limite superiore

$$G_j = 1 - \sum_{i=1}^{k_t} \left( \frac{m_{ij}}{M_j} \right)^2$$

% punti  
del cluster  
 $j$  predetti  
in classe  $i$

$$G_{average} = \frac{\sum_{j=1}^{k_d} G_j \cdot M_j}{\sum_{j=1}^{k_d} M_j}$$

# Misure di bontà del clustering

- Criteri di validazione esterni
  - Entropia: l'indice di Gini  $G_j$  è legato all'entropia del cluster  $j$   $E_j$  poiché  $m_{ij}/M_j$  è la probabilità frequentista che un punto appartenga a tale cluster

$$E_j = - \sum_{i=1}^{k_t} \left( \frac{m_{ij}}{M_j} \right) \cdot \log \left( \frac{m_{ij}}{M_j} \right)$$

$$E_{\text{average}} = \frac{\sum_{j=1}^{k_d} E_j \cdot M_j}{\sum_{j=1}^{k_d} M_j}$$

# Misure di bontà del clustering

- Criteri di validazione esterni
  - È possibile infine stabilire una misura di bontà del clustering analizzando la matrice di confusione con le misure tipiche della classificazione: Precision, Recall e  $F_1$ -score (che vedremo più avanti)