



**Università  
degli Studi  
di Palermo**



# Cassandra

CORSO DI BIG DATA – MODULO ANALISI PER I BIG DATA  
a.a. 2022/2023

Prof. Roberto Pirrone

# Sommario

- Caratteristiche principali
- Cassandra vs MongoDB
- Architettura
- Modello dei dati

# Caratteristiche principali

- Column-oriented
  - Le colonne contengono direttamente i dati e non i metadati (i nomi dei campi)
- Architettura distribuita altamente scalabile
  - Basata sui concetti di nodo, data center e cluster, può essere facilmente scalata in entrambe le direzioni
  - Comunicazione master-slave o peer-to-peer tra i database
- Fault tolerant
  - Connessione ad anello tra i nodi, data center multipli, gestione del carico per singolo nodo/cluster


# Caratteristiche principali

- Elevate prestazioni
  - È disegnato per la gestione routinaria di elevatissime moli di dati
- Consistenza configurabile
  - Gestisce la consistenza stretta, quella «eventual», ma anche un mix delle due
- Schema lasco
  - Anche se sembra di interagire con un RDBMS, l'aggregato principale delle colonne è la «column family» cioè righe ciascuna delle quali può contenere gruppi di colonne differenti

# Caratteristiche principali

- Applicazioni tipiche
  - Storage di dati molto eterogenei e in grande quantità (Digg)
  - Sviluppo del back-end delle applicazioni (Netflix, Google App Engine)
  - Analisi di serie temporali (WebEx di Cisco per lo storage dei feed utente)
  - Strumenti di monitoring (CERN)
  - Strumenti di Analytics (BlackRock)

# Caratteristiche principali




# Cassandra vs MongoDB

	Cassandra	MongoDB
Modello dei dati	Basato su tabelle con righe e colonne	Modello ricco ed espressivo object-oriented
Nodo master	Multipli: se uno va down, un altro prende il suo posto	Uno solo: processo di elezione necessario in caso di failure
Indici secondari	Supporto per indici su singole colonne che gestiscono solo l'uguaglianza dei valori (sono semplici cursori)	Ogni proprietà o sub-documento è indicizzabile
Scalabilità	Elevata	Limitata
Linguaggio di query	CQL (simile a SQL)	Nessuno: la query è un documento JSON
Aggregazione	Non presente	Aggregation framework che include anche MapReduce
Schema	Tipizzazione statica: l'utente deve definire il tipo di una colonna	Assolutamente schema free

# Architettura


- Nodi organizzati circolarmente in *cluster*
- I cluster possono essere suddivisi fisicamente su più *data center* dislocati in luoghi diversi
- Un nodo è un singolo server in un *rack*






# Architettura

- I nodi comunicano tra loro in modalità peer-to-peer usando il Gossip protocol per stabilire l'appartenenza al cluster
  - Comunicano randomicamente a coppie per *diffondere* le informazioni
- L'organizzazione circolare al suo interno suddivide gli intervalli di valori delle chiavi



PEER TO PEER DISTRIBUTION  
MODEL OF CASSANDRA


## Partitioning of Keys in the Cluster



LABORATORIO DI INTERAZIONE UOMO-MACCHINA  
CHILAB


# Architettura

- Una read/write dal client avviene verso un nodo qualunque del cluster che diviene il *coordinatore*
- Individua i nodi effettivamente responsabili dell'intervallo di valori di chiavi coinvolto
- Coordina la replicazione



# Architettura

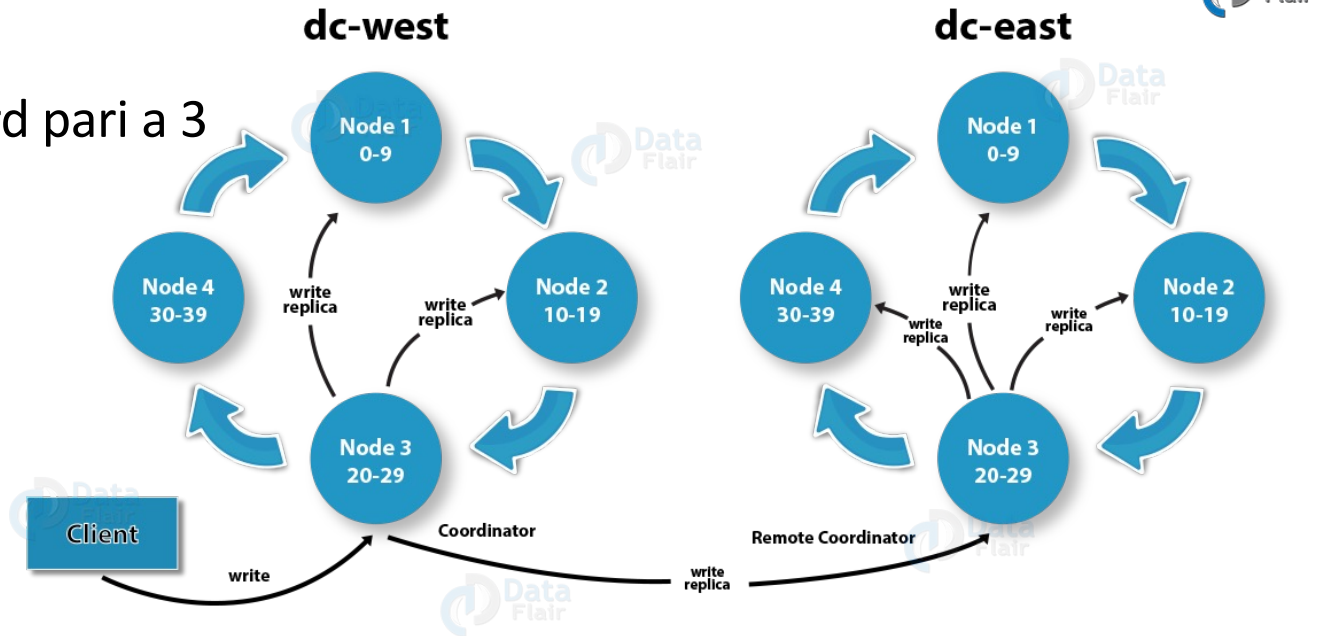
- Strategie di replicazione
  - Replication factor standard pari a 3
  - Simple Strategy
  - Network Topology



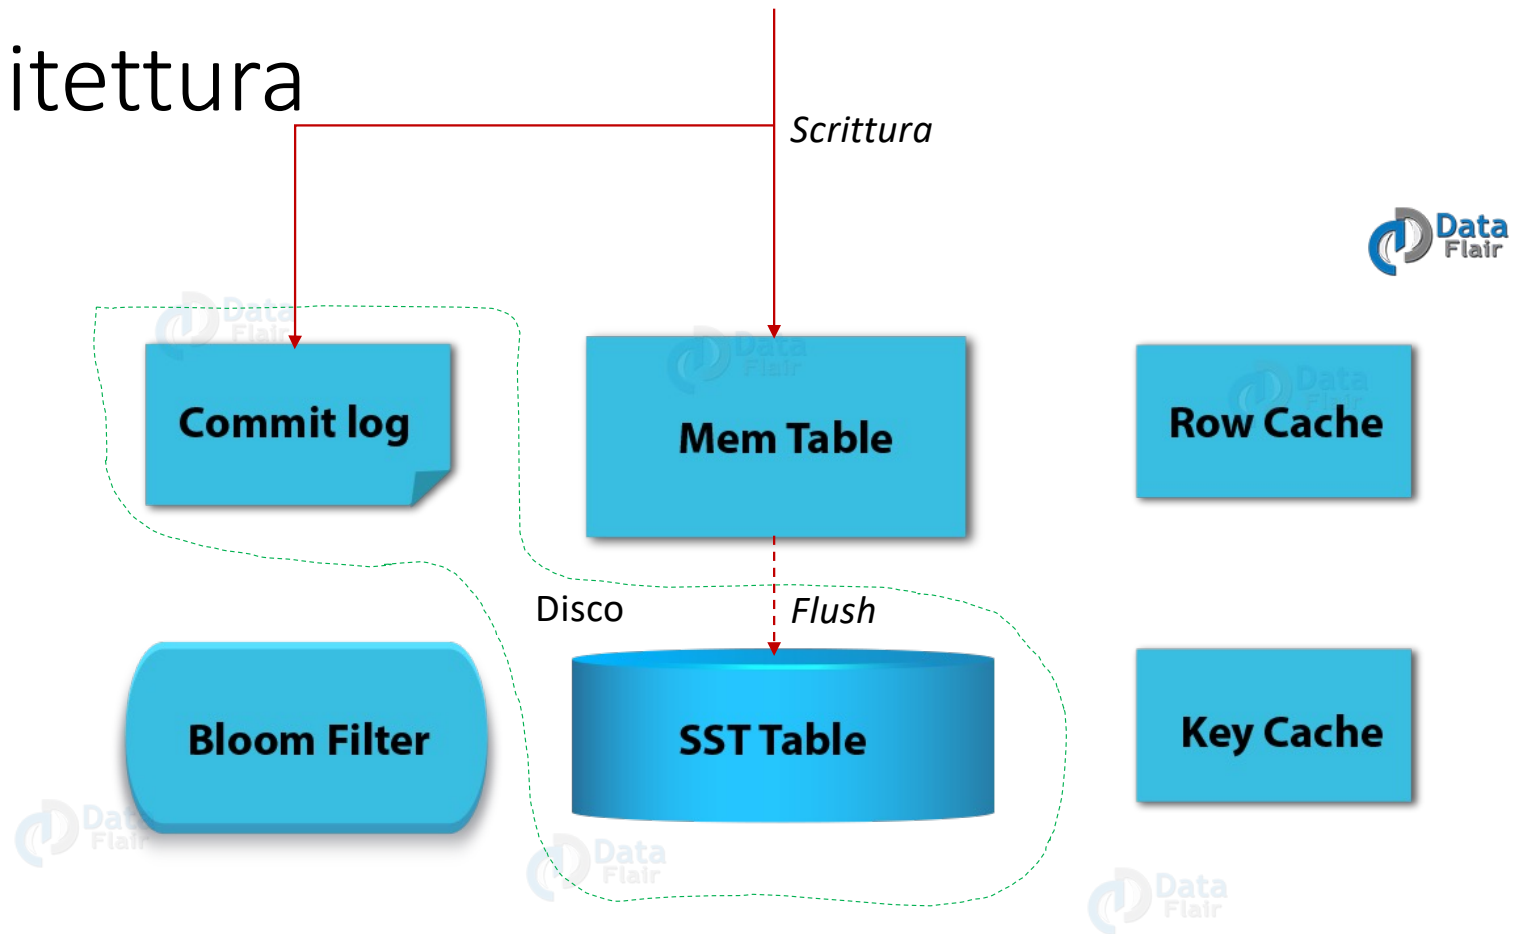
# Architettura

- Strategie di replicazione

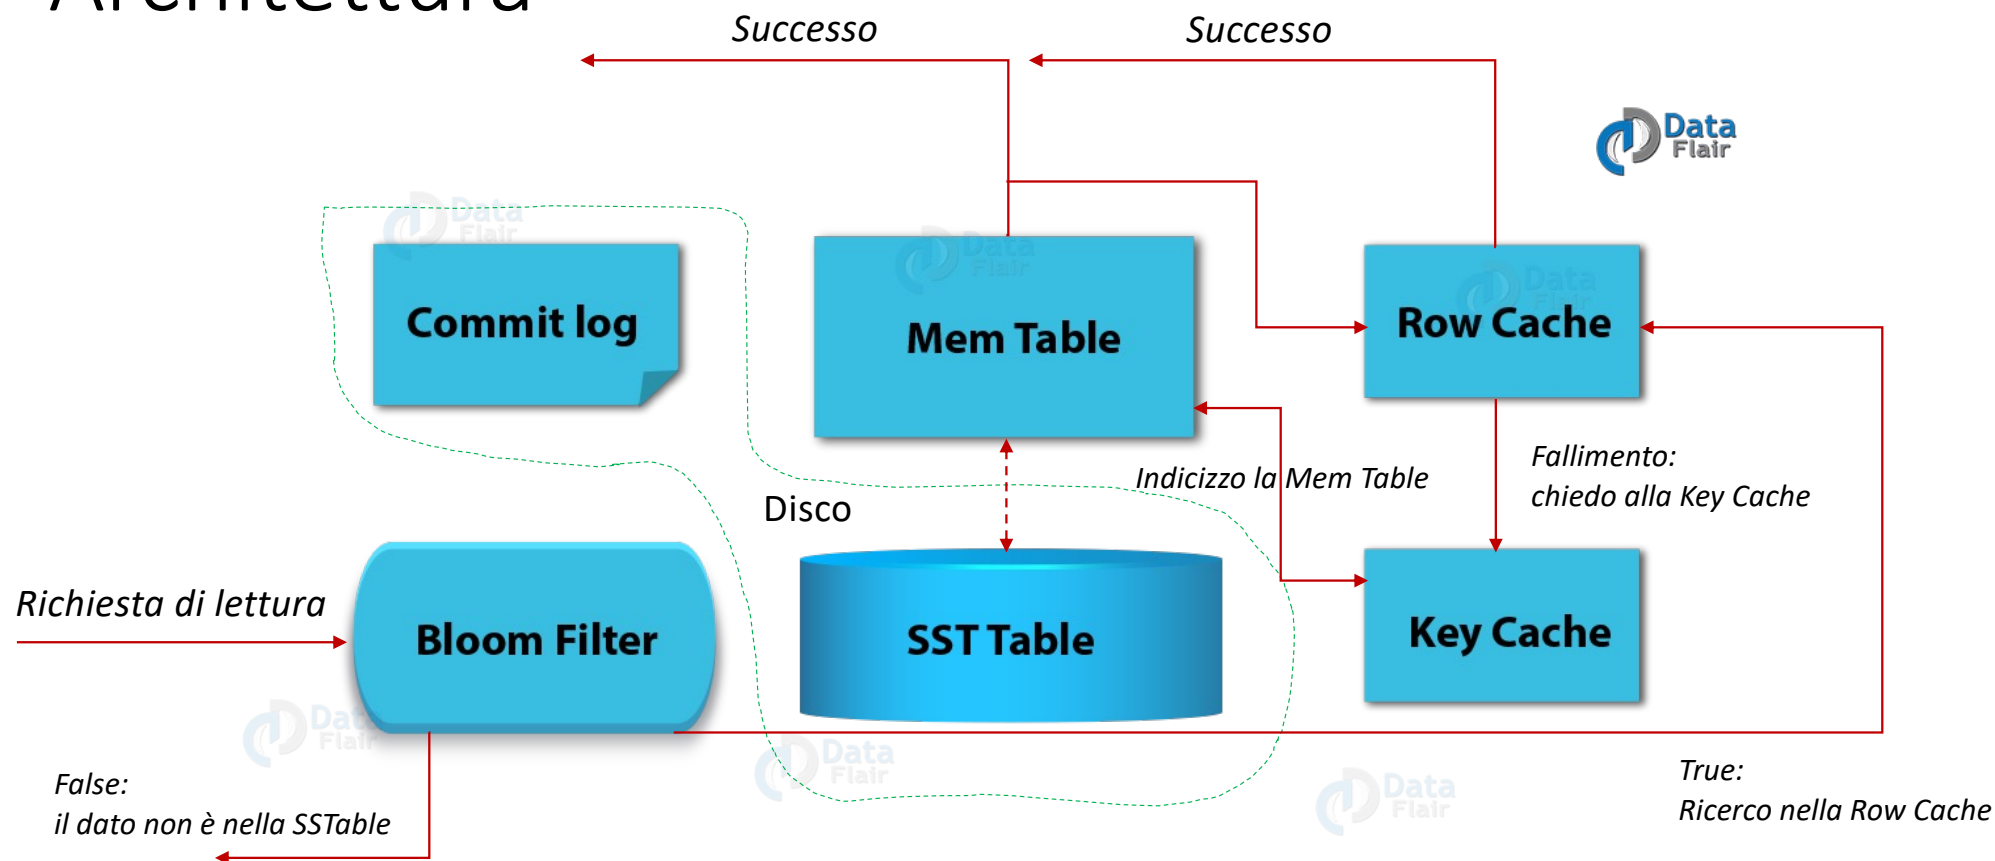
- Replication factor standard pari a 3
- Simple Strategy
- Network Topology



# Architettura




# Architettura



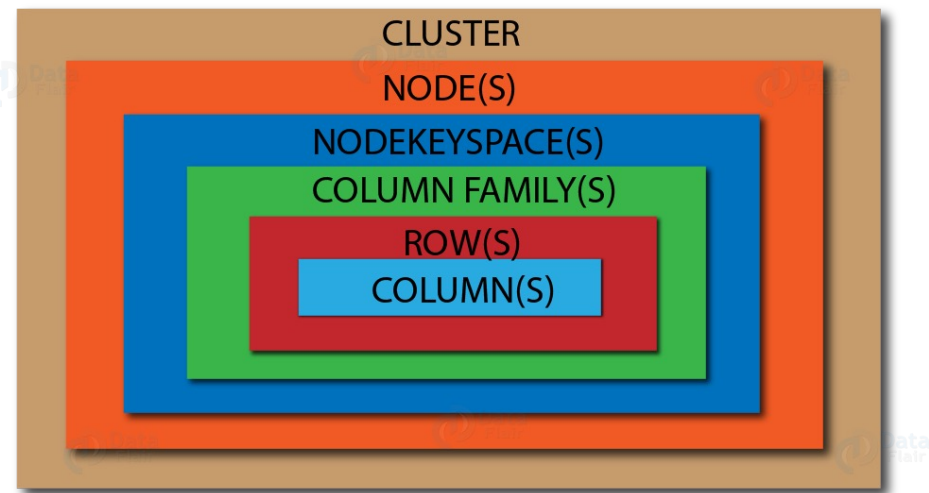
# Modello dei dati

- Key space
  - Può essercene più di uno per nodo
  - E' equivalente al concetto di database
  - E' la struttura di storage più esterna



# Modello dei dati


- Column family
  - La suddivisione del key space
  - Possono essere assimilate a tabelle
    - Si accedono come tabelle in CQL





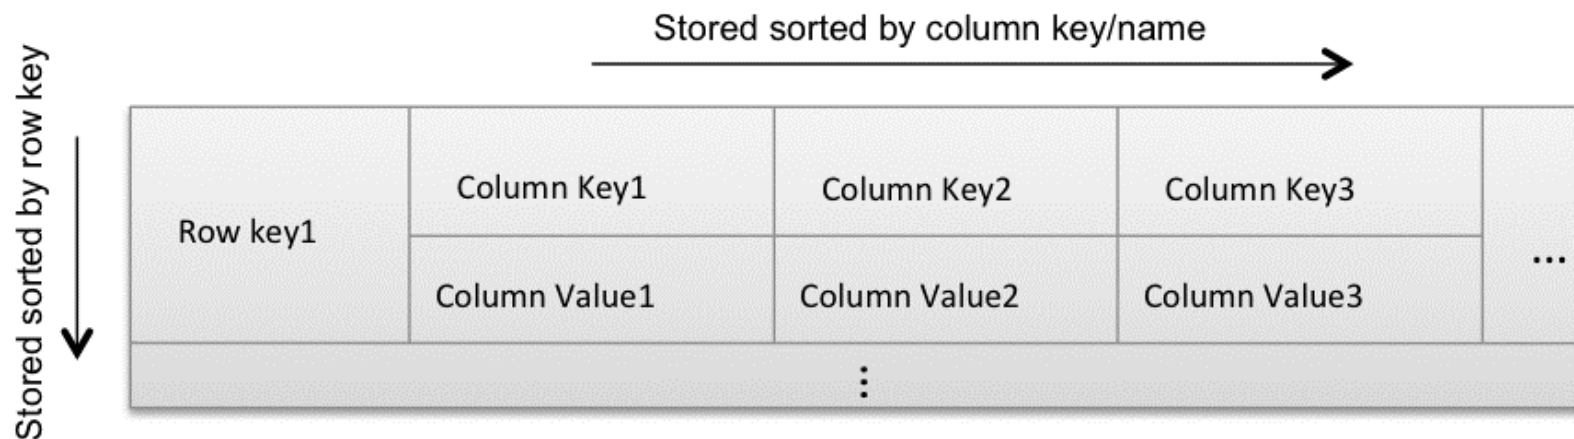
# Modello dei dati

- Rapporto tra Key space, righe e colonne



# Modello dei dati

- Righe e colonne



# Modello dei dati

Relational Model	Cassandra Model
Database	Keyspace
Table	Column Family (CF)
Primary key	Row key
Column name	Column name/key
Column value	Column value