Università degli Studi di Palermo

dipartimento di ingegneria unipa

Classificatori

CORSO DI BIG DATA – MODULO MACHINE LEARNING PER I BIG DATA

a.a. 2024/2025

Prof. Roberto Pirrone

LABORATORIO DI INTERAZIONE UOMO-MACCHINA
CHILAB

Sommario

- Generalità
- Selezione delle feature
- Decision Tree
- Classificatori probabilistici
  - Regressione logistica
  - Naive Bayes
- Instance based learning
- Support Vector Machine
- Classificazione multiclasse
- Rare class learning
- Regressione per dati numerici
- Metodi di ensemble
  - Random Forests
  - AdaBoost
  - Gradient boosting
  - XGBoost
- Valutazione della bontà della classificazione

Generalità

- Dato un insieme di dati di addestramento, ciascuno associato ad una «etichetta» che individua l'appartenenza del dato ad una classe, *la classificazione consiste nel predire il valore dell'etichetta per dati di test mai visti dall'algoritmo*

- È una classe di algoritmi di apprendimento supervisionati
  - Le etichette provengono da una associazione artificiale (dipendente dall'applicazione) ai dati e non dalla naturale tendenza di questi ultimi a formare cluster
  - È, forse, la tipologia di algoritmo di ML più comune

Generalità

- In generale, dato un insieme di *n* punti in $\mathbb{R}^d$ appartenenti ad un data set $\mathcal{D}$, questi vengono associati ad un insieme di etichette in {1, …, *k*}
  - Spesso la classificazione è binaria: {0, 1} ovvero {-1, 1}
- Due modalità di funzionamento
  - Predizione esplicita dell'etichetta
  - Score numerico (probabilità) di appartenenza del punto ad una certa classe

Selezione delle feature

- Filtri: indicatori numerici della rilevanza delle feature

- Modelli «wrapped»:
  - un algoritmo di classificazione viene usato per valutare la performance su un sotto-insieme di feature e quindi «avvolge» il vero e proprio algoritmo di classificazione in uno schema di ricerca delle feature rilevanti

- Modelli «embedded»:
  - l'algoritmo stesso fornisce indicazioni sulle feature rilevanti e, dopo averle individuate, viene riaddestrato solo su di esse

Selezione delle feature

- Filtri
  - Usati per dati categorici
  - Gini index

Valore i-esimo dell'attributo categorico a *r* valori

Frazione dei punti che hanno il valore v_i nella classe *j*

$$G(v_i) = 1 - \sum_{j=1}^{k} p_j^2$$

$G(v_i) = 0$ se tutti i valori v_i appartengono alla stessa classe

$$G = \sum_{i=1}^{r} n_i G(v_i) / n$$

Frazione dei punti che hanno il valore v_i

Selezione delle feature

- Filtri
  - Usati per dati categorici
  - Entropia

Frazione dei punti che hanno il valore v_i nella classe j

$$E\left(v_i\right) = -\sum_{j=1}^{k} p_j \log_2\left(p_j\right), \quad E = \sum_{i=1}^{r} n_i E\left(v_i\right)/n$$

$E(v_i) = \log_2(k)$ se i valori v_i sono uniformemente distribuiti tra le classi

Selezione delle feature

Separazione media «inter-classe»

- Filtri
  - Fisher score
  - Usato per attributi numerici
  - Per ogni feature:

$$F = \frac{\sum_{j=1}^{k} p_j \left(\mu_j - \mu\right)^2}{\sum_{j=1}^{k} p_j \sigma_j^2}$$

Separazione media «intra-classe»

    - p_j → frazione dei campioni appartenete alla classe *j*
    - μ_j → media dell'attributo nella classe *j*
    - μ → media totale dell'attributo nel data set
    - σ_j → dev. standard dell'attributo nella classe *j*

Selezione delle feature

- Filtri
  - Fisher Linear Discriminant
    - Generalizzazione del Fisher Score per combinazioni lineari di feature numeriche
    - Tende a trovare, in forma supervisionata, la direzione di massima variazione delle feature e, per contro, l'iperpiano perpendicolare che separa meglio le classi rispetto alle feature
    - Il rapporto *Inter-class/Intra-class* tende ad essere massimizzato

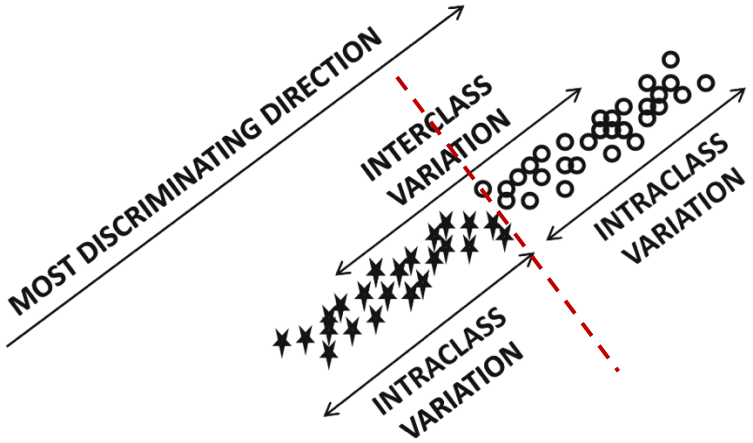

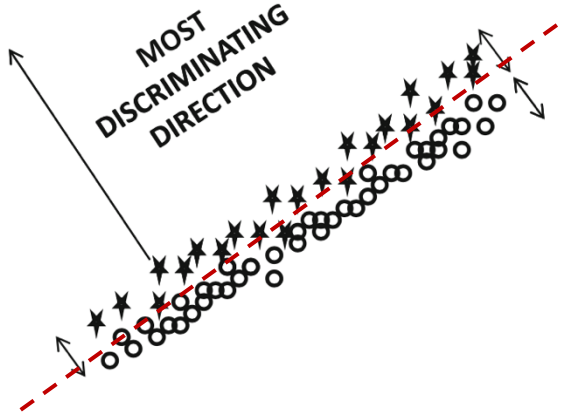

Selezione delle feature

- Filtri
  - Fisher Linear Discriminant: caso binario
  - Troviamo la direzione lungo la quale le *proiezioni* dei punti del data set risultano *massimamente separati* rispetto alle due classi

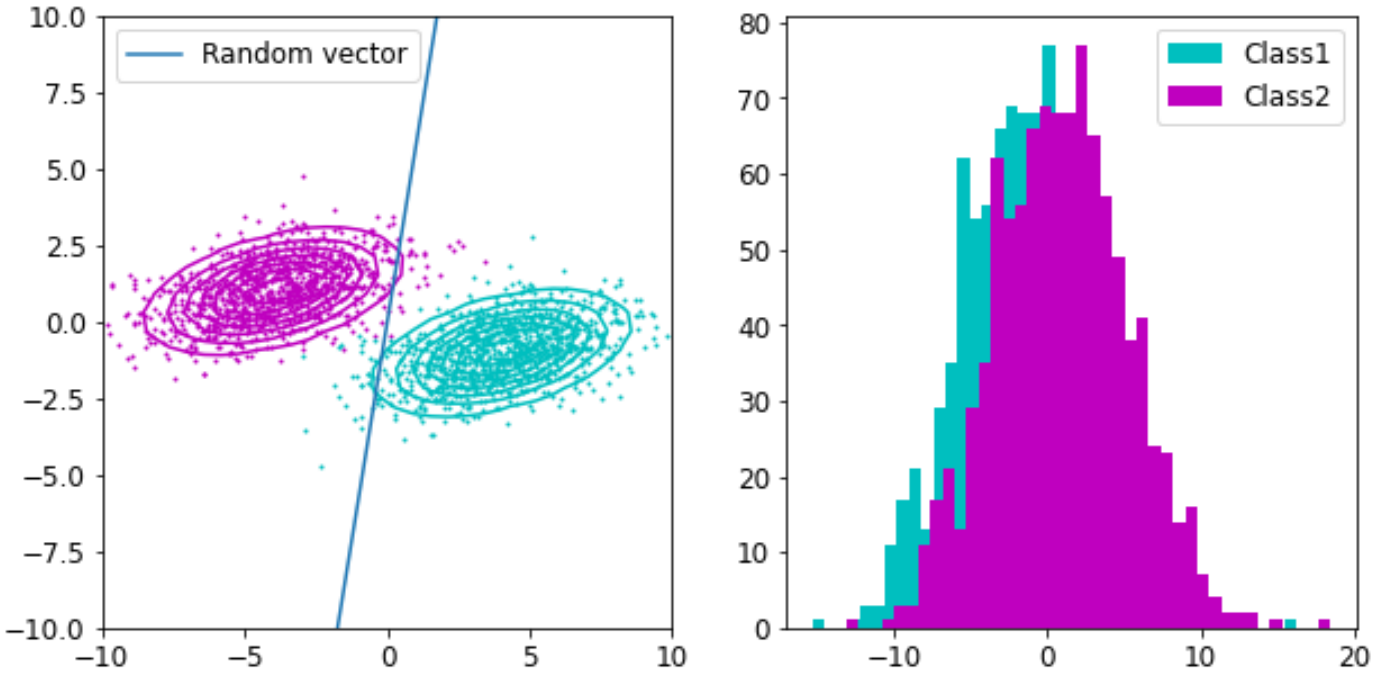

https://bit.ly/3y92WUJ

Selezione delle feature

- Filtri
  - Fisher Linear Discriminant: caso binario
  - Troviamo la direzione ***w*** lungo la quale massimizziamo le *proiezioni dei punti medi* di ciascuna classe
  - Bene, ma non benissimo: perché? → *Dobbiamo tenere conto della varianza dei dati proiettati lungo **w**!!*

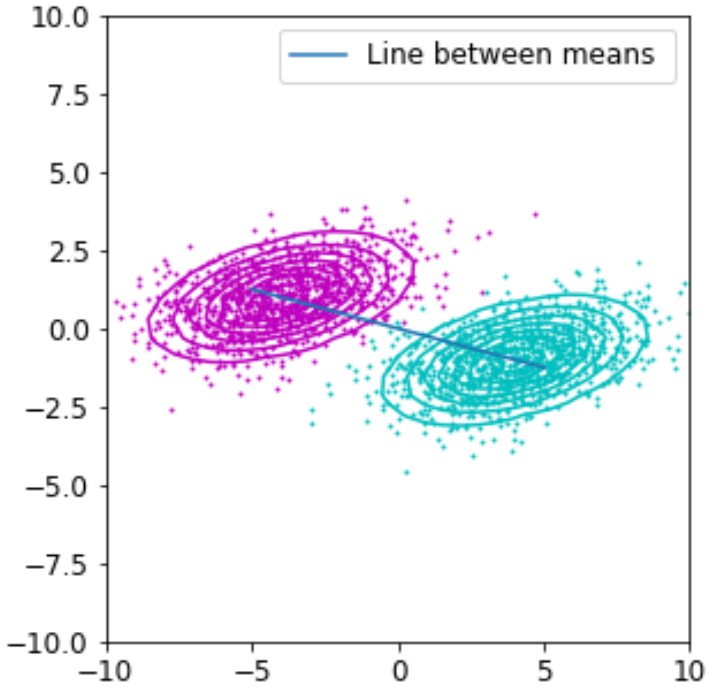

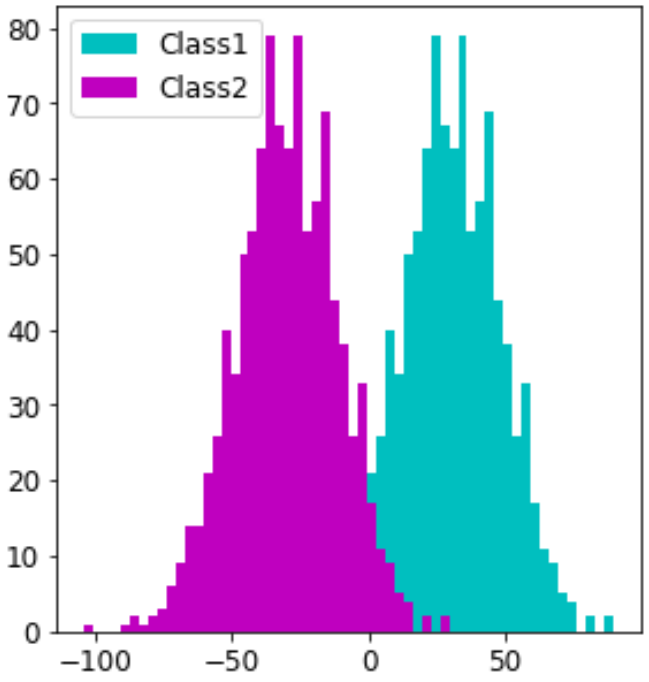

https://bit.ly/3y92WUJ

Selezione delle feature

- Filtri
  - Fisher Linear Discriminant: caso binario
  - Tenendo conto delle varianze intra-classe s_1 e s_2 troviamo la direzione lungo la quale massimizziamo la *separazione dei punti* di ciascuna classe
  - Massimizziamo una funzione obiettivo analoga al rapporto *Inter/Intra* lungo la direzione ***w***

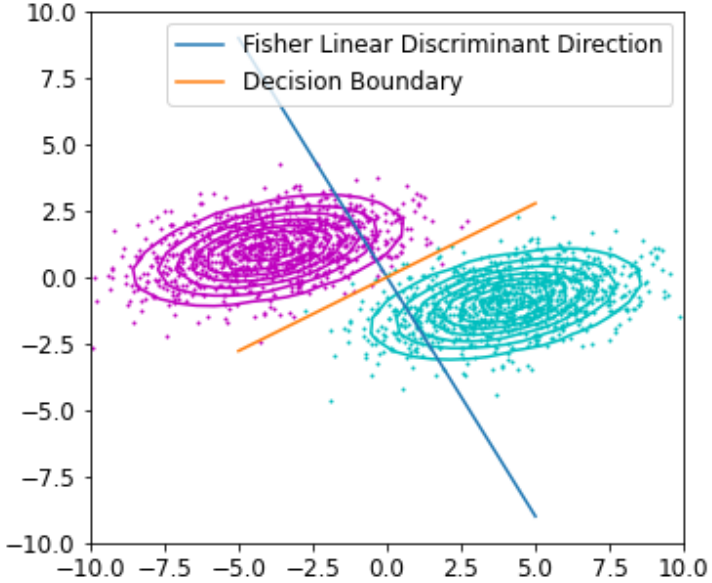

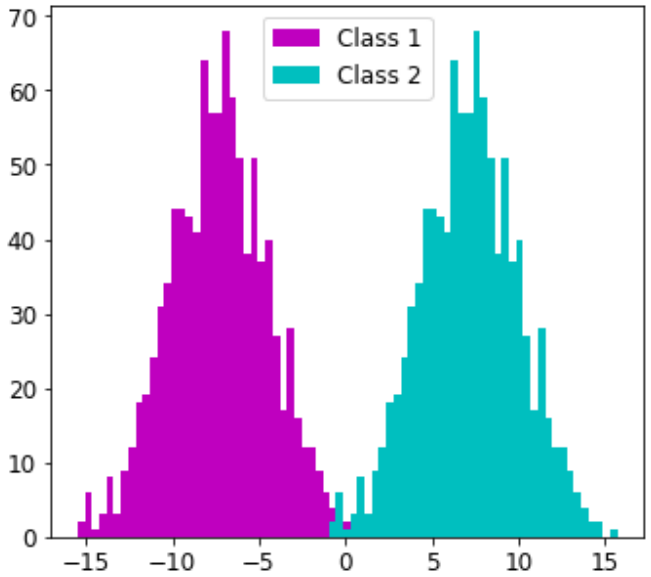

Selezione delle feature

- Filtri
  - Fisher Linear Discriminant: caso binario

$$J(\boldsymbol{w}) = \frac{(m_1 - m_2)^2}{s_1^2 + s_2^2}$$

  - Troviamo la proiezione $y = \boldsymbol{w}^T \cdot \boldsymbol{x}$ in modo tale che si massimizzi la funzione obiettivo

$$m_k = \boldsymbol{w}^T \boldsymbol{m}_k = \boldsymbol{w}^T \left(\frac{1}{N_k} \sum_{n \in C_k} \boldsymbol{x}_n \right), \quad k = 1, 2$$

$$s_k^2 = \sum_{n \in C_k} (y_n - m_k)^2 = \sum_{n \in C_k} \left(\boldsymbol{w}^T \boldsymbol{x}_n - m_k \right)^2 \quad k = 1, 2$$

Selezione delle feature

- Filtri
  - Fisher Linear Discriminant: caso binario

$$J(\boldsymbol{w}) = \frac{(m_1 - m_2)^2}{s_1^2 + s_2^2} = \frac{\boldsymbol{w}^T S_B \boldsymbol{w}}{\boldsymbol{w}^T S_W \boldsymbol{w}}$$

  - Andando a sostituire otteniamo

$$S_B = (\boldsymbol{m_2} - \boldsymbol{m_1})(\boldsymbol{m_2} - \boldsymbol{m_1})^T$$

$$S_W = \sum_{n \in C_1} (\boldsymbol{x}_n - \boldsymbol{m}_1)(\boldsymbol{x}_n - \boldsymbol{m}_1)^T + \sum_{n \in C_2} (\boldsymbol{x}_n - \boldsymbol{m}_2)(\boldsymbol{x}_n - \boldsymbol{m}_2)^T$$

Scatter matrices (W)ithin e (B)etween classes

Selezione delle feature

- Filtri
  - Fisher Linear Discriminant:
    caso binario
  - Soluzione ponendo $\partial J/\partial \boldsymbol{w} = 0$

$$\boldsymbol{w}^* \propto S_W^{-1}\left(\boldsymbol{m}_2 - \boldsymbol{m}_1\right)$$

Selezione delle feature

- Filtri
  - Fisher Linear Discriminant: caso multiclasse

$$S_W = \sum_{i=1}^{C} S_i, \;\; S_i = \sum_{i \in C_i} (\boldsymbol{x}_i - \boldsymbol{m}_i)(\boldsymbol{x}_i - \boldsymbol{m}_i)^T, \;\; \boldsymbol{m}_i = \frac{1}{N_i} \sum_{i \in C_i} \boldsymbol{x}_i$$

  - Trovare una matrice $\mathbf{W} = [\boldsymbol{w}_1 \mid \boldsymbol{w}_2 \mid \ldots \mid \boldsymbol{w}_{C-1}]$ tale che i $\boldsymbol{w}_i$ separino massimamente le coppie di classi

$$S_B = \sum_{i=1}^{C} N_i (\boldsymbol{m}_i - \boldsymbol{m})(\boldsymbol{m}_i - \boldsymbol{m})^T, \;\; \boldsymbol{m} = \frac{1}{N} \sum_{i=1}^{N} \boldsymbol{x}_i$$

  - Le matrici di scatter sono definite diversamente

Selezione delle feature

- Filtri
  - Fisher Linear Discriminant: caso multiclasse

$$J(\boldsymbol{W}) = \frac{\left|\boldsymbol{W}^T S_B \boldsymbol{W}\right|}{\left|\boldsymbol{W}^T S_W \boldsymbol{W}\right|}$$

  - La nuova funzione obiettivo è

$$\begin{aligned}\frac{\boldsymbol{W}^T S_B \boldsymbol{W}}{\boldsymbol{W}^T S_W \boldsymbol{W}} &= \left(\boldsymbol{W}^T S_W \boldsymbol{W}\right)^{-1} \left(\boldsymbol{W}^T S_B \boldsymbol{W}\right) = \\ &= \boldsymbol{W}^{-1} S_W^{-1} \left(\boldsymbol{W}^T\right)^{-1} \boldsymbol{W}^T S_B \boldsymbol{W} = \\ &= \boldsymbol{W}^{-1} S_W^{-1} S_B \boldsymbol{W}\end{aligned}$$

Problema agli autovalori!!!

https://bit.ly/3y92WUJ

Selezione delle feature

- Filtri
  - Fisher Linear Discriminant: caso multiclasse
  - La nuova funzione obiettivo è

$$J(\boldsymbol{W}) = \frac{\left|\boldsymbol{W}^T S_B \boldsymbol{W}\right|}{\left|\boldsymbol{W}^T S_W \boldsymbol{W}\right|}$$

  - La matrice soluzione ***W**** è la matrice degli autovettori di $S_W^{-1} S_B$

$$\boldsymbol{W}^* = \mathrm{argmax}_{\boldsymbol{W}} \left|\boldsymbol{W}^{-1} S_W^{-1} S_B \boldsymbol{W}\right|$$

Selezione delle feature

- Modelli «wrapped»
  - Si parte da un insieme di feature $F = \{\}$
  - Si aggiungono feature a F e si testa l'accuratezza di un algoritmo di classificazione $\mathcal{A}$ per accettare l'aggiunta delle nuova feature a F
  - L'incremento di F si può fare secondo diverse strategie
    - Random
    - Aggiunta della feature con maggior potere discriminativo rispetto ad un criterio di filtro

Decision Tree

- Il data set viene suddiviso ricorsivamente in parti più piccole sulla base del discrimine sui valori degli attributi

- I nodi foglia dell'albero vengono attribuiti alla classe dominante
  - Gerarchico similmente al clustering
  - Split univariato → decisione su un solo attributo
  - Split multivariato → decisione su un insieme di attributi

Decision tree

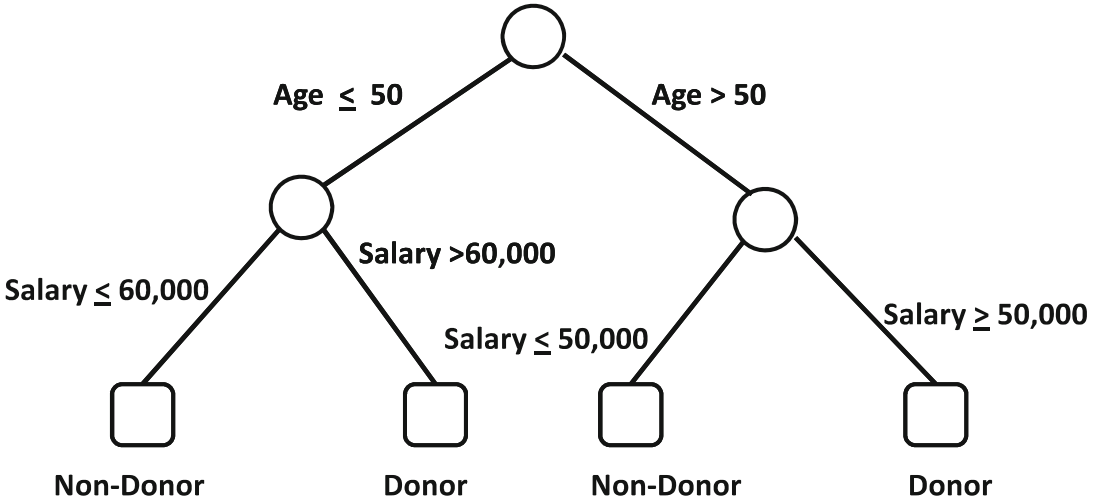

Name	Donor?
Nancy	N
Jim	N
Jane	N
Steve	N

Name	Donor?
Allen	Y

Name	Donor?
Mary	N

Name	Donor?
Peter	Y
Sayani	Y
Lata	Y
Victor	Y
Dale	Y

(a) Univariate split

Decision tree

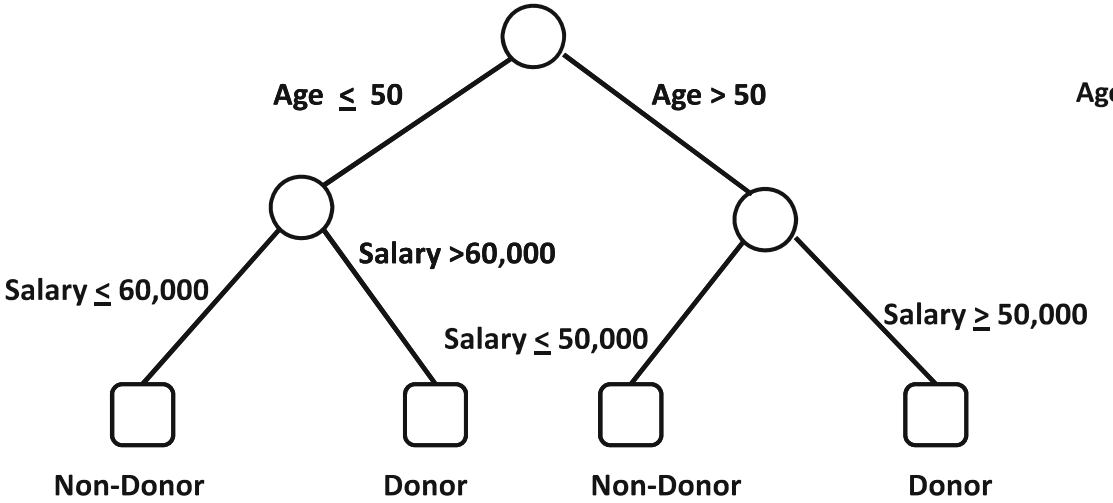

Name	Donor?
Nancy	N
Jim	N
Jane	N
Steve	N

Name	Donor?
Allen	Y

Name	Donor?
Mary	N

Name	Donor?
Peter	Y
Sayani	Y
Lata	Y
Victor	Y
Dale	Y

(a) Univariate split

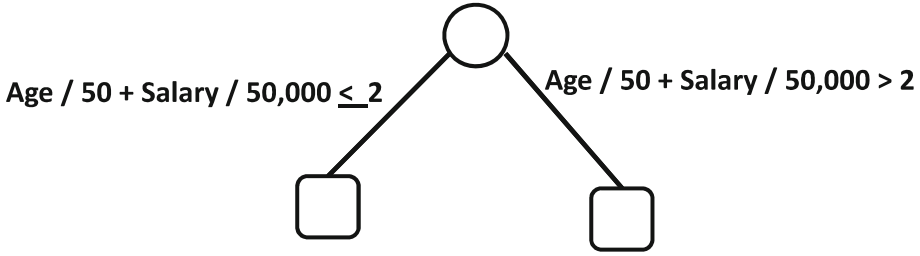

Name	Donor?
Nancy	N
Jim	N
Jane	N
Steve	N
Mary	N

Name	Donor?
Allen	Y
Peter	Y
Sayani	Y
Lata	Y
Victor	Y
Dale	Y

(b) Multivariate split

Decision tree

Algorithm *GenericDecisionTree*(Data Set: $\mathcal{D}$)
begin
  Create root node containing $\mathcal{D}$;
  repeat
    Select an eligible node in the tree;
    Split the selected node into two or more nodes
      based on a pre-defined split criterion;
  until no more eligible nodes for split;
  Prune overfitting nodes from tree;
  Label each leaf node with its dominant class;
end

- Split binario
- Split a *r* vie per attributi categorici o per attributi numerici con piccolo range di variazione
- Split binario per attributi categorici binarizzati
- Split a soglia per attributi numerici

Decision tree

Algorithm *GenericDecisionTree*(Data Set: $\mathcal{D}$)
begin
  Create root node containing $\mathcal{D}$;
  repeat
    Select an eligible node in the tree;
    Split the selected node into two or more nodes
      based on a pre-defined split criterion;
  until no more eligible nodes for split;
  Prune overfitting nodes from tree;
  Label each leaf node with its dominant class;
end

- Error rate: la frazione di elementi che ***non*** appartengono alla classe dominante
- Gini index
- Entropia

$$G(S) = 1 - \sum_{j=1}^{k} p_j^2, \quad \text{Gini-Split}\ (S \Rightarrow S_1 \ldots S_r) = \sum_{i=1}^{r} \frac{|S_i|}{|S|} G(S_i)$$

Suddivisione del data set in *r* sottoinsiemi per uno split a *r* vie → *si sceglie lo split con Error rate, Gini index o Entropia più bassa*

$$E(S) = -\sum_{j=1}^{k} p_j \log_2(p_j), \quad \text{Entropy-Split}\ (S \Rightarrow S_1 \ldots S_r) = \sum_{i=1}^{r} \frac{|S_i|}{|S|} E(S_i)$$

Decision Tree

- In genere i nodi vicini ai nodi foglia lavorano su pochi dati e sono proni al rumore nell'applicare lo split
  - Tendenza ad esibire overfitting
  - Si utilizzano tecniche di stop che prediligono alberi poco profondi
- Si utilizzano tecniche di pruning dei nodi foglia che vanno in overfit
  - Si valida l'eventuale incremento dell'accuracy su un validation set espunto dai dati di addestramento

Classificatori probabilistici

- L'appartenenza di un campione ad una classe è espressa in termini di una probabilità

- (Naive) Bayes Classifier

  - Si usa il Teorema di Bayes per stimare la probabilità di classe dall'evidenza delle feature *che si suppongono categoriche*

  - Il campione **x** è espresso come *d* variabili statistiche: $\{x_1 = a_1, x_2 = a_2, \ldots, x_d = a_d\}$

Classificatori probabilistici

- L'appartenenza di un campione ad una classe è espressa in termini di una probabilità

- (Naive) Bayes Classifier
  - Il modello è una mistura di distribuzioni di natura generativa analogamente al clustering
  - L'ipotesi «naive» è quella dell'indipendenza statistica delle feature che consente il calcolo della probabilità di un campione come produttoria delle probabilità delle singole feature

Classificatori probabilistici

- L'appartenenza di un campione ad una classe è espressa in termini di una probabilità

- Regressione logistica
  - E' un modello discriminativo tra due classi
  - La probabilità della variabile di classe è una distribuzione di Bernoulli parametrizzata in termini delle feature
  - Si cercherà così l'iperpiano di separazione tra le due classi

Naive Bayes

La probabilità di classe si ottiene dal Teorema di Bayes massimizzando la likelihood degli attributi condizionati alla classe

$$P\left(C=c|x_1=a_1,\ldots x_d=a_d\right)=\frac{P(C=c)P\left(x_1=a_1,\ldots x_d=a_d|C=c\right)}{P\left(x_1=a_1,\ldots x_d=a_d\right)}$$

$$\propto P(C=c)P\left(x_1=a_1,\ldots x_d=a_d|C=c\right)$$

Distribuzione di Bernoulli o Multinomiale *su ogni singolo attributo*

$$P\left(x_1=a_1,\ldots x_d=a_d|C=c\right)=\prod_{j=1} P\left(x_j=a_j|C=c\right)$$

Assunzione «naive» ovvero di indipendenza statistica degli attributi

Naive Bayes

$$P\left(C=c|x_1=a_1,\ldots x_d=a_d\right) \propto P(C=c)\prod_{j=1}^{d} P\left(x_j=a_j|C=c\right)$$

Il Teorema di Bayes fornisce questa forma

$$P\left(x_j=a_j|C=c\right)=\frac{q\left(a_j,c\right)}{r(c)}$$

Stima maximum likelihood delle probabilità dei singoli attributi

$$P\left(x_j=a_j|C=c\right)=\frac{q\left(a_j,c\right)+\alpha}{r(c)+\alpha\cdot m_j}$$

Frazione dei campioni che hanno attributo a_j e classe c

Frazione dei campioni in classe c

Laplacian smoothing: m_j è il numero di valori distinti di a_j

La probabilità tende a $1/m_j$ se $r(c)=0$

Per attributi numerici si può discretizzare ovvero pensare a $P(C = c|x_1 = a_1, \ldots , x_n = a_n)$ come a una mistura di componenti in cui le componenti delle feature numeriche sono gaussiane

Regressione logistica

- La regressione logistica prende il nome dalla funzione di discrimine della probabilità di appartenenza del campione ad una di due classi individuate come {+1, -1}.

- Il modello dipende da d + 1 parametri θ_i che individuano la separazione tra le classi lungo ogni dimensione del campione

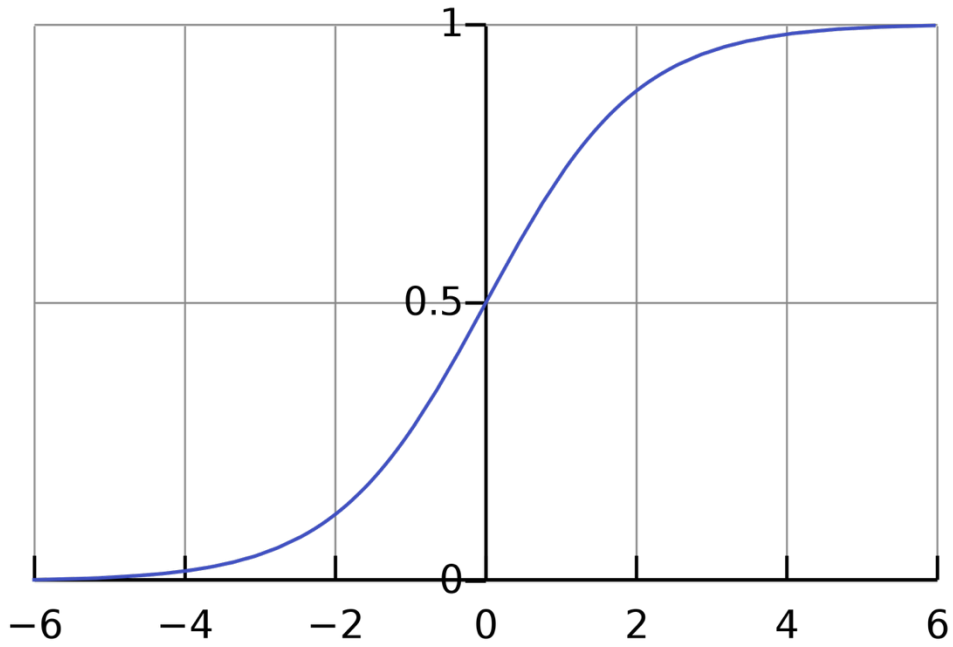

$$\sigma(x) = \frac{1}{1 + e^{-x}} = \frac{e^x}{1 + e^x}$$

Funzione logistica o sigmoide

$$P(C = +1|\bar{X}) = \frac{1}{1 + e^{-\left(\theta_0 + \sum_{i=1}^{d} \theta_i x_i\right)}}$$

$$P(C = -1|\bar{X}) = \frac{1}{1 + e^{\left(\theta_0 + \sum_{i=1}^{d} \theta_i x_i\right)}}$$

Regressione logistica

- La regressione logistica è un «modello lineare» perché individua l'iperpiano di separazione tra le due classi in termini del luogo dei punti equiprobabili rispetto all'appartenenza ed una delle due classi

$P(C = +1) \equiv P(C = -1) = 0.5 \rightarrow \theta_0 + \sum_{i=1}^{d} \theta_i x_i = 0$

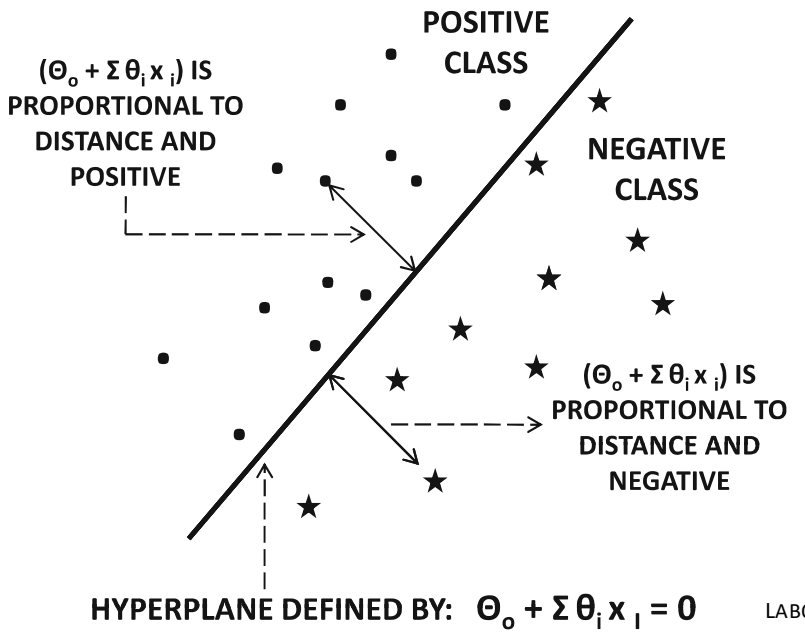

Regressione logistica

Addestramento tramite massimizzazione della likelihood del data set

$$\mathcal{L}(\bar{\Theta}) = \prod_{\overline{X_k} \in \mathcal{D}_+} \frac{1}{1 + e^{-\left(\theta_0 + \sum_{i=1}^{d} \theta_i x_k^i\right)}} \prod_{X_k \in \mathcal{D}_-} \frac{1}{1 + e^{\left(\theta_0 + \sum_{i=1}^{d} \theta_i x_k^i\right)}}$$

Si passa, poi, alla log-likelihood

$$\mathcal{LL}(\bar{\Theta}) = \log(\mathcal{L}(\bar{\Theta})) = -\sum_{\overline{X_k} \in \mathcal{D}_+} \log\left(1 + e^{-\left(\theta_0 + \sum_{i=1}^{d} \theta_i x_k^i\right)}\right) - \sum_{\overline{X_k} \in \mathcal{D}_-} \log\left(1 + e^{\left(\theta_0 + \sum_{i=1}^{d} \theta_i x_k^i\right)}\right)$$

Regressione logistica

La massimizzazione si ottiene ponendo la derivata della log-likelihood rispetto ai parametri pari a 0

$$\frac{\partial \mathcal{LL}(\bar{\Theta})}{\partial \theta_i} = \sum_{\bar{X}_k \in \mathcal{D}_+} \frac{x_k^i}{1 + e^{\left(\theta_0 + \sum_{i=1}^d \theta_i x_i\right)}} - \sum_{\bar{X}_k \in \mathcal{D}_-} \frac{x_k^i}{1 + e^{-\left(\theta_0 + \sum_{i=1}^d \theta_i x_i\right)}}$$

$$= \sum_{\bar{X}_k \in \mathcal{D}_+} P\left(\overline{X_k} \in \mathcal{D}_-\right) x_k^i - \sum_{\bar{X}_k \in \mathcal{D}_-} P\left(\overline{X_k} \in \mathcal{D}_+\right) x_k^i$$

$$\theta_i \leftarrow \theta_i + \alpha \left(\sum_{\overline{X_k} \in \mathcal{D}_+} P\left(\overline{X_k} \in \mathcal{D}_-\right) x_k^i - \sum_{\overline{X_k} \in \mathcal{D}_-} P\left(\overline{X_k} \in \mathcal{D}_+\right) x_k^i \right)$$

Si massimizza tramite gradient ascent e, in genere, anche regolarizzazione: $-\lambda \sum_{i=1}^{d} \theta_i^2 / 2$

Instance based learning

- L'idea su cui si basano questi classificatori è

  «Campioni simili hanno etichetta di classe simile»

- Sono dei «lazy learners»:
  - Il modello addestrato viene costruito solo *alla fine* dell'osservazione di tutti i dati

Instance based learning

- Classificatore k-NN
  - Il classificatore osserva i *k* elementi più vicini al campione ed attribuisce la classe dominante tra questi
  - Si può pensare di pesare il contributo dei vicini rispetto alla loro distanza δ dal campione, per esempio $f(\delta) = e^{-\frac{\delta^2}{t^2}}$
  - *k* e *t* sono iperparametri e la loro scelta è cruciale

Instance based learning

- Classificatore k-NN
  - In generale si userà una distanza nella forma:

$$\mathrm{Dist}(\bar{X},\bar{Y}) = \sqrt{(\bar{X}-\bar{Y})A(\bar{X}-\bar{Y})^T}$$

  - $A = \Sigma^{-1}$ implica la distanza di Mahalanobis
  - *Ma è la scelta migliore?*

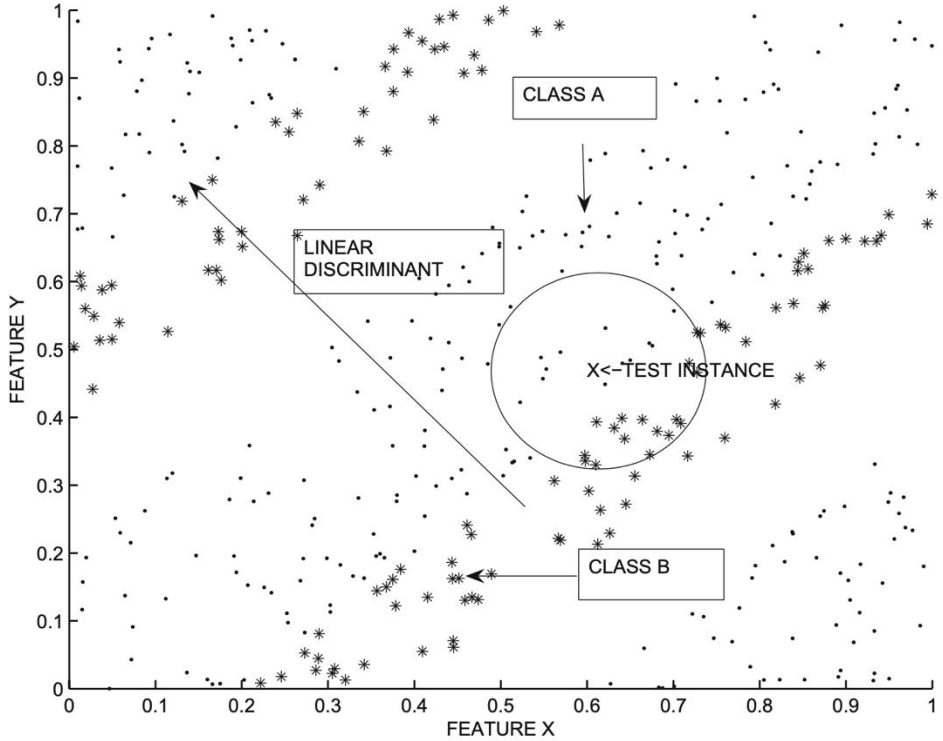

Instance based learning

- Classificatore k-NN
  - Si possono proiettare le distanze lungo le direzioni di massima variazione tra le diverse classi
  - $A = S_B/S_W$ ovvero il rapporto tra le matrici di *inter class scatter* e *intra class scatter* determinate con la Fisher LDA

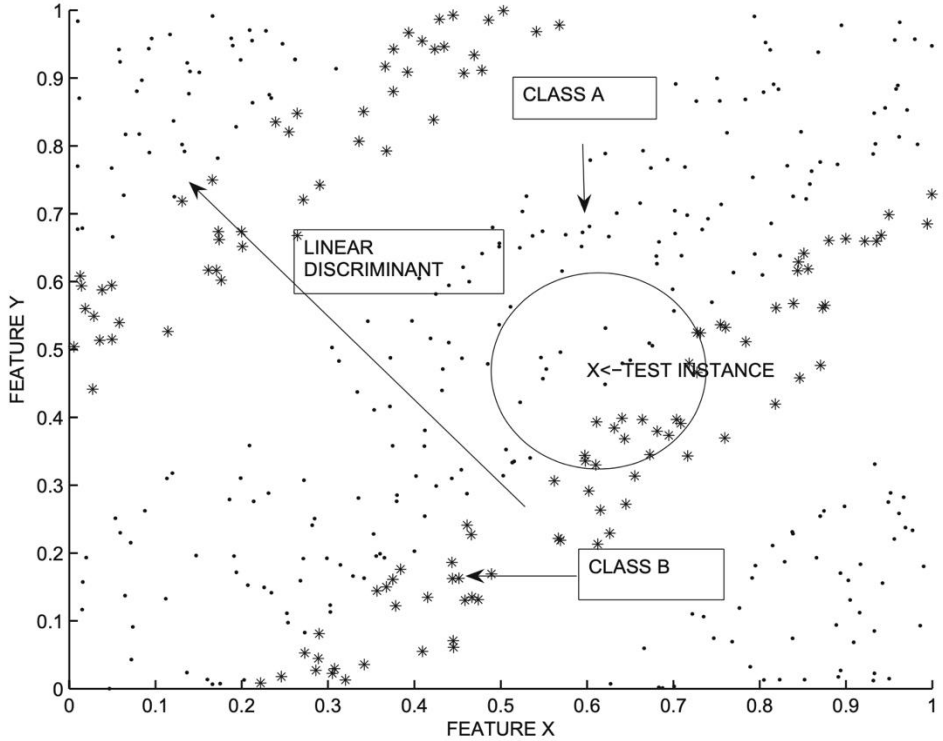

Support Vector Machines

- Classificatore *lineare* per problemi di *classificazione binaria*

- Il modello ricerca l'*iperpiano a massimo margine* che separa le due classi

  - *Massimo margine*: la massima distanza tra due iperpiani paralleli che contengono alcune istanze di entrambe le classi dette support vector

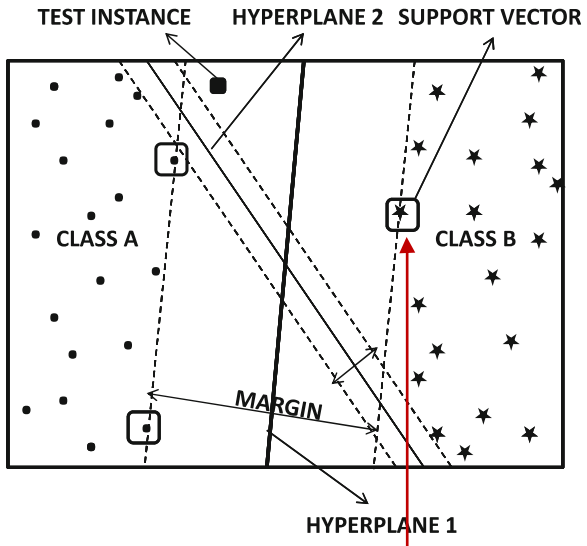

Support Vector Machines

Le equazioni dei due iperpiani che limitano il margine si possono scrivere in termini dei coefficienti *W* e dell'intercetta *b*:

$$\overline{W} \cdot \overline{X_i} + b \geq 0 \quad \forall i : y_i = +1$$

$$\overline{W} \cdot \overline{X_i} + b \leq 0 \quad \forall i : y_i = -1$$

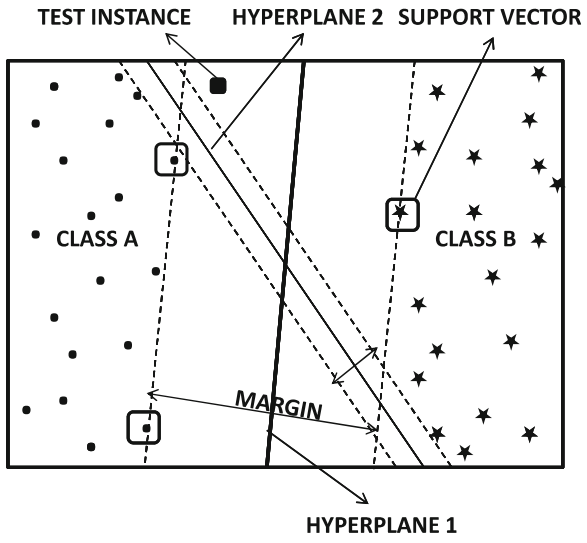

Con un apposito scaling di $\overline{W}$ e b :

$$\begin{cases} \overline{W} \cdot \overline{X_i} + b \geq +1 \forall i : y_i = +1 \\ \overline{W} \cdot \overline{X_i} + b \leq -1 \forall i : y_i = -1 \end{cases} \Rightarrow y_i(\overline{W} \cdot \overline{X_i} + b) \geq +1, \forall i$$

Support Vector Machines

Un po' di ripasso di algebra.

Calcoliamo la distanza $d(\pi_1, \pi_2)$ tra due piani paralleli
$\pi_1 = ax + by + cz + h$ e $\pi_2 = ax + by + cz + k$

La normale comune ai due piani è data dai coefficienti direttori:
$\mathbf{n} = \{a, b, c\}$

$d(\pi_1, \pi_2) \equiv d(P, \pi_2)$, $P \in \pi_1$ posto lungo la direzione di $\mathbf{n}$

$d(P, \pi_2) = |ax + by + cz + k| \,/\, ||\mathbf{n}||$.

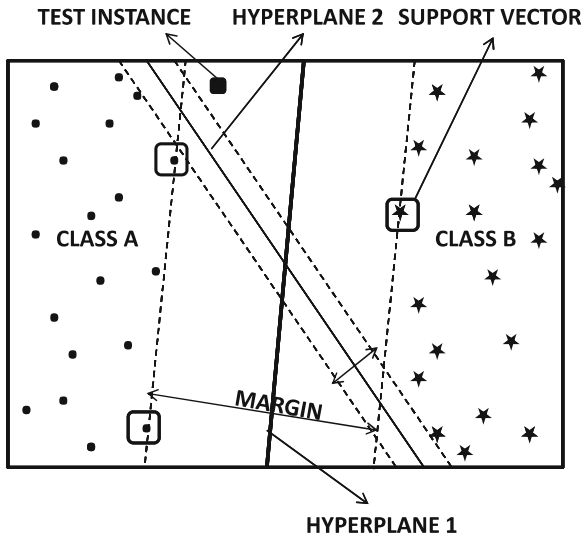

Support Vector Machines

In relazione al margine si deduce che vogliamo massimizzare la seguente funzione obiettivo

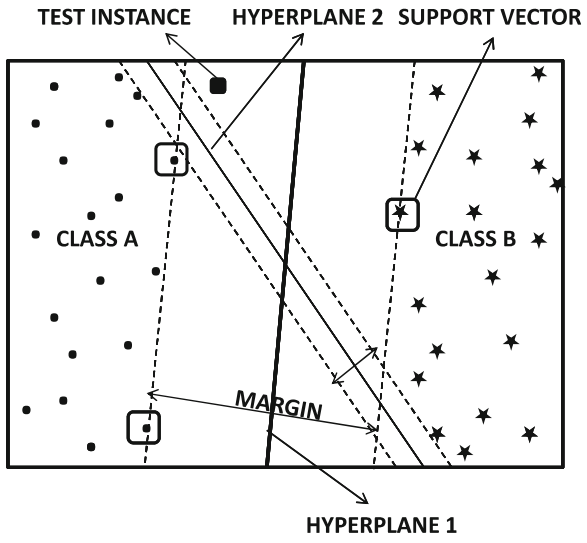

$$\text{distanza iperpiani}: \ 2/\|\overline{W}\|$$

$$\text{funzione obiettivo}: \ O = \|\overline{W}\|^2/2$$

$$L_P = \frac{\|\overline{W}\|^2}{2} - \boxed{\sum_{i=1}^{n} \lambda_i \left[y_i(\overline{W} \cdot \overline{X_i} + b) - 1\right]}, \ \lambda_i \geq 0$$

Moltiplicatori di Lagrange

$$\text{support vectors}: \ \lambda_i \left[y_i(\overline{W} \cdot \overline{X_i} + b) - 1\right] = 0$$

Support Vector Machines

$$L_P = \frac{\|\overline{W}\|^2}{2} - \sum_{i=1}^{n} \lambda_i \left[y_i(\overline{W} \cdot \overline{X_i} + b) - 1 \right], \ \lambda_i \geq 0$$

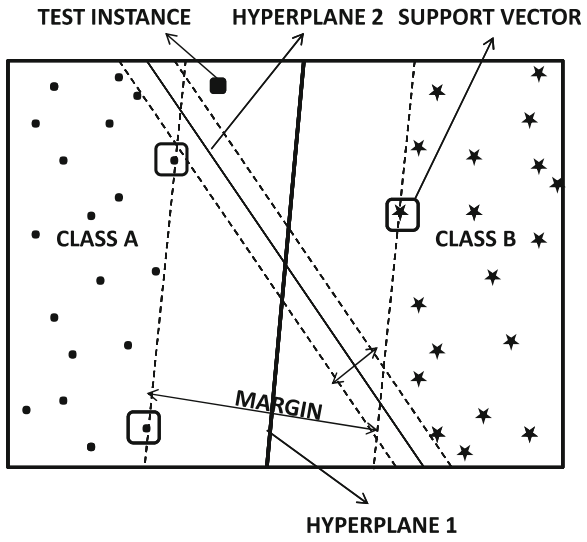

La minimizzazione di L_P può essere formulata come problema duale di massimizzazione :

$$O^* = \frac{\|\overline{W^*}\|^2}{2} \geq L_D^* = \max_{\lambda \geq 0} \min_{\overline{W}, b} L_P$$

Support Vector Machines

Formulando il problema come pura massimizzazione, eliminiamo la dipendenza da $\overline{W}$ e b ponendo a zero il gradiente di L_P

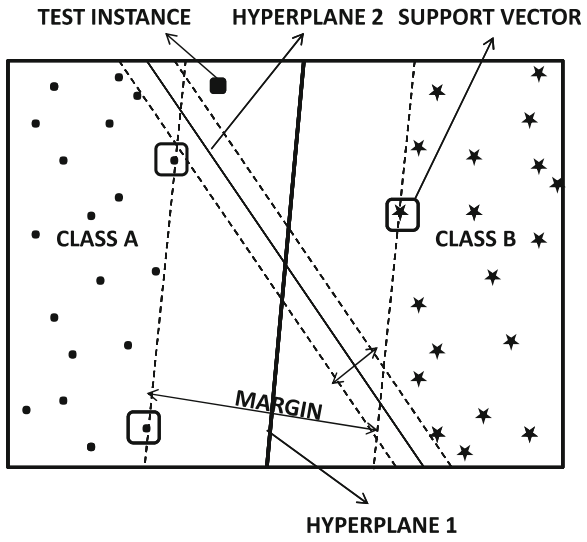

$$\nabla L_P = \nabla \frac{\|\overline{W}\|^2}{2} - \nabla \sum_{i=1}^{n} \lambda_i \left[y_i(\overline{W} \cdot \overline{X_i} + b) - 1 \right] = 0$$

$$\overline{W} = \sum_{i=1}^{n} \lambda_i y_i \overline{X}_i, \sum_{i=1}^{n} \lambda_i y_i = 0$$

$\partial L_P / \partial b = 0$

Support Vector Machines

Il problema duale di massimizzazione si ottiene sostituendo l'espressione di $\overline{W}$ in L_P:

$$L_D = \sum_{i=1}^{n} \lambda_i - \frac{1}{2} \sum_{i=1}^{n} \sum_{j=1}^{n} \lambda_i \lambda_j y_i y_j \overline{X_i} \cdot \overline{X_j}$$

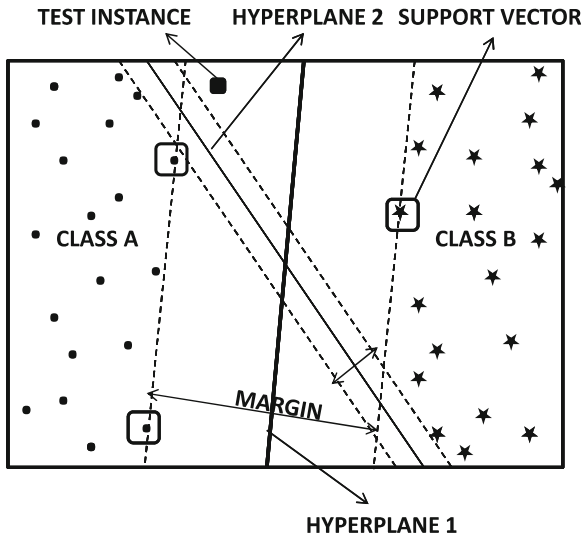

Support Vector Machines

L'addestramento lungo il gradiente ci fornisce la seguente formulazione:

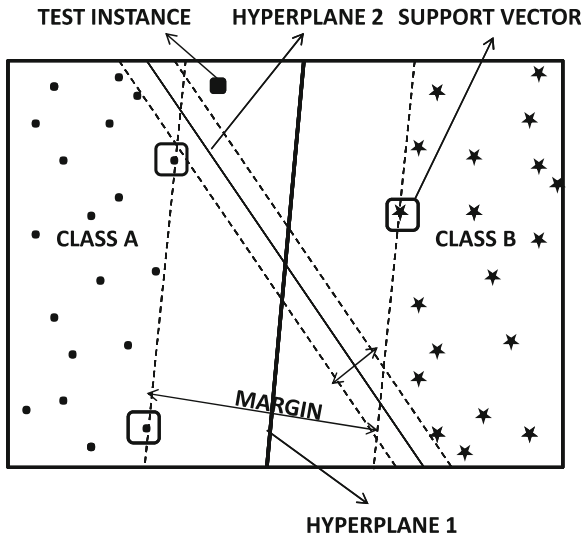

$$\frac{\partial L_D}{\partial \lambda_i} = 1 - y_i \sum_{j=1}^{n} y_j \lambda_j \overline{X_i} \cdot \overline{X_j}$$

$$(\lambda_1 \dots \lambda_n) \leftarrow (\lambda_1 \dots \lambda_n) + \alpha \left(\frac{\partial L_D}{\partial \lambda_1} \dots \frac{\partial L_D}{\partial \lambda_n} \right)$$

Support Vector Machines

Esistono delle situazioni in cui alcuni punti violano leggermente la condizione di lineare separabilità

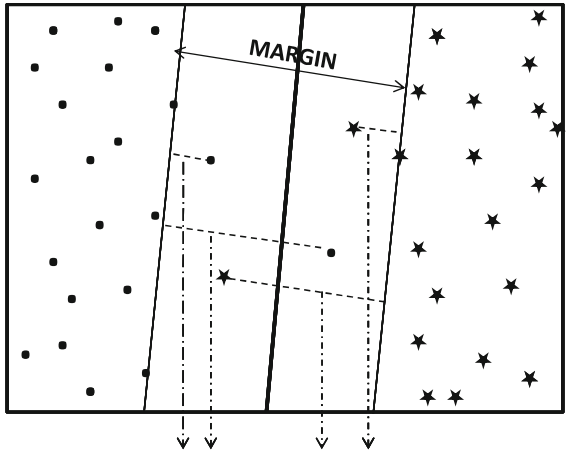

MARGIN VIOLATION WITH PENALTY-BASED SLACK VARIABLES

Si modifica la funzione obiettivo ammettendo delle *violazioni con penalità* sulla funzione obiettivo

$$\begin{cases} \overline{W} \cdot \overline{X_i} + b \geq +1 - \xi_i \ \forall i : y_i = +1 \\ \overline{W} \cdot \overline{X_i} + b \leq -1 + \xi_i \ \forall i : y_i = -1 \end{cases} , \ \xi_i \geq 0 \ \forall i$$

Slack variables

Support Vector Machines

Si modifica la funzione obiettivo ammettendo delle *violazioni con penalità* sulla funzione obiettivo

$$\begin{cases} \overline{W} \cdot \overline{X_i} + b \geq +1 - \xi_i \ \forall i : y_i = +1 \\ \overline{W} \cdot \overline{X_i} + b \leq -1 + \xi_i \ \forall i : y_i = -1 \end{cases} , \ \xi_i \geq 0 \ \forall i$$

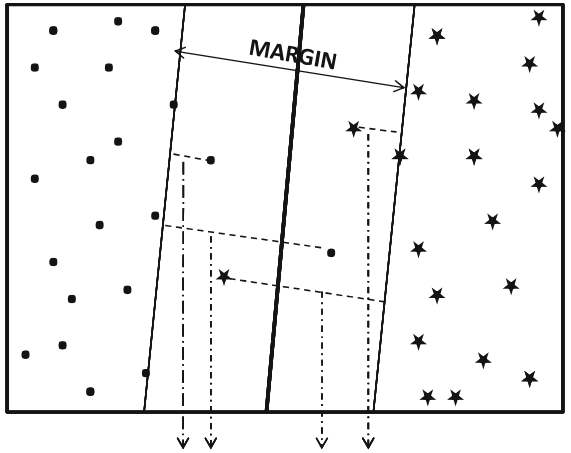

MARGIN VIOLATION WITH PENALTY-BASED SLACK VARIABLES

funzione obiettivo :

$$O = \frac{\|\overline{W}\|^2}{2} + C \sum_{i=1}^{n} \xi_i$$

Lagrange penalty :

$$L_P = \frac{\|\overline{W}\|^2}{2} + C \sum_{i=1}^{n} \xi_i - \sum_{i=1}^{n} \lambda_i \left[y_i (\overline{W} \cdot \overline{X_i} + b) - 1 + \xi_i \right] - \sum_{i=1}^{n} \beta_i \xi_i$$

Support Vector Machines

Si modifica la funzione obiettivo ammettendo delle *violazioni con penalità* sulla funzione obiettivo

Lagrange penalty :

$$L_P = \frac{\|\overline{W}\|^2}{2} + C\sum_{i=1}^{n}\xi_i - \sum_{i=1}^{n}\lambda_i\left[y_i(\overline{W}\cdot\overline{X_i}+b)-1+\xi_i\right] - \sum_{i=1}^{n}\beta_i\xi_i$$

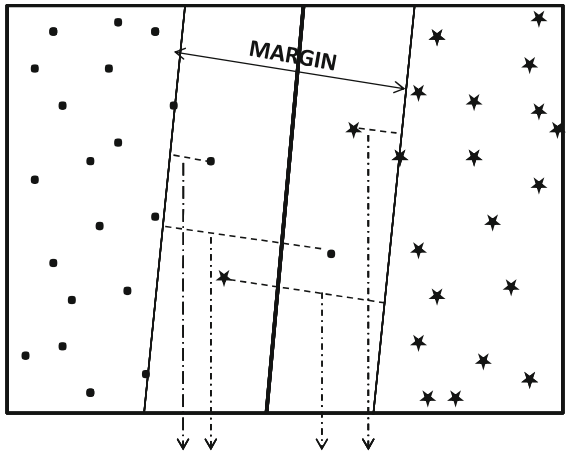

MARGIN VIOLATION WITH PENALTY-BASED SLACK VARIABLES

Si mostra che il problema duale di questa SVM massimizza L_D sotto certe condizioni rispetto ai parametri λ_i che derivano dalle slack variables:

$\partial L_P / \partial \xi_i = 0 \rightarrow (C - \lambda_i - \beta_i) = 0$ *per i punti che violano il margine ($\xi_i > 0$)*

Per i support vectors $\xi_i = 0 \rightarrow (C - \lambda_i) = \beta_i >= 0 \rightarrow$ *$0 < \lambda_i < C$*

Support Vector Machines

kernel trick per superfici di separazione non lineari :

$$L_D = \sum_{i=1}^{n} \lambda_i - \frac{1}{2} \cdot \sum_{i=1}^{n} \sum_{j=1}^{n} \lambda_i \lambda_j y_i y_j K(\overline{X_i}, \overline{X_j})$$

Function	Form
Gaussian radial basis kernel	$K(\overline{X_i}, \overline{X_j}) = e^{-\|\|\overline{X_i} - \overline{X_j}\|\|^2 / 2\sigma^2}$
Polynomial kernel	$K(\overline{X_i}, \overline{X_j}) = (\overline{X_i} \cdot \overline{X_j} + c)^h$
Sigmoid kernel	$K(\overline{X_i}, \overline{X_j}) = \tanh(\kappa \overline{X_i} \cdot \overline{X_j} - \delta)$

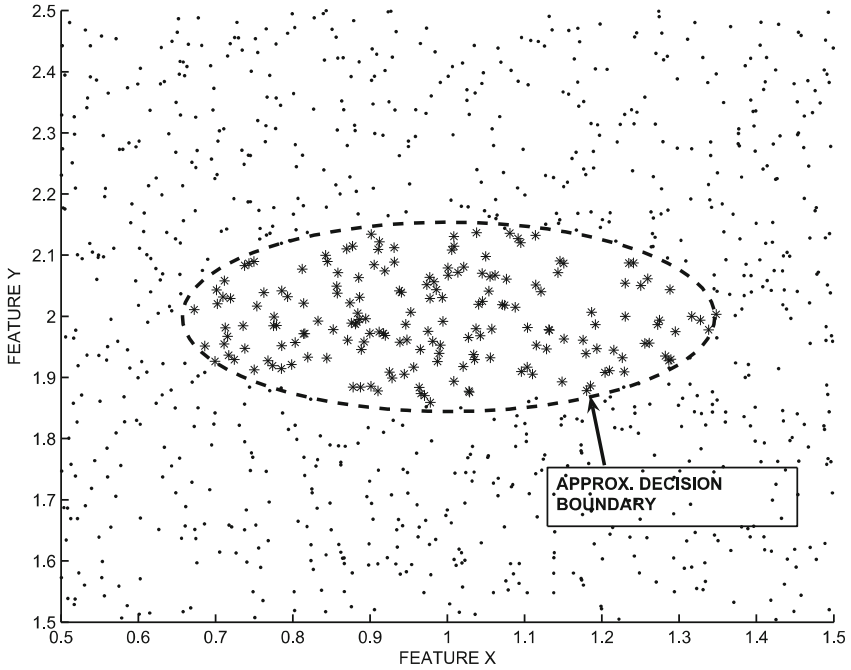

Classificazione multiclasse

- Molti algoritmi di classificazione possono lavorare nativamente per più classi
  - Decision tree
  - Classificatori (Naive) Bayes
- La regressione logistica e la SVM sono concepite come classificatori binari
- Si possono definire strategie per estendere il loro comportamento alla gestione di problemi multiclasse

Classificazione multiclasse

- Strategia *one-against-rest*:
  - Si addestrano *k* classificatori per cui l'*i*-esimo modello binario predice come classe positiva l'appartenenza alla classe C_i
  - Nel test, se il modello *i*-esimo predice correttamente la classe C_i questa ottiene un voto
  - Altrimenti ottengono un voto tutte le altre classi
  - Il classificatore fornirà come etichetta di classe quella che ha ottenuto la maggioranza dei voti

Classificazione multiclasse

- Strategia *one-against-one*:
  - Si addestrano $\binom{k}{2}$ classificatori per tutte le coppie possibili di classi
  - Nel test, il generico modello C_i-*against*-C_j attribuisce un voto alla classe correttamente predetta
  - Il classificatore fornirà come etichetta di classe quella che ha ottenuto la maggioranza dei voti
  - Molti più classificatori, ma training set più piccoli per cui risulta più conveniente dal punto di vista computazionale

Rare class learning

- La classificazione di un data set molto *sbilanciato* ovvero con dei campioni appartenenti ad una *classe rara* è interessante per diversi aspetti:
  - Nel dominio del problema, la classe rara è quella *interessante* ed un errore di classificazione nella classe rara è *molto dannoso*
  - I classificatori necessitano di tecniche di *pesatura* e/o *campionamento* dei dati ad hoc per gestire lo sbilanciamento

Rare class learning

- Pesatura dei campioni
  - Ogni campione ha un peso legato al costo della sua errata classificazione
    → privilegia le classi rare
  - Decision tree: il peso si incorpora nel criterio di split come Gini index o Entropia
  - Naive Bayes: si pesa la stima dei prior e delle probabilità delle feature

Rare class learning

- Pesatura dei campioni
  - Ogni campione ha un peso legato al costo della sua errata classificazione
    → privilegia le classi rare
  - Support Vector Machines (con slack variables): le penalità di violazione del margine sono pesate per le diverse classi
  - k-NN: i voti rispetto alle singole classi dei *k* vicini vengono pesati

Rare class learning

- Campionamento
  - Si *sovracampiona* la classe rara ovvero si *campionano* le classi abbondanti
  - Campionamento con rimpiazzo o senza rimpiazzo
  - Il sovracampionamento può essere dannoso perché è ovviamente una tecnica con rimpiazzo e quindi genera più copie dello stesso campione
    → porta ad overfitting

Rare class learning

- Campionamento
  - Sovracampionamento sintetico – SMOTE:
    - Si selezionano i *k* vicini di un campione raro, appartenenti alla classe minoritaria
    - Si sceglie una frazione casuale di questi, a seconda del livello richiesto di sovracampionamento
    - Si genera un campione sintetico in un punto casuale lungo la linea congiungente il campione con ognuno dei vicini selezionati

Regressione

- Regressione lineare
  - Si consideri un data set *D* di *n* vettori in $\mathbb{R}^d$ $D = \begin{bmatrix} \bar{X}_1 \\ \vdots \\ \bar{X}_n \end{bmatrix}, (n \times d)$ e siano definite *n* corrispondenze $X_i \rightarrow y_i$, $i = 1, \ldots, n$
  - Determinare un vettore di coefficienti $W = \{w_1, \ldots, w_d\}$ che consenta di approssimare l'insieme delle corrispondenze $X_i \rightarrow y_i$, $i = 1, \ldots, n$, come:

$$y_i \approx \bar{W} \cdot \overline{X_i} \quad \forall i \in \{1 \ldots n\}$$

Regressione

- Regressione lineare
  - Si minimizza una funzione obiettivo definita come la somma degli errori quadratici (Sum of Squared Errors – SSE):

$$O = \sum_{i=1}^{n} \left(\bar{W} \cdot \overline{X_i} - y_i\right)^2 = \left\| D\bar{W}^T - \bar{y} \right\|^2$$

- Si parlerà di Least Squares Regression

Regressione

- Regressione lineare
  - Ponendo a 0 il gradiente di *O* rispetto a *W*, si ottiene:

$$2D^T(D\overline{W}^T - \overline{y}) \Rightarrow D^T D\overline{W}^T = D^T\overline{y},\ \overline{W}^T = (D^T D)^{-1} D^T \overline{y}$$

  - Questa è la *matrice pseudoinversa di Moore-Penrose* D^+ della matrice *D* per cui:

$$\overline{W}^T = D^+\overline{y}$$

  - Quando D^TD non è invertibile perché non ha rango massimo si usa la definizione esplicita della pseudoinversa:

$$D^+ = \lim_{\delta \to 0} \left(D^T D + \delta^2 I\right)^{-1} D^T$$

Regressione

- Regressione lineare
  - Si può mostrare che il Fisher linear discriminant è un caso particolare di least squares regression sotto alcune condizioni:

    → D è a media nulla
    → y_i = -1/p_0 per la classe negativa e 1/p_1 per la classe positiva

  - Il risultato della regressione $\overline{W}^T = D^+\overline{y}$ corrisponde a

$$\overline{W}^T \propto S_W^{-1}\left(\boldsymbol{m}_2 - \boldsymbol{m}_1\right)$$

Regressione

- Regressione lineare:
  - *<u>Ridge regression</u>*: si utilizza una regolarizzazione L_2

$$O = \left\| D\bar{W}^T - \bar{y} \right\|^2 + \lambda \left\| \bar{W} \right\|^2$$

$$\bar{W}^T = (D^T D + \lambda I)^{-1} D^T \bar{y}$$

  - La matrice $D^T D + \lambda I$ è semidefinita positiva e quindi sempre invertibile
  - la ridge regression riduce la varianza della stima rispetto alla least squares

Regressione

- Regressione lineare
  - *Lasso regression*: si utilizza una regolarizzazione L_1

$$O = \left\| D\bar{W}^T - \bar{y} \right\|^2 + \lambda \left\| \bar{W} \right\|$$

  - La soluzione è iterativa e ammette, tendenzialmente, il caso $W = 0$
  - La regressione Lasso, in genere, predilige un vettore dei coefficienti sparso
  - Indicata nel caso di presenza di molte feature irrilevanti per il problema, le quali vedranno azzerarsi i rispettivi coefficienti

Regressione

- Effetto della regolarizzazione

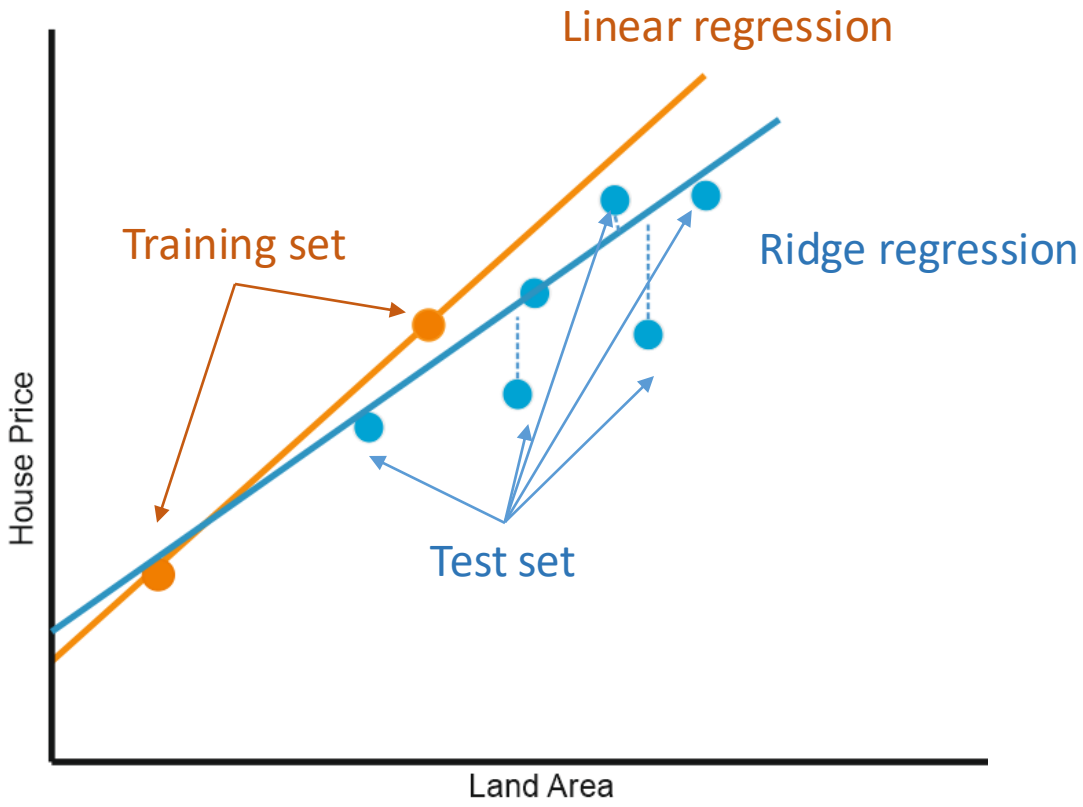

Regressione

- Ridge vs Lasso

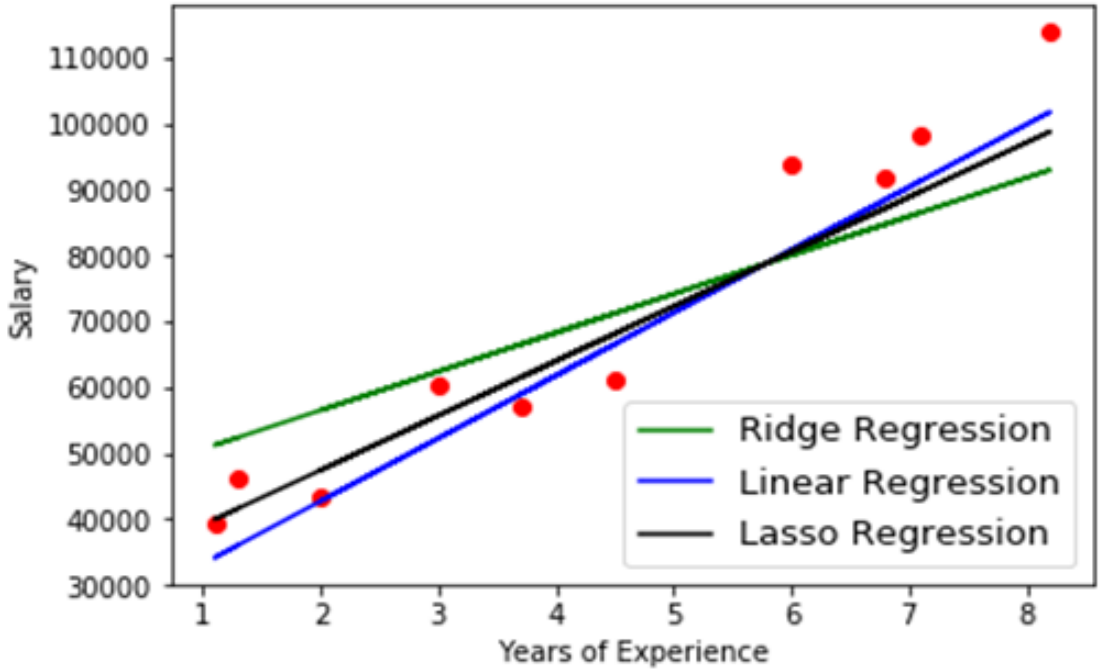

La Ridge regression azzera il contributo di una feature solo asintoticamente ($\lambda \rightarrow \infty$) mentre la Lasso regression può eliminare esattamente la feature (pendenza nulla per λ molto grande, ma non ∞)

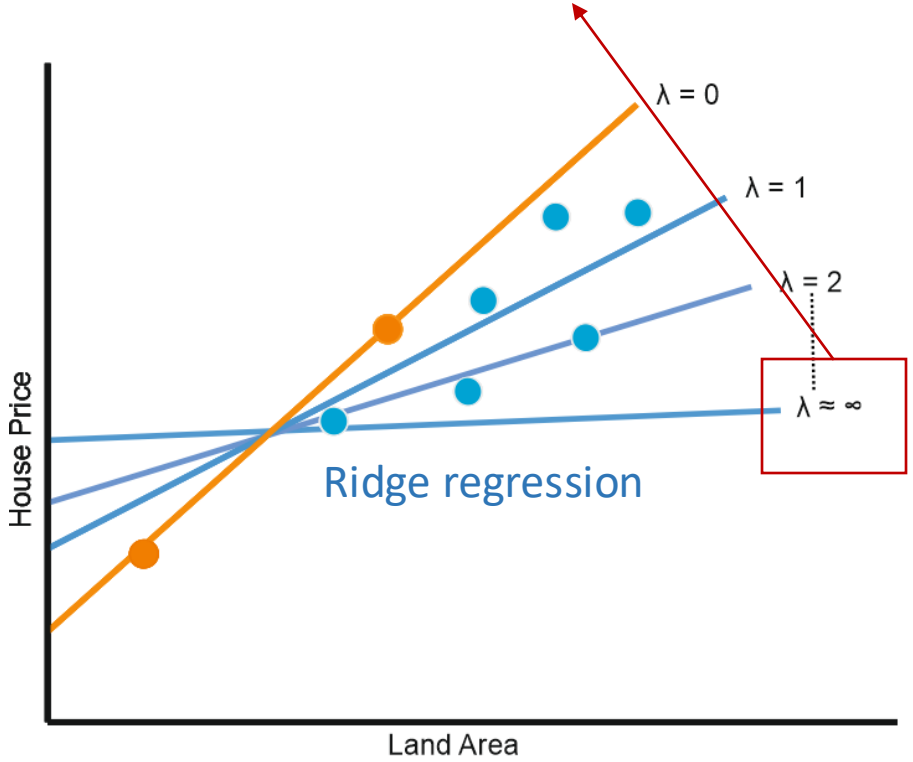

Regressione

- Principal Component Regression
  - Utilizzato per ridurre la dimensionalità del data set rispetto alle feature poco interessanti o rumorose
  - Si applica la PCA a *D* ottenendo una nuova matrice dei dati $R = \begin{bmatrix} \bar{Z}_1 \\ \vdots \\ \bar{Z}_n \end{bmatrix}, (n \times k)$ proiettando *D* sulle *k* direzioni principali
  - Si risolve, quindi il problema

$$y_i \approx \bar{W} \cdot \overline{Z_i} \quad \forall i \in \{1 \ldots n\},\ \bar{W} = (R^T R)^{-1} R^T \bar{y}$$

Regressione

- Generalized Linear Models
  - Modello generalizzato della regressione lineare in cui si stima una *funzione di media* $f(\overline{W} \cdot \overline{X_i}), i = 1, \dots, n$ della distribuzione di probabilità delle etichette numeriche y_i
  - Mantiene le caratteristiche della regressione lineare, ma si estende a diverse tipologie di dati
  - Il problema da risolvere è quindi:

$$y_i \sim \text{ Probability distribution with mean } f\left(\bar{W} \cdot \overline{X_i}\right) \quad \forall i \in \{1 \dots n\}$$

Regressione

- Generalized Linear Models
  - La scelta della funzione di media (o della sua inversa $f^{-1}(\cdot)$ detta *link function*) sottende una particolare distribuzione di probabilità e quindi una determinata tipologia di dato

Link function	**Mean function**	**Distribution assumption**
Identity	$\overline{W} \cdot \overline{X}$	Normal
Inverse	$-1/(\overline{W} \cdot \overline{X})$	Exponential, Gamma
Log	$\exp(\overline{W} \cdot \overline{X})$	Poisson
Logit	$1/[1 + \exp(-\overline{W} \cdot \overline{X})]$	Bernoulli, Categorical
Probit	$\Phi(\overline{W} \cdot \overline{X})$	Bernoulli, Categorical

Regressione

- Generalized Linear Models

Least squares regression:

$$\text{Likelihood}\left(\{y_1 \dots y_n\}\right) = \prod_{i=1}^{n} \text{Probability}\left(y_i\right) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{\left(y_i - f\left(\bar{W} \cdot \overline{X_i}\right)\right)^2}{2\sigma^2}\right)$$

$$= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{\left(y_i - \bar{W} \cdot \overline{X_i}\right)^2}{2\sigma^2}\right)$$

$$\propto \exp\left(-\frac{\sum_{i=1}^{n}\left(y_i - \bar{W} \cdot \overline{X_i}\right)^2}{2\sigma^2}\right)$$

Link function	Mean function	Distribution assumption
Identity	$\overline{W} \cdot \overline{X}$	Normal
Inverse	$-1/(\overline{W} \cdot \overline{X})$	Exponential, Gamma
Log	$\exp(\overline{W} \cdot \overline{X})$	Poisson
Logit	$1/[1 + \exp(-\overline{W} \cdot \overline{X})]$	Bernoulli, Categorical
Probit	$\Phi(\overline{W} \cdot \overline{X})$	Bernoulli, Categorical

Regressione

- Generalized Linear Models

Logistic regression:

$$y_i = \begin{cases} 1 & \text{with probability } 1/\left[1+\exp\left(-\bar{W}\cdot\overline{X_i}\right)\right] \\ 0 & \text{with probability } 1/\left[1+\exp\left(\bar{W}\cdot\overline{X_i}\right)\right] \end{cases}$$

Link function	Mean function	Distribution assumption
Identity	$\overline{W}\cdot\overline{X}$	Normal
Inverse	$-1/(\overline{W}\cdot\overline{X})$	Exponential, Gamma
Log	$\exp(\overline{W}\cdot\overline{X})$	Poisson
Logit	$1/[1+\exp(-\overline{W}\cdot\overline{X})]$	Bernoulli, Categorical
Probit	$\Phi(\overline{W}\cdot\overline{X})$	Bernoulli, Categorical

Regressione

- Generalized Linear Models

Variante della regressione logistica che usa la CDF della distribuzione normale

Utile per fare regressione su dati ordinati come i valori di rating

Link function	Mean function	Distribution assumption
Identity	$\overline{W} \cdot \overline{X}$	Normal
Inverse	$-1/(\overline{W} \cdot \overline{X})$	Exponential, Gamma
Log	$\exp(\overline{W} \cdot \overline{X})$	Poisson
Logit	$1/[1 + \exp(-\overline{W} \cdot \overline{X})]$	Bernoulli, Categorical
Probit	$\Phi(\overline{W} \cdot \overline{X})$	Bernoulli, Categorical

Regressione non lineare

- Estensione della regressione ad una funzione non lineare del campione:

$$y = \sum_{i=1}^{m} w_i h_i(\bar{X})$$

- Il caso tipico è quello della regressione polinomiale in cui $h_i(\bar{X}) = \bar{X}^i$

- Cattura relazioni funzionali complesse tra i punti del data set

Regressione non lineare

- Kernel ridge regression
  - Si usa il kernel trick per modellare la relazione tra i dati e le etichette numeriche
  - È necessario mostrare che la ridge regression può essere espressa in termini del *prodotto scalare tra i dati di addestramento* $\bar{X}_i$ *e quelli di test* $\bar{Z}_i$
  - Si può mostrare, usando la SVD della matrice D^+, che:

$$\left(D^T D + \lambda I_d\right)^{-1} D^T = D^T \left(D D^T + \lambda I_n\right)^{-1}$$

Regressione non lineare

- Kernel ridge regression
  - La predizione della ridge regression $F(\bar{Z}) = \bar{Z}\bar{W}^T$ per un vettore di test $\bar{Z}$ si può scrivere :

$$F(\bar{Z}) = \bar{Z}\left(D^T D + \lambda I_d\right)^{-1} D^T \bar{y} = \bar{Z} D^T \left(D D^T + \lambda I_n\right)^{-1} \bar{y}$$

  - La kernel ridge regression si può quindi formulare come:

$$F(\bar{Z}) = \bar{\kappa}\left(K + \lambda I_n\right)^{-1} \bar{y}$$

  - In cui $\bar{\kappa} = \left[k(\bar{Z}, \bar{X}_1), \ldots, k(\bar{Z}, \bar{X}_n)\right], \; K = \left[k(\bar{X}_i, \bar{X}_j)\right]$

Regressione

- Alberi di regressione
  - Modella le relazioni non lineari tra i dati come un insieme di *approssimazioni lineari locali* nei nodi foglia dell'albero
  - Lo split per variabili categoriche è quello tipico di un decision tree (Gini index, entropia) e così pure le tecniche di pruning
  - Per dati numerici si minimizza il valore di SSE su tutti i nodi risultanti dallo split

Regressione

- Alberi di regressione
  - Modella le relazioni non lineari tra i dati come un insieme di *approssimazioni lineari locali* nei nodi foglia dell'albero
  - Il modello richiederebbe una regressione ad ogni nodo.
  - In alternativa si può controllare la varianza dei dati ad ogni split e poi fare la regressione nei nodi foglia *dopo* aver costruito l'albero

Regressione

- Valutazione della regressione
  - Si usa la statistica R^2 o la sua variante per *d* elevato:

$$R^2 = 1 - \frac{SSE}{SST} \qquad R^2 = 1 - \frac{(n-d)}{(n-1)}\frac{SSE}{SST}$$

  - In cui

$$SSE = \sum_{i=1}^{n} \left(y_i - g\left(\overline{X_i}\right)\right)^2 \quad SST = \sum_{i=1}^{n} \left(y_i - \sum_{j=1}^{n} \frac{y_j}{n}\right)^2$$

Metodi di ensemble

- I metodi di ensemble combinano le predizioni di un insieme di algoritmi (base learners) sul data set

- Sfruttano le caratteristiche peculiari di ciascun algoritmo rispetto ai dati per incrementare l'accuratezza

Algorithm *EnsembleClassify*(Training Data Set: $\mathcal{D}$
Base Algorithms: $\mathcal{A}_1 \ldots \mathcal{A}_r$, Test Instances: $\mathcal{T}$)
begin
$j = 1$;
repeat
Select an algorithm $\mathcal{Q}_j$ from $\mathcal{A}_1 \ldots \mathcal{A}_r$;
Create a new training data set $f_j(\mathcal{D})$ from $\mathcal{D}$;
Apply $\mathcal{Q}_j$ to $f_j(\mathcal{D})$ to learn model $\mathcal{M}_j$;
$j = j + 1$;
until(termination);
report labels of each $T \in \mathcal{T}$ based on combination of predictions from all learned models $\mathcal{M}_j$;
end

Metodi di ensemble

- I metodi di ensemble orientati ai dati
  - $\mathcal{A}_1, \ldots, \mathcal{A}_r$ sono istanze dello stesso modello
  - $f_j(\mathcal{D})$ è differente per ciascun modello
    - Campionamento
    - Manipolazione delle feature o delle etichette
    - Focalizzazione su porzioni di dati in cui la classificazione non è corretta

Algorithm *EnsembleClassify*(Training Data Set: $\mathcal{D}$
Base Algorithms: $\mathcal{A}_1 \ldots \mathcal{A}_r$, Test Instances: $\mathcal{T}$)
begin
$j = 1$;
repeat
Select an algorithm $\mathcal{Q}_j$ from $\mathcal{A}_1 \ldots \mathcal{A}_r$;
Create a new training data set $f_j(\mathcal{D})$ from $\mathcal{D}$;
Apply $\mathcal{Q}_j$ to $f_j(\mathcal{D})$ to learn model $\mathcal{M}_j$;
$j = j + 1$;
until(termination);
report labels of each $T \in \mathcal{T}$ based on combination of predictions from all learned models $\mathcal{M}_j$;
end

Metodi di ensemble

- I metodi di ensemble orientati ai modelli
  - $\mathcal{A}_1, \ldots, \mathcal{A}_r$ sono istanze di modelli differenti
  - $f_j(\mathcal{D}) \equiv \mathcal{D}$
    - Differenti modelli esibiscono performance migliori in diverse porzioni del data set

Algorithm *EnsembleClassify*(Training Data Set: $\mathcal{D}$
Base Algorithms: $\mathcal{A}_1 \ldots \mathcal{A}_r$, Test Instances: $\mathcal{T}$)
begin
$j = 1$;
repeat
Select an algorithm $\mathcal{Q}_j$ from $\mathcal{A}_1 \ldots \mathcal{A}_r$;
Create a new training data set $f_j(\mathcal{D})$ from $\mathcal{D}$;
Apply $\mathcal{Q}_j$ to $f_j(\mathcal{D})$ to learn model $\mathcal{M}_j$;
$j = j + 1$;
until(termination);
report labels of each $T \in \mathcal{T}$ based on combination of predictions from all learned models $\mathcal{M}_j$;
end

Metodi di ensemble

- I metodi di ensemble migliorano *sia il bias sia la varianza della stima* del classificatore

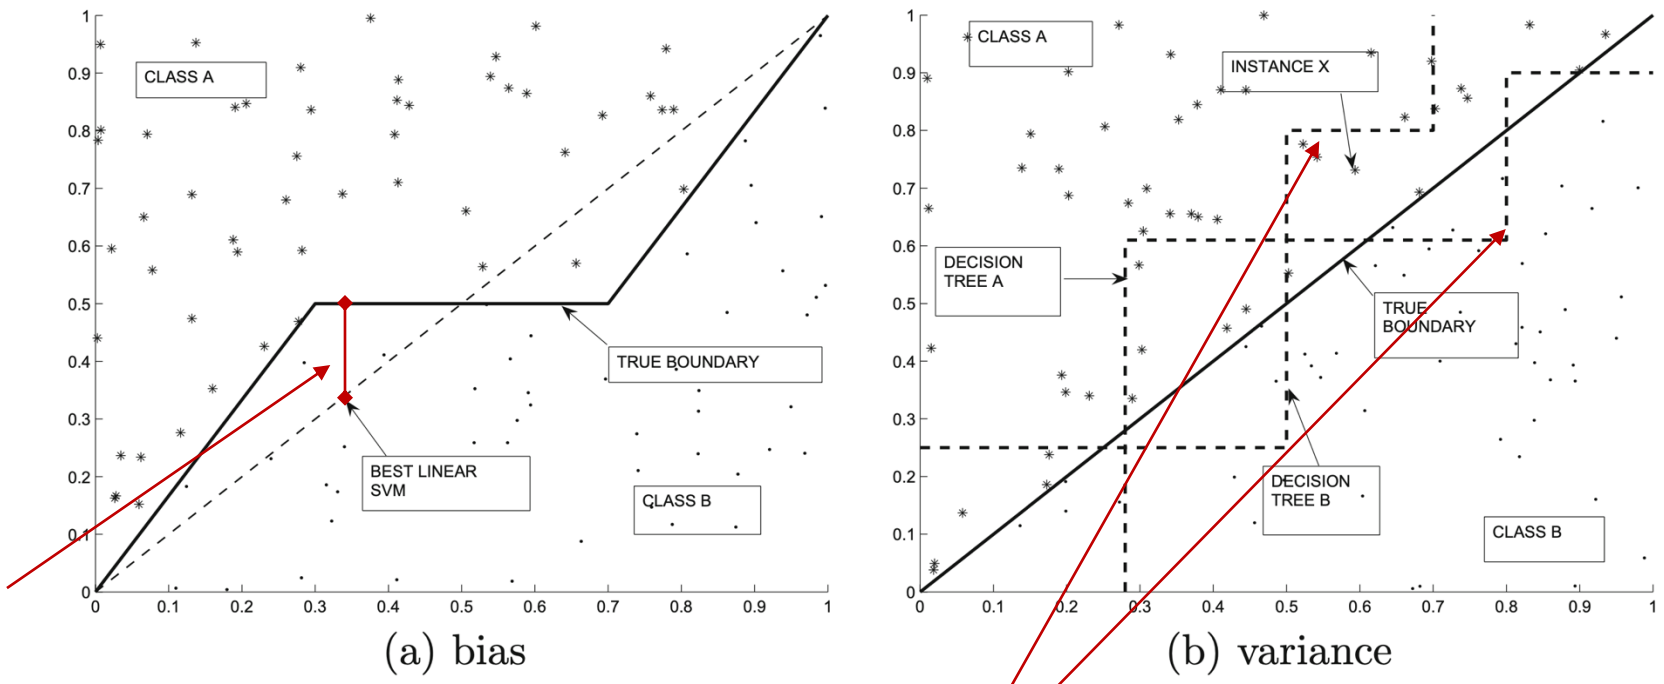

Un singolo classificatore esibisce un proprio *bias* rispetto alla reale distribuzione dele classi *anche per un numero elevato di dati di addestramento*

Un singolo classificatore ha *varianza* insita nella stima perché al variare dell'istanza del training set la predizione del medesimo campione può cambiare

Metodi di ensemble

Tre decision tree indipendenti:

$$p_{tree,1} = p_{tree,2} = p_{tree,3} = p_{tree} = 80\%$$

$$p_{ensemble} = p_{tree,1} \times p_{tree,2} \times p_{tree,3} + \\ + \binom{3}{2} p_{tree} \times p_{tree} \times (1 - p_{tree}) = \mathbf{89.6\%}$$

- I metodi di ensemble migliorano *sia il bias sia la varianza della stima* del classificatore

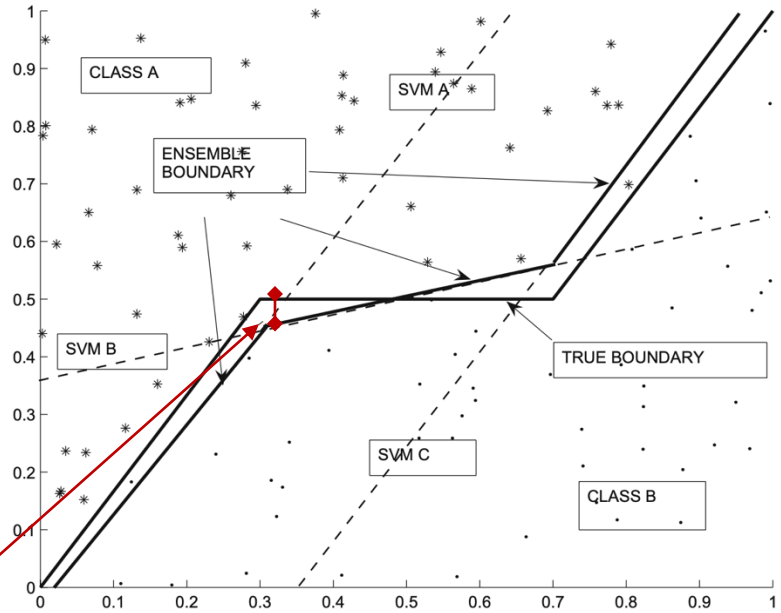

(a) bias

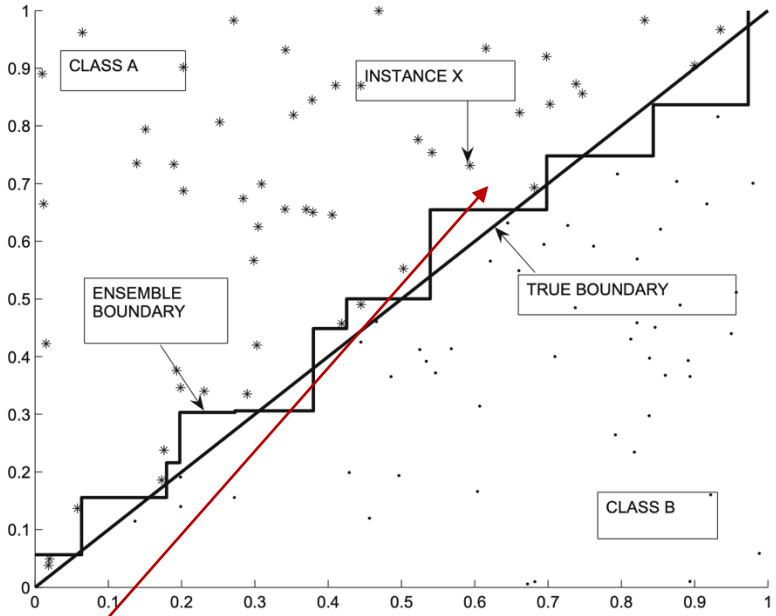

(b) variance

Un ensemble di classificatori approssima meglio un boundary complesso riducendo il bias

All'aumentare del numero dei componenti dell'ensemble la stima riduce la propria varianza

Metodi di ensemble

- Bagging (Bootstrapped aggregating)
  - Tecnica per creare un ensemble di classificatori i.i.d. in modo tale da ridurre la varianza della stima da σ^2 a σ^2/k
  - Si generano *k* data set tramite campionamento con rimpiazzo: i nuovi data set contengono duplicati
    - Si può mostrare che la frazione di dati distinti in ogni data set è $1-(1-1/n)^n \approx 1-1/e$ per *n* elevato
    - Questa tecnica è detta Bootstrap: usata anche per calcolare l'Accuracy di un modello pesata su più istanze del data set «lievemente» diverse

Metodi di ensemble

- Bagging (Bootstrapped aggregating)
  - Si addestrano i *k* classificatori e la predizione è data dalla maggioranza o dalla media dei voti espressi da ciascuno su ogni campione
  - Riduce la varianza della stima, *ma non il bias*
  - Conviene scegliere dei modelli che tendano di per sé a ridurre il bias

Random Forests

- È un ensemble di decision tree addestrati con il bagging
- Il decision tree, soprattutto se fatto accrescere molto in profondità, riduce molto il bias anche se a forte scapito della varianza della classificazione
- È un modello ideale per il bagging

Random Forests

- I nodi più elevati della gerarchia rimangono sostanzialmente invarianti nei diversi alberi
  - I singoli alberi sono molto correlati e ciò limita la riduzione dell'errore di stima
  - È necessario diversificare molto gli alberi durante la loro crescita per aumentare la capacità di predizione dell'ensemble
- Le Random Forests usano un *criterio random per lo split nei diversi alberi* dell'ensemble

Random Forests

- Random split selection
  - Forest-RI (Random Input): Un sottoinsieme casuale di *q* feature viene estratto per lo split
  - Forest-RC (Random Combination): un sottoinsieme *L* di feature viene estratto e si creano *q* combinazioni lineari che vengono usate come feature multivariate per lo split
    - Preferibile per bassa dimensionalità dei dati per cui *q* diventa molto piccolo

Boosting

- Tecnica di ensemble iterativa orientata a ridurre il bias

- Lo stesso learner viene riaddestrato più volte sul data set in cui ogni campione è pesato *con un peso maggiore se è stato mis-classificato all'iterata precedente*

  - Il classificatore all'iterata *t* viene guidato dagli errori commessi dalle iterate precedenti

Boosting

- AdaBoost

Predizione:

somma pesata delle predizioni ad ogni iterata *t* tramite il coefficiente α_t

Si può ridurre la varianza se si ricampiona il data set ad ogni iterazione

Poco indicato per dati rumorosi

Il coefficiente di peso cresce logaritmicamente al decrescere dell'error rate

Algorithm *AdaBoost*(Data Set: $\mathcal{D}$, Base Classifier: $\mathcal{A}$, Maximum Rounds: T)
begin
$t = 0$;
for each i initialize $W_1(i) = 1/n$;
repeat
$t = t + 1$;
Determine weighted error rate ϵ_t on $\mathcal{D}$ when base algorithm $\mathcal{A}$ is applied to weighted data set with weights $W_t(\cdot)$;
$\alpha_t = \frac{1}{2}\log_e((1-\epsilon_t)/\epsilon_t)$;
for each misclassified $\overline{X_i} \in \mathcal{D}$ **do** $W_{t+1}(i) = W_t(i)e^{\alpha_t}$;
else (correctly classified instance) **do** $W_{t+1}(i) = W_t(i)e^{-\alpha_t}$;
for each instance $\overline{X_i}$ **do** normalize $W_{t+1}(i) = W_{t+1}(i)/[\sum_{j=1}^{n} W_{t+1}(j)]$;
until $((t \geq T)$ OR $(\epsilon_t = 0)$ OR $(\epsilon_t \geq 0.5))$;
Use ensemble components with weights α_t for test instance classification;
end

Frazione dei campioni mis-classificati

Peso crescente

Peso decrescente

Classificazione perfetta

Performance peggiore del classificatore casuale

Boosting

- XGBoost (eXtreme Gradient Boosting)
  - Algoritmo molto recente di ensemble per compiti di classificazione e regressione, basato sul concetto di *gradient boosting*
  - L'idea di base è che:

    «il boosting può essere interpretato come la minimizzazione di un'apposita funzione di costo nello spazio funzionale dei modelli»

Boosting

- XGBoost (eXtreme Gradient Boosting)
  - Gradient boosting:
    - Si consideri il problema di classificazione:

$$\hat{y} = F(x)$$

$$L_{\mathrm{MSE}} = \frac{1}{n} \sum_{i=1}^{n} \left(y_i - F\left(x_i\right)\right)^2$$

    - Lo schema di boosting aggiorna il modello come segue:

$$F_{m+1}\left(x_i\right) = F_m\left(x_i\right) + h_m\left(x_i\right) = y_i$$

$$\boxed{h_m\left(x_i\right) = y_i - F_m\left(x_i\right)}$$

Residui

Boosting

- XGBoost (e<u>X</u>treme <u>G</u>radient <u>Boost</u>ing)
  - Gradient boosting:
    - L'algoritmo, ad ogni iterata, fa il *fit dei residui* $h_m(x_i)$

Sono i modelli di base dell'ensemble

    - È facile mostrare che *i residui sono <u>proporzionali</u> alle derivate della funzione di Loss rispetto alla funzione del modello*

$$L_{\mathrm{MSE}} = \frac{1}{n}\sum_{i=1}^{n}\left(y_i - F_m\left(x_i\right)\right)^2$$

$$-\frac{\partial L_{\mathrm{MSE}}}{\partial F_m\left(x_i\right)} = \frac{2}{n}\left(y_i - F_m\left(x_i\right)\right) = \frac{2}{n}h_m\left(x_i\right)$$

Boosting

- XGBoost (eXtreme Gradient Boosting)
  - Gradient boosting:

Input: training set $\{(x_i, y_i)\}_{i=1}^n$, a differentiable loss function $L(y, F(x))$, number of iterations M.

Algorithm:

1. Initialize model with a constant value:

$$F_0(x) = \arg\min_{\gamma} \sum_{i=1}^{n} L(y_i, \gamma).$$

2. For m = 1 to M:
   1. Compute so-called *pseudo-residuals*:

$$r_{im} = -\left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)}\right]_{F(x)=F_{m-1}(x)} \quad \text{for } i = 1, \ldots, n.$$

   2. Fit a base learner (or weak learner, e.g. tree) closed under scaling $h_m(x)$ to pseudo-residuals, i.e. train it using the training set $\boxed{\{(x_i, r_{im})\}_{i=1}^n}$.
   3. Compute multiplier γ_m by solving the following one-dimensional optimization problem:

$$\boxed{\gamma_m = \arg\min_{\gamma} \sum_{i=1}^{n} L\left(y_i, F_{m-1}(x_i) + \gamma h_m(x_i)\right).}$$

   4. Update the model:

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x).$$

3. Output $\boxed{F_M(x).}$

γ_m è la costante di proporzionalità del *m*-esimo learner.

Viene scelta per minimizzare *L*.

La discesa lungo il gradiente di *L* viene approssimata da una ricerca lineare

Addestramento del *m*-esimo learner sui residui

È la somma di tutti base learner che minimizza la loss media dell'ensemble

Boosting

- XGBoost (eXtreme Gradient Boosting)
  - La discesa lungo il gradiente è effettuata usando il metodo di Newton-Raphson

$$f'(x_n) = \frac{f(x_n) - 0}{x_n - x_{n+1}}$$

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$$

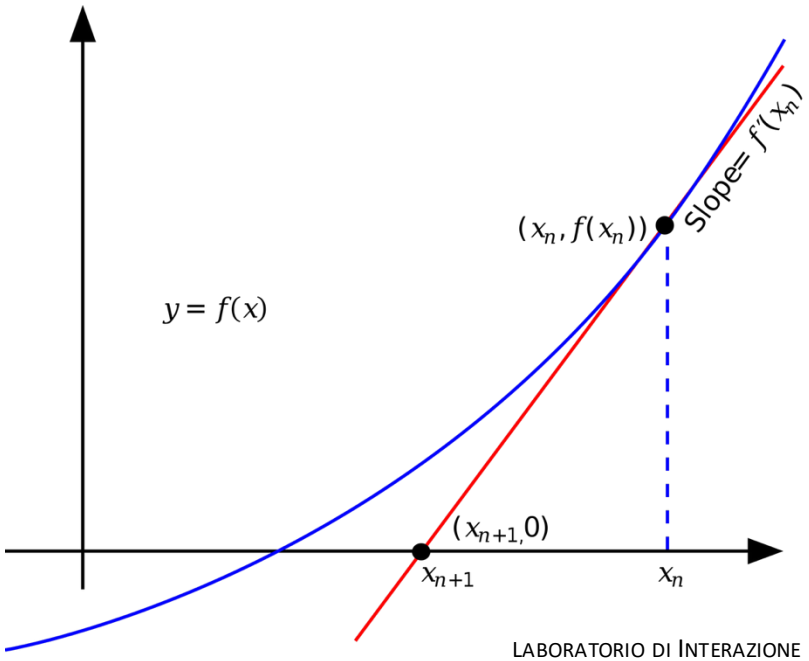

Boosting

- XGBoost (eXtreme Gradient Boosting)
  - Nel Newton boosting *f*(*x*) è approssimata tramite espansione in serie di Taylor fino al secondo ordine:

$$f\left(x_k+t\right) \approx f\left(x_k\right)+f'\left(x_k\right) t+\frac{1}{2} f''\left(x_k\right) t^2$$

$$0=\frac{\mathrm{d}}{\mathrm{d}t}\left(f\left(x_k\right)+f'\left(x_k\right) t+\frac{1}{2} f''\left(x_k\right) t^2\right)=f'\left(x_k\right)+f''\left(x_k\right) t$$

$$t=-\frac{f'\left(x_k\right)}{f''\left(x_k\right)}, \quad x_{k+1}=x_k+t=x_k \boxed{-\frac{f'\left(x_k\right)}{f''\left(x_k\right)}}$$

Questi sono i residui del boosting

Boosting

- XGBoost

Input: training set $\{(x_i, y_i)\}_{i=1}^N$, a differentiable loss function $L(y, F(x))$, a number of weak learners M and a learning rate α.

Algorithm:

1. Initialize model with a constant value:

$$\hat{f}_{(0)}(x) = \arg\min_{\theta} \sum_{i=1}^{N} L(y_i, \theta).$$

2. For m = 1 to M:

   1. Compute the 'gradients' and 'hessians':

$$\hat{g}_m(x_i) = \left[\frac{\partial L(y_i, f(x_i))}{\partial f(x_i)}\right]_{f(x)=\hat{f}_{(m-1)}(x)}.$$

$$\hat{h}_m(x_i) = \left[\frac{\partial^2 L(y_i, f(x_i))}{\partial f(x_i)^2}\right]_{f(x)=\hat{f}_{(m-1)}(x)}.$$

   2. Fit a base learner (or weak learner, e.g. tree) using the training set $\left\{x_i, -\frac{\hat{g}_m(x_i)}{\hat{h}_m(x_i)}\right\}_{i=1}^N$ by solving the optimization problem below:

$$\boxed{\begin{aligned} \hat{\phi}_m &= \arg\min_{\phi \in \mathbf{\Phi}} \sum_{i=1}^{N} \frac{1}{2} \hat{h}_m(x_i) \left[-\frac{\hat{g}_m(x_i)}{\hat{h}_m(x_i)} - \phi(x_i)\right]^2. \\ \hat{f}_m(x) &= \alpha \hat{\phi}_m(x). \end{aligned}}$$

   3. Update the model:

$$\hat{f}_{(m)}(x) = \hat{f}_{(m-1)}(x) + \hat{f}_m(x).$$

3. Output $\hat{f}(x) = \hat{f}_{(M)}(x) = \sum_{m=0}^{M} \hat{f}_m(x).$

Il singolo learner minimizza un problema ai minimi quadrati rispetto ai residui

Valutazione della bontà della classificazione

La più semplice misura è l'accuracy ovvero la percentuale di elementi predetti correttamente in tutte le classi.

Fornisce una falsa informazione se le classi sono fortemente sbilanciate.

$$ACC = \frac{1}{N} \sum_{k=1}^{C} \sum_{x \in C_k} I(C(x) \equiv C_k), \quad I = \begin{cases} 0, & C(x) \neq C_k \\ 1, & C(x) = C_k \end{cases}$$

$$bACC = \frac{1}{C} \sum_{k=1}^{C} \frac{1}{|C_k|} \sum_{x \in C_k} I(C(x) \equiv C_k)$$

Valutazione della bontà della classificazione

Predizione → Reference ↓	C_i	Altre classi
C_i	TP_i	FN_i
Altre classi	FP_i	TN_i

$$P_i = \frac{TP_i}{TP_i + FP_i}$$

$$R_i = \frac{TP_i}{TP_i + FN_i}$$

$$F_1 = 2\frac{P_i \cdot R_i}{P_i + R_i}$$

$$\mathrm{Acc}_i = \frac{TP_i + TN_i}{TP_i + TN_i + FP_i + FN_i}$$

$$P_{\text{micro}} = \frac{\sum_{i=1}^{C} TP_i}{\sum_{i=1}^{C} TP_i + FP_i}$$

$$R_{\text{micro}} = \frac{\sum_{i=1}^{C} TP_i}{\sum_{i=1}^{C} TP_i + FN_i}$$

$$F_{1\text{micro}} = 2\frac{P_{\text{micro}} \cdot R_{\text{micro}}}{P_{\text{micro}} + R_{\text{micro}}}$$

$$P_{\text{macro}} = \frac{1}{C}\sum_{i=1}^{C}\frac{TP_i}{TP_i + FP_i} = \frac{\sum_{i=1}^{C} P_i}{C}$$

$$R_{\text{macro}} = \frac{1}{C}\sum_{i=1}^{C}\frac{TP_i}{TP_i + FN_i} = \frac{\sum_{i=1}^{C} R_i}{C}$$

$$F_{1\text{macro}} = 2\frac{P_{\text{macro}} \cdot R_{\text{macro}}}{P_{\text{macro}} + R_{\text{macro}}}$$

Valutazione della bontà della classificazione

La Receiver Operating Curve (ROC) è tracciata misurando il *False Positive Rate* e il *True Positive Rate* al variare di una soglia definita sullo score della classe positiva.

$$ROC(t) \propto FPR(t) \text{ vs. } TPR(t)$$

$$TPR(t) \equiv Recall(t), FPR(t) = \frac{FP(t)}{FP(t) + TN(t)}$$

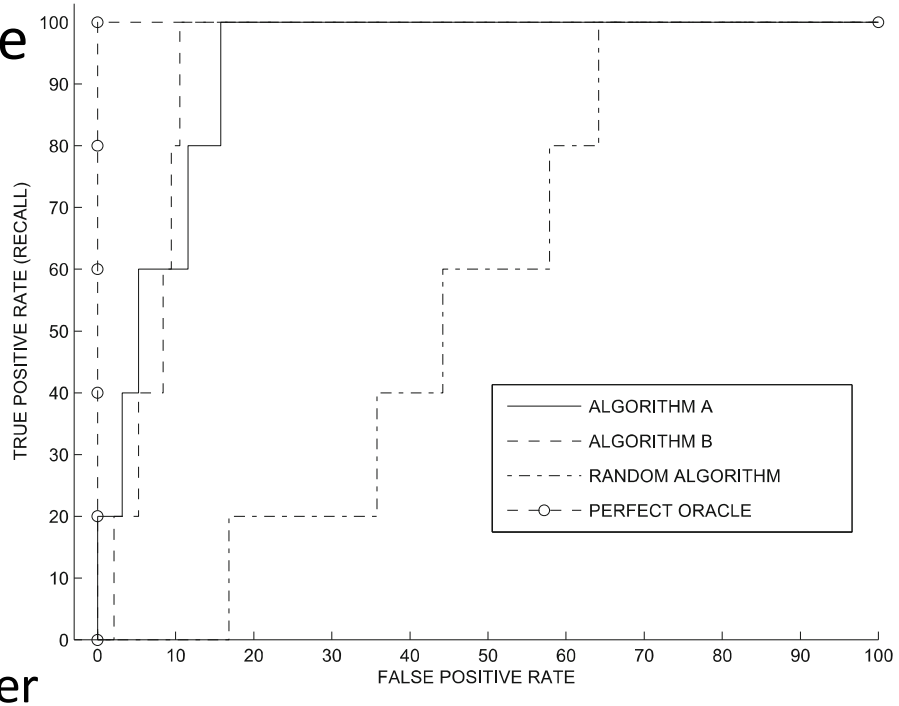

(a) ROC

AUC, Area Under the Curve, tende a 1 per buona classificazione

Per i problemi multi-classe si possono tracciare più curve, una per singola classe, e calcolare l'AUC media.