




CORSO DI BIG DATA – MODULO MACHINE LEARNING PER I BIG DATA

**Simulazione della Prova scritta del 28 maggio 2026**

Si consideri il data set CIFAR10 che contiene un training set di 50.000 immagini a colori aventi dimensione 32x32 e articolate in 10 categorie diverse. Il test set è costituito da 10.000 immagini di test con le stesse dimensioni e le stesse etichette di classe.



1. Caricare il dataset direttamente dalla sua home page: <https://www.cs.toronto.edu/~kriz/cifar.html> ed espungere randomicamente un validation set pari al 10% dei dati di training, mantenendo il restante 90% come training set vero e proprio. Effettuare una data augmentation tramite `torchvision` usando mirroring orizzontali e verticali casuali nonché traslazioni e rotazioni casuali in un range di  $\pm 5$  pixel in x e y e  $\pm 10^\circ$  rispettivamente.

punti \_\_\_\_/ 8

2. Implementare un classificatore dei punti del data set processato al punto 1, utilizzando un algoritmo di Gradient Boosting con la seguente griglia di ricerca, usando una cross-validation a 10 fold:
  - Learning rate: 0.01, 0.1, 0.2
  - N. stimatori: 50, 100, 200
  - Min. campioni per foglia: 10, 20, 50

Stampare l'accuracy del miglior modello in addestramento e in predizione.

punti \_\_\_\_/ 4

3. Implementare una piccola rete neurale convoluzionale bidimensionale in PyTorch, utilizzando la semplice API `torch.nn.py`, per eseguire la classificazione multiclasse. La rete dovrà avere un adeguato numero di layer convoluzionali bidimensionali e, nella parte densa, dropout 0.2. Si utilizzi per l'addestramento l'ottimizzatore SGD con momento di Nesterov e learning rate decrescente esponenzialmente a partire da 0.01. Implementare una callback di early stopping con una pazienza sulla validation loss di 5 epoche e un incremento minimo di miglioramento pari a 0.01; implementare anche una callback di model checkpoint per il salvataggio del solo miglior modello rispetto alla minima validation loss.

punti \_\_\_\_/ 10

Data: \_\_\_\_\_ Allievo: \_\_\_\_\_ Matricola: \_\_\_\_\_



4. Conservare la lista delle accuracy di addestramento e di test su tutte le epoche del classificatore neurale e stamparne il grafico. Confrontare i risultati del miglior classificatore Gradient Boosting e del classificatore neurale calcolando e stampando, per ciascuno, la matrice di confusione, il valore di accuracy e di loss, la ROC e il valore di AUC per singola classe, calcolati sul test set.

punti \_\_\_\_/ 8

TOTALE: punti \_\_\_\_/ 30

---

#### Regole della prova scritta

Di seguito si riportano le regole da seguire e le caratteristiche della prova ai fini della valutazione:

- La durata complessiva della prova è pari a due ore e prevede una serie di quesiti che approfondiscono diversi aspetti dello stesso problema: ognuno sarà libero di dedicare ad ogni quesito il tempo che vorrà.
- La prova si svolge **interamente** al calcolatore.
- L'ambiente di sviluppo predisposto è un environmet conda/mamba dotato di editor Spyder e dei seguenti pacchetti:
  - Pandas
  - Matplotlib
  - Seaborn
  - Numpy
  - Scipy
  - Scikit-learn
  - Pyspark
  - Keras
  - Tensorflow
- Ai fini dell'avvio dell'ambiente, aprire il prompt dei comandi e digitare i due seguenti comandi:

```
$ mamba activate spyder-env  
$ spyder
```
- Sarà consentito consegnare dopo la prima ora di prova.
- Sarà necessario spegnere e consegnare i dispositivi mobili (smartphone, smartwatch e tablet) alla cattedra prima dello svolgimento della prova.
- La navigazione internet dalle postazioni sarà bloccata, in generale, e consentita solo verso i siti di documentazione delle librerie ed il repository delle slide in pdf.
- Il docente distribuirà copia digitale del compito ed eventuali data set direttamente dalla propria postazione ovvero tramite penna USB e allo stesso modo raccoglierà gli elaborati di programmazione.
- Il candidato consegnerà comunque il presente foglio datato e con l'indicazione del nome e del numero di matricola.
- Ai fini del calcolo del voto finale della prova, il valore massimo di ciascun quesito è riportato in calce allo stesso. La prova riceverà una valutazione pari alla somma dei voti riportati in ciascun quesito. Si precisa che il docente attribuirà ad ogni quesito una votazione non binaria, cioè non tutto il valore oppure 0, ma valuterà la correttezza formale dell'elaborato, il rigore metodologico dell'approccio teorico e l'originalità delle soluzioni proposte per attribuire una votazione nel range definito dal valor massimo del quesito.

Data: \_\_\_\_\_ Allievo: \_\_\_\_\_ Matricola: \_\_\_\_\_