



CORSO DI BIG DATA – MODULO ANALISI PER I BIG DATA
Simulazione Prova Scritta del 1 giugno 2026

Si consideri il data set Titanic composto dai file `train.csv` e `test.csv`, allegati al presente compito, costituiti da 891+418 record che descrivono i passeggeri del Titanic e li etichettano come sopravvissuti o meno sulla base delle seguenti caratteristiche:

- PassengerId
- Survived (1/0, solo train)
- Pclass (1, 2, 3)
- Name
- Sex ('male', 'female')
- Age (frazionaria se meno di 1; se stimata è nella forma xx.5)
- SibSp (numero di familiari; Sibling: fratelli/sorelle; Spouse: moglie/marito)
- Parch (numero familiari; Parent: padre/madre; Child: figli/figlie; Parch=0 per piccoli accompagnati solo dalla tata)
- Ticket
- Fare
- Cabin
- Embarked (C = Cherbourg, Q = Queenstown, S = Southampton)

1. Effettuare uno split 90%-10% tra training set e validation set. Individuare eventuali dati mancanti e farne l'imputazione secondo criteri che rispecchino la diversa stratificazione sociale e distribuzione di genere dei passeggeri ovvero rimuoverle se troppo sparse. Effettuare la codifica delle feature categoriche e l'eventuale scaling di tutte le feature, una volta trasformate in numeriche. Verificare la presenza di feature multicollineari e ridurle tramite opportune combinazioni lineari. Infine, procedere alla feature selection attraverso una *tecnica embedded* che impieghi un classificatore come modello. La scelta del modello embedded è lasciata al candidato, tenendo conto che il problema è di classificazione binaria.

punti ____/ 8

2. Implementare un classificatore SVM non lineare per il data set curato risultato del punto 1 con i seguenti iper-parametri:
 - a. $C = \{1, 1/\sqrt{n_samples}\}$
 - b. `kernel={RBF, polinomiale}`
 - c. grado del kernel polinomiale = {3, 4}

Usare l'accuracy come metrica e stampare l'accuracy del miglior classificatore e la test accuracy ottenuta in predizione.

punti ____/ 6

3. Implementare una piccola rete neurale densa con almeno tre layer nascosti in PyTorch, utilizzando la semplice API `torch.nn.py`, per eseguire la classificazione binaria. Si dovrà implementare anche il relativo `Dataset` per caricare i dati. I layer nascosti dovranno avere un dropout pari a 0.2. Si utilizzi per l'addestramento l'ottimizzatore Adam con weight decay pari a 1×10^{-4} e

Data: _____ Allievo: _____ Matricola: _____



learning rate decrescente esponenzialmente a partire da 0.01. Implementare una callback di early stopping con una pazienza sulla validation loss di 5 epoche e un incremento minimo di miglioramento pari a 0.01; implementare anche una callback di model checkpoint per il salvataggio del solo miglior modello rispetto alla minima validation loss.

punti ___/ 10

4. Conservare la lista delle accuracy di addestramento e di test su tutte le epoche del classificatore neurale e stamparne il grafico. Confrontare i risultati del miglior classificatore SVM e del classificatore neurale calcolando e stampando, per ciascuno, la matrice di confusione, il valore di accuracy e di loss. Calcolare e stampare in un unico grafico le curve ROC dei due classificatori binari e stamparne anche le relative AUC.

punti ___/ 6

TOTALE: punti ___/ 30

Regole della prova scritta

Di seguito si riportano le regole da seguire e le caratteristiche della prova ai fini della valutazione:

- La durata complessiva della prova è pari a due ore e prevede una serie di quesiti che approfondiscono diversi aspetti dello stesso problema: ognuno sarà libero di dedicare ad ogni quesito il tempo che vorrà.
- La prova si svolge **interamente** al calcolatore.
- L'ambiente di sviluppo predisposto è un environmet conda/mamba dotato di editor Spyder e dei seguenti pacchetti:
 - Pandas
 - Matplotlib
 - Seaborn
 - Numpy
 - Scipy
 - Scikit-learn
 - Pyspark
 - Keras
 - Tensorflow
- Ai fini dell'avvio dell'ambiente, aprire il prompt dei comandi e digitare i due seguenti comandi:

```
$ mamba activate spyder-env  
$ spyder
```
- Sarà consentito consegnare dopo la prima ora di prova.
- Sarà necessario spegnere e consegnare i dispositivi mobili (smartphone, smartwatch e tablet) alla cattedra prima dello svolgimento della prova.
- La navigazione internet dalle postazioni sarà bloccata, in generale, e consentita solo verso i siti di documentazione delle librerie ed il repository delle slide in pdf.
- Il docente distribuirà copia digitale del compito ed eventuali data set direttamente dalla propria postazione ovvero tramite penna USB e allo stesso modo raccoglierà gli elaborati di programmazione.
- Il candidato consegnerà comunque il presente foglio datato e con l'indicazione del nome e del numero di matricola.

Data: _____ Allievo: _____ Matricola: _____



**Università
degli Studi
di Palermo**

Dipartimento di Ingegneria
Direttore: prof. Antonino Valenza



10. Ai fini del calcolo del voto finale della prova, il valore massimo di ciascun quesito è riportato in calce allo stesso. La prova riceverà una valutazione pari alla somma dei voti riportati in ciascun quesito. Si precisa che il docente attribuirà ad ogni quesito una votazione non binaria, cioè non tutto il valore oppure 0, ma valuterà la correttezza formale dell'elaborato, il rigore metodologico dell'approccio teorico e l'originalità delle soluzioni proposte per attribuire una votazione nel range definito dal valor massimo del quesito.

Data: _____ Allievo: _____ Matricola: _____